

**Rapport du Projet de Fin Cycle**  
**En vue de l'obtention du diplôme en**  
**Ingénierie des Systèmes Informatique (IISI) de SUPMTI**  
**Bac+3**  
**Filière : Ingénierie Intelligente des Systèmes Réseaux et**  
**Télécommunication (IISRT)**

**Par: Fatimzahra El Hmaidy & Chaymae Kamouni**

**Sous le thème**

**Intelligence Artificielle appliquée à la santé, notamment l'analyse  
d'images médicales (IRM) pour la détection précoce de la maladie  
d'Alzheimer.**

**Membres de jury :**

|                                   |            |                     |
|-----------------------------------|------------|---------------------|
| <b>Mr. KRIOUILE Saad</b>          | Président  | Professeur à SUPMTI |
| <b>Mr. AIT EL MOUDEN Zakaria</b>  | Examineur  | Professeur à l'EST  |
| <b>Mr. EL HARMOUCHI Nouredine</b> | Rapporteur | Professeur à SUPMTI |
| <b>Mme : EL KHOUKHI Hasnae</b>    | Encadrante | Professeur à SUPMTI |

## **Dédicace**

Nous dédions ce travail,

À nos très chers parents, pour leur amour inconditionnel, leurs sacrifices, leur patience et leurs encouragements permanents. Leur soutien moral, leurs conseils et leurs prières ont été une source de motivation tout au long de notre parcours. Nous leur exprimons notre profonde gratitude et espérons que ce travail sera pour eux un motif de fierté.

À nos frères et sœurs, pour leur affection, leur présence, leurs encouragements et leur soutien tout au long de cette aventure. Leur confiance et leur bienveillance nous ont accompagnés dans les moments les plus exigeants.

À tous les membres de nos familles, qui ont toujours cru en nous et nous ont encouragés à persévérer jusqu'à l'aboutissement de ce projet.

Enfin, nous dédions ce travail à toutes les personnes qui nous ont soutenus, de près ou de loin, et qui ont contribué, par leurs conseils ou leurs encouragements, à la réalisation de ce mémoire.

Que ce travail soit le témoignage de notre reconnaissance et de notre profonde gratitude.

## **Remerciement**

Nous adressons nos plus sincères remerciements à notre encadrante, Mme Hassnae El Khoukhi, pour sa disponibilité, ses précieux conseils, son accompagnement et ses orientations tout au long de la réalisation de ce projet. Ses remarques pertinentes et son soutien ont grandement contribué à l'aboutissement de ce travail.

Nous exprimons également notre profonde gratitude à l'ensemble des enseignants du département, qui nous ont transmis leurs connaissances et leurs compétences tout au long de notre formation, ainsi qu'aux membres du jury, qui nous font l'honneur d'évaluer ce mémoire et auxquels nous adressons nos sincères remerciements pour le temps consacré à l'examen de notre travail.

Nous adressons une pensée toute particulière à nos parents, pour leur amour, leurs sacrifices, leurs encouragements constants et leur confiance indéfectible. Leur soutien moral a été une source de motivation tout au long de notre parcours universitaire.

Nos remerciements vont également à nos frères et sœurs, ainsi qu'à tous les membres de nos familles et à nos proches, pour leur présence, leurs encouragements et leur soutien durant cette période.

Enfin, nous remercions toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce mémoire et nous ont accompagnés tout au long de cette expérience.

À toutes et à tous, nous exprimons notre profonde reconnaissance et nos plus sincères remerciements.

## **Résumé**

Ce projet de fin d'études porte sur le développement d'un système intelligent destiné à la détection de la maladie d'Alzheimer à partir d'images d'Imagerie par Résonance Magnétique (IRM) en utilisant des techniques de Deep Learning. L'objectif principal est de classer automatiquement les images IRM en trois catégories : Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN).

Les images utilisées proviennent de la base de données ADNI et ont subi plusieurs étapes de prétraitement, notamment la lecture des fichiers DICOM, le redimensionnement, la normalisation, la conversion en RGB ainsi que l'augmentation des données (Data Augmentation). Deux modèles de Deep Learning ont été développés et comparés : un réseau de neurones convolutif (CNN) conçu spécifiquement pour cette étude et un modèle de Transfer Learning basé sur MobileNetV2.

Les performances des modèles ont été évaluées à l'aide de plusieurs métriques, notamment l'accuracy, la précision, le rappel (recall), le F1-score, la matrice de confusion ainsi que la courbe ROC. Les résultats expérimentaux montrent que le modèle MobileNetV2 a obtenu les meilleures performances avec une accuracy de 91 %, tandis que le modèle CNN a atteint 87 %. Une comparaison avec plusieurs travaux de la littérature a permis de situer les performances obtenues. Enfin, la méthode Grad-CAM a été utilisée afin d'améliorer l'interprétabilité des prédictions en mettant en évidence les régions cérébrales ayant le plus influencé les décisions des modèles.

### **Mots clés :**

Maladie d'Alzheimer, IRM, Deep Learning, CNN, MobileNetV2, Transfer Learning, Grad-CAM, ADNI.

# **Abstract**

This final-year project focuses on the development of an intelligent system for the detection of Alzheimer's disease from Magnetic Resonance Imaging (MRI) using Deep Learning techniques. The main objective is to automatically classify brain MRI images into three categories: Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI), and Cognitively Normal (CN).

The MRI images were obtained from the ADNI database and underwent several preprocessing steps, including DICOM image reading, resizing, normalization, RGB conversion, and data augmentation. Two Deep Learning approaches were implemented and compared: a custom Convolutional Neural Network (CNN) and a Transfer Learning model based on MobileNetV2.

The proposed models were evaluated using several performance metrics, including accuracy, precision, recall, F1-score, confusion matrix, and ROC curve. Experimental results showed that MobileNetV2 achieved the best performance with an accuracy of 91%, while the CNN model reached 87%. The obtained results were compared with several recent studies reported in the literature. Furthermore, the Grad-CAM explainability technique was employed to highlight the brain regions that contributed most to the model predictions, thereby improving the interpretability of the proposed system.

## **Keywords:**

Alzheimer's disease, MRI, Deep Learning, CNN, MobileNetV2, Transfer Learning, Grad-CAM , ADNI

## ملخص

يهدف هذا المشروع إلى تطوير نظام ذكي للمساعدة في الكشف المبكر عن مرض ألزهايمر اعتمادًا على صور ويتمثل الهدف الرئيسي (Deep Learning) باستخدام تقنيات التعلم العميق (MRI) بالرنين المغناطيسي التصوير (MCI)، والضعف الإدراكي البسيط (AD) مرض ألزهايمر: في تصنيف صور الدماغ تلقائيًا إلى ثلاث فئات (CN) والأشخاص السليمون إدراكًا.

، حيث خضعت الصور لعدة مراحل من المعالجة المسبقة، شملت قراءة ADNI اعتمدت الدراسة على قاعدة بيانات ، بالإضافة إلى تطبيق تقنيات زيادة RGB، وإعادة تحجيم الصور، وتطبيعها، وتحويلها إلى صيغة DICOM ملفات .يهدف تحسين أداء النماذج (Data Augmentation) البيانات

MobileNetV2، والثاني نموذج (CNN) تم تطوير ومقارنة نموذجين للتعلم العميق، الأول شبكة عصبية التلافيفية وقد تم تقييم أداء النموذجين باستخدام عدة مؤشرات، من بينها (Transfer Learning) المعتمد على التعلم بالنقل ، ومصفوفة F1-Score، ومقياس (Recall)، والاسترجاع (Precision)، والدقة الإيجابية (Accuracy) الدقة ROC، ومنحنى (Confusion Matrix) الالتباس

CNN، في حين حقق نموذج 91% حقق أفضل أداء، حيث بلغت دقته MobileNetV2 أظهرت النتائج أن نموذج Grad-CAM كما تمت مقارنة النتائج مع عدد من الدراسات العلمية المنشورة، واستخدام تقنية 86% دقة بلغت لتفسير قرارات النموذج وإبراز المناطق الدماغية الأكثر تأثيرًا في عملية التصنيف، مما يعزز موثوقية النظام المقترح وقابليته للتفسير

### كلمات الرئيسية :

MobileNetV2، الالتلافية، العصبية الشبكات العميق، التعلم المغناطيسي، بالرنين التصوير ألزهايمر، مرض ADNI، Grad-CAM بالنقل، التعلم

# **Table de matières**

|                                                                     |             |
|---------------------------------------------------------------------|-------------|
| <b>Dédicace .....</b>                                               | <b>ii</b>   |
| <b>Remerciement.....</b>                                            | <b>iii</b>  |
| <b>Résumé .....</b>                                                 | <b>iv</b>   |
| <b>Abstract.....</b>                                                | <b>v</b>    |
| <b>ملخص.....</b>                                                    | <b>vi</b>   |
| <b>Liste des figures.....</b>                                       | <b>x</b>    |
| <b>Liste des tableaux.....</b>                                      | <b>xii</b>  |
| <b>Liste des sigles et abréviations .....</b>                       | <b>xiii</b> |
| <b>INTRODUCTION GÉNÉRALE .....</b>                                  | <b>1</b>    |
| <b>CHAPITRE 1 : CADRE THÉORIQUE ET CONTEXTE TECHNOLOGIQUE .....</b> | <b>3</b>    |
| 1.1 Introduction .....                                              | 3           |
| 1.2 Maladies neurodégénératives .....                               | 4           |
| 1.2.1 Définition.....                                               | 4           |
| 1.2.2 Classification des maladies neurodégénératives.....           | 4           |
| 1.3 Maladie d'Alzheimer .....                                       | 6           |
| 1.3.1 Définition.....                                               | 6           |
| 1.3.2 Physiopathologie .....                                        | 7           |
| 1.3.3 Facteurs de risque .....                                      | 8           |
| 1.3.4 Symptômes .....                                               | 10          |
| 1.3.5 Stades de la maladie .....                                    | 11          |
| 1.4 Imagerie médicale .....                                         | 12          |
| 1.5 Imagerie IRM .....                                              | 14          |
| 1.5.1 Principe.....                                                 | 14          |
| 1.5.2 Types d'IRM .....                                             | 15          |
| 1.5.3 IRM et Alzheimer.....                                         | 16          |
| 1.6 Intelligence Artificielle .....                                 | 17          |
| 1.7 Machine Learning .....                                          | 18          |
| 1.8 Deep Learning.....                                              | 19          |
| 1.9 Réseaux de Neurones Convolutifs (CNN) .....                     | 21          |
| 1.10 Transfer Learning .....                                        | 23          |
| 1.11 Explainable Artificial Intelligence (XAI).....                 | 25          |
| 1.12 Revue bibliographique.....                                     | 27          |
| 1.12.1 Synthèse de la revue bibliographique.....                    | 29          |

|                                               |                                                 |    |
|-----------------------------------------------|-------------------------------------------------|----|
| 1.13                                          | Synthèse critique.....                          | 29 |
| 1.14                                          | Conclusion .....                                | 30 |
| CHAPITRE 2 : MÉTHODOLOGIE PROPOSÉE .....      |                                                 | 33 |
| 2.1                                           | Introduction.....                               | 33 |
| 2.2                                           | Environnement de travail.....                   | 33 |
| 2.2.1                                         | Environnement matériel.....                     | 34 |
| 2.2.2                                         | Environnement logiciel.....                     | 35 |
| 2.3                                           | Présentation du Dataset.....                    | 36 |
| 2.3.1                                         | Source du Dataset .....                         | 36 |
| 2.3.2                                         | Organisation du Dataset.....                    | 37 |
| 2.3.3                                         | Description des classes .....                   | 38 |
| 2.3.4                                         | Format des images .....                         | 40 |
| 2.4                                           | Prétraitement des images .....                  | 41 |
| 2.4.1                                         | Lecture des images DICOM .....                  | 41 |
| 2.4.2                                         | Redimensionnement des images .....              | 42 |
| 2.4.3                                         | Normalisation.....                              | 43 |
| 2.4.4                                         | Conversion en RGB .....                         | 44 |
| 2.4.5                                         | Data Augmentation .....                         | 45 |
| 2.5                                           | Préparation des données.....                    | 46 |
| 2.5.1                                         | Division des données .....                      | 46 |
| 2.5.2                                         | Pipeline de préparation .....                   | 46 |
| 2.6                                           | Développement des modèles de Deep Learning..... | 47 |
| 2.6.1                                         | Architecture du modèle CNN .....                | 48 |
| 2.6.2                                         | Architecture de MobileNetV2.....                | 50 |
| 2.7                                           | Paramètres d'entraînement .....                 | 51 |
| 2.8                                           | Méthodes d'évaluation .....                     | 54 |
| 2.10                                          | Conclusion .....                                | 57 |
| CHAPITRE 3 : IMPLÉMENTATION ET RÉSULTATS..... |                                                 | 59 |
| 3.1                                           | Introduction.....                               | 59 |
| 3.2                                           | Implémentation du système .....                 | 59 |
| 3.2.1                                         | Implémentation du modèle CNN .....              | 60 |
| 3.2.2                                         | Implémentation de MobileNetV2 .....             | 61 |
| 3.3                                           | Résultats expérimentaux du CNN.....             | 63 |
| 3.3.1                                         | Courbes Accuracy et Loss .....                  | 64 |
| 3.3.2                                         | Matrice de confusion.....                       | 66 |
| 3.3.3                                         | Courbe ROC et AUC .....                         | 67 |
| 3.3.4                                         | Rapport de classification.....                  | 68 |



|                                                            |           |
|------------------------------------------------------------|-----------|
| 3.3.5 Analyse des résultats.....                           | 69        |
| 3.4 Résultats expérimentaux de MobileNetV2 .....           | 70        |
| 3.4.1 Courbes Accuracy et Loss .....                       | 71        |
| 3.4.2 Matrice de confusion.....                            | 72        |
| 3.4.3 Courbe ROC et AUC .....                              | 73        |
| 3.4.4 Rapport de classification.....                       | 75        |
| 3.4.5 Analyse des résultats.....                           | 76        |
| 3.6 Comparaison des modèles.....                           | 77        |
| 3.6.2 Comparaison graphique .....                          | 79        |
| 3.6.3 Comparaison avec les travaux de la littérature ..... | 83        |
| 3.7 Interprétabilité du modèle (Grad-CAM).....             | 84        |
| 3.7.1 Principe de Grad-CAM.....                            | 84        |
| 3.7.3 Analyse des cartes d'activation .....                | 85        |
| 3.8 Discussion générale .....                              | 86        |
| 3.8.1 Analyse comparative des modèles .....                | 86        |
| 3.8.2 Avantages et limites.....                            | 87        |
| 3.8.3 Perspectives d'amélioration.....                     | 88        |
| 3.9 Conclusion .....                                       | 88        |
| <b>CONCLUSION ET PERSPECTIVE .....</b>                     | <b>90</b> |
| <b>Références.....</b>                                     | <b>91</b> |

## Liste des figures

|                                                                                                      |                                      |
|------------------------------------------------------------------------------------------------------|--------------------------------------|
| Figure 1.1 : Illustration des principales maladies neurodégénératives .....                          | 20                                   |
| Figure 1.2 : Formation des plaques amyloïdes .....                                                   | 22                                   |
| Figure 1.3 : Évolution des symptômes .....                                                           | 25                                   |
| Figure 1.4 : Exemples des différentes techniques .....                                               | 28                                   |
| Figure 1.5 : Fonctionnement d'une IRM.....                                                           | 29                                   |
| Figure 1.6 : Exemples des types d'IRM.....                                                           | 30                                   |
| Figure 1.7 : Zones cérébrales touchées.....                                                          | 31                                   |
| Figure 1.8 : Relation entre l'intelligence artificielle, le Machine Learning et le Deep Learning ... | 32                                   |
| Figure 1.9 : Types d'apprentissage.....                                                              | 33                                   |
| Figure 1.10 : Principe de la convolution .....                                                       | 36                                   |
| Figure 1.11 : Opération de Max Pooling .....                                                         | 37                                   |
| Figure 1.12 : Architecture générale d'un CNN .....                                                   | 37                                   |
| Figure 1.13 : Architecture MobileNetV2.....                                                          | 39                                   |
| Figure 1.14 : Exemple de Grad-CAM .....                                                              | 41                                   |
| Figure 2.1 : Organisation du Dataset .....                                                           | 52                                   |
| Figure 2.2 : Exemple d'une image IRM DICOM .....                                                     | 54                                   |
| Figure 2.3 : Lecture d'une image DICOM.....                                                          | 56                                   |
| Figure 2.4 : Redimensionnement.....                                                                  | 57                                   |
| Figure 2.5 : Conversion RGB.....                                                                     | 58                                   |
| Figure 2.6 : Exemples de Data Augmentation.....                                                      | 59                                   |
| Figure 2.7 : Pipeline de préparation des données .....                                               | <b>6Error! Bookmark not defined.</b> |
| Figure 2.8 : Architecture du CNN .....                                                               | 63                                   |
| Figure 2.9 : Architecture MobileNetV2.....                                                           | 65                                   |
| Figure 2.10 : Architecture globale du système proposé.....                                           | 71                                   |
| Figure 3.1 : Pipeline d'entraînement du CNN .....                                                    | 76                                   |
| Figure 3.2 : Pipeline d'implémentation du modèle MobileNetV2.....                                    | 78                                   |
| Figure 3.3 : Courbe accuracy.....                                                                    | 79                                   |
| Figure 3.4 : Courbe loss .....                                                                       | 80                                   |
| Figure 3.5 : Matrice de confusion.....                                                               | 81                                   |
| Figure 3.6 : Courbe ROC.....                                                                         | 83                                   |

|                                                                                   |     |
|-----------------------------------------------------------------------------------|-----|
| Figure 3.7 : Évolution de l'Accuracy du modèle MobileNetV2 .....                  | 86  |
| Figure 3.8 : Évolution de la fonction de perte (Loss) du modèle MobileNetV2 ..... | 87  |
| Figure 3.9 : Matrice de confusion du modèle MobileNetV2.....                      | 88  |
| Figure 3.10 : Courbe ROC.....                                                     | 89  |
| Figure 3.11 : Accuracy Comparaison .....                                          | 94  |
| Figure 3.12 : Precision Comparaison .....                                         | 95  |
| Figure 3.13 : Recall Comparaison .....                                            | 95  |
| Figure 3.14 : F1-score Comparaison .....                                          | 96  |
| Figure 3.15 : AUC Comparaison .....                                               | 97  |
| Figure 3.16 : Training Time Comparaison .....                                     | 97  |
| Figure 3.17 : Image IRM originale.....                                            | 100 |
| Figure 3.18 : Carte thermique (Heatmap) générée par Grad-CAM.....                 | 100 |
| Figure 3.19 : Superposition (Overlay) de la carte thermique sur l'image IRM ..... | 100 |

## Liste des tableaux

|                                                                   |                                     |    |
|-------------------------------------------------------------------|-------------------------------------|----|
| Tableau 1 : Comparaison des maladies neurodégénératives.....      | <b>Error! Bookmark not defined.</b> | 9  |
| Tableau 2 : Facteurs de risque de la maladie d'Alzheimer.....     |                                     | 23 |
| Tableau 3 : Comparaison CN/MCI/AD .....                           |                                     | 26 |
| Tableau 4 : Comparaison des techniques.....                       |                                     | 27 |
| Tableau 5 : Comparaison des méthodes XAI .....                    |                                     | 41 |
| Tableau 6 : Travaux de classification .....                       |                                     | 42 |
| Tableau 7 : Configuration matérielle .....                        |                                     | 48 |
| Tableau 8 : Logiciels et bibliothèques utilisés.....              |                                     | 50 |
| Tableau 9 : Répartition des images .....                          |                                     | 53 |
| Tableau 10 : Répartition des données.....                         |                                     | 60 |
| Tableau 11 : Description des couches du CNN .....                 |                                     | 63 |
| Tableau 12 : Paramètres d'entraînement des modèles .....          |                                     | 65 |
| Tableau 13 : Rapport de classification du modèle CNN.....         |                                     | 84 |
| Tableau 14 : Rapport de classification du modèle MobileNetV2..... |                                     | 91 |
| Tableau 15 : Comparaison des performances .....                   |                                     | 93 |
| Tableau 16 : Comparaison avec les travaux existants .....         |                                     | 98 |

## Liste des sigles et abréviations

| ABRÉVIATION     | SIGNIFICATION                                                              |
|-----------------|----------------------------------------------------------------------------|
| <b>AD</b>       | Alzheimer's Disease (Maladie d'Alzheimer)                                  |
| <b>ADNI</b>     | Alzheimer's Disease Neuroimaging Initiative                                |
| <b>AI</b>       | Artificial Intelligence (Intelligence Artificielle)                        |
| <b>AUC</b>      | Area Under the Curve                                                       |
| <b>CAD</b>      | Computer-Aided Diagnosis (Diagnostic Assisté par Ordinateur)               |
| <b>CAM</b>      | Class Activation Mapping                                                   |
| <b>CNN</b>      | Convolutional Neural Network                                               |
| <b>CN</b>       | Cognitively Normal                                                         |
| <b>CT</b>       | Computed Tomography (Tomodensitométrie)                                    |
| <b>DICOM</b>    | Digital Imaging and Communications in Medicine                             |
| <b>DL</b>       | Deep Learning (Apprentissage Profond)                                      |
| <b>FMRI</b>     | Functional Magnetic Resonance Imaging (IRM Fonctionnelle)                  |
| <b>F1-SCORE</b> | F1 Score                                                                   |
| <b>GRAD-CAM</b> | Gradient-weighted Class Activation Mapping                                 |
| <b>GPU</b>      | Graphics Processing Unit                                                   |
| <b>IA</b>       | Intelligence Artificielle                                                  |
| <b>IMAGENET</b> | Image Database for Visual Object Recognition                               |
| <b>IRM</b>      | Imagerie par Résonance Magnétique                                          |
| <b>LIME</b>     | Local Interpretable Model-agnostic Explanations                            |
| <b>MCI</b>      | Mild Cognitive Impairment (Trouble Cognitif Léger)                         |
| <b>ML</b>       | Machine Learning (Apprentissage Automatique)                               |
| <b>MRI</b>      | Magnetic Resonance Imaging                                                 |
| <b>PET</b>      | Positron Emission Tomography                                               |
| <b>PPMI</b>     | Parkinson's Progression Markers Initiative                                 |
| <b>RELU</b>     | Rectified Linear Unit                                                      |
| <b>RGB</b>      | Red Green Blue                                                             |
| <b>ROC</b>      | Receiver Operating Characteristic                                          |
| <b>SHAP</b>     | SHapley Additive exPlanations                                              |
| <b>SVM</b>      | Support Vector Machine                                                     |
| <b>U-NET</b>    | U-shaped Convolutional Neural Network                                      |
| <b>WHO</b>      | World Health Organization (Organisation Mondiale de la Santé)              |
| <b>XAI</b>      | Explainable Artificial Intelligence (Intelligence Artificielle Explicable) |

# INTRODUCTION GÉNÉRALE

L'évolution rapide des technologies de l'information et de l'intelligence artificielle transforme progressivement les pratiques du domaine médical. Grâce aux progrès réalisés en apprentissage automatique et en Deep Learning, il devient aujourd'hui possible de développer des systèmes capables d'assister les professionnels de santé dans l'analyse d'examens médicaux complexes. Ces outils constituent un soutien précieux pour améliorer la rapidité, la précision et la fiabilité du diagnostic, en particulier pour les maladies nécessitant une détection précoce.

Parmi ces maladies, la maladie d'Alzheimer représente un défi majeur en raison de son caractère neurodégénératif, de sa progression irréversible et de son impact considérable sur les patients, leurs familles et les systèmes de santé. Le diagnostic précoce de cette pathologie demeure essentiel afin de mettre en place une prise en charge adaptée et de ralentir l'évolution des troubles cognitifs. Dans ce contexte, l'Imagerie par Résonance Magnétique (IRM) constitue un outil de référence pour l'observation des modifications anatomiques du cerveau. Toutefois, l'interprétation de ces images reste une tâche complexe qui exige une expertise médicale importante.

Face à ces difficultés, le recours au Deep Learning apparaît comme une solution prometteuse pour automatiser l'analyse des images médicales. Les réseaux de neurones convolutifs permettent d'extraire automatiquement des caractéristiques discriminantes, tandis que les techniques de Transfer Learning facilitent le développement de modèles performants même lorsque les jeux de données disponibles sont limités. Par ailleurs, l'émergence des méthodes d'intelligence artificielle explicable contribue à rendre les décisions des modèles plus compréhensibles et plus fiables dans un contexte médical.

C'est dans cette perspective que s'inscrit ce projet de fin d'études. Son objectif est de développer un système intelligent capable de classifier automatiquement des images IRM cérébrales en trois catégories cliniques : **Alzheimer's Disease (AD)**, **Mild Cognitive Impairment (MCI)** et **Cognitively Normal (CN)**. Pour atteindre cet objectif, une étude comparative est réalisée entre un modèle **CNN** développé spécifiquement pour ce projet et une approche de **Transfer Learning** basée sur **MobileNetV2**. Afin d'améliorer l'interprétabilité des résultats obtenus, la méthode **Grad-CAM** est intégrée pour visualiser les régions des images ayant le plus influencé les prédictions du modèle.

Le présent mémoire est organisé en trois chapitres. Le premier présente les fondements théoriques relatifs à la maladie d'Alzheimer, à l'IRM, au Deep Learning et aux travaux de recherche existants. Le deuxième décrit la méthodologie adoptée, depuis la préparation des données jusqu'à la conception des modèles et leur évaluation. Enfin, le troisième chapitre est consacré aux expérimentations, à l'analyse des résultats obtenus, à la comparaison des modèles ainsi qu'à la discussion des principales perspectives d'amélioration.

# CHAPITRE1:

## CADRE THÉORIQUE ET CONTEXTE TECHNOLOGIQUE

# CHAPITRE 1 : CADRE THÉORIQUE ET CONTEXTE TECHNOLOGIQUE

## 1.1 Introduction

Les maladies neurodégénératives représentent aujourd'hui un enjeu majeur de santé publique en raison de l'augmentation de leur prévalence. Parmi elles, la maladie d'Alzheimer est la forme de démence la plus fréquente et touche un nombre croissant de personnes dans le monde. Selon l'Organisation mondiale de la Santé, cette tendance devrait se poursuivre au cours des prochaines décennies, soulignant l'importance de développer des méthodes de diagnostic précoces et fiables [15].

La maladie d'Alzheimer se manifeste principalement par une dégradation progressive de la mémoire, du raisonnement, du langage et des capacités d'orientation. Les lésions cérébrales apparaissent généralement plusieurs années avant les premiers signes cliniques, ce qui rend le diagnostic précoce particulièrement difficile. Pourtant, une détection à un stade initial permet une prise en charge plus adaptée, un meilleur suivi médical et la mise en œuvre de traitements visant à ralentir l'évolution de la maladie et à améliorer la qualité de vie des patients [15].

Dans ce contexte, l'Imagerie par Résonance Magnétique (IRM) joue un rôle essentiel dans le diagnostic de la maladie d'Alzheimer. Grâce à ses images anatomiques de haute résolution, elle permet d'observer les structures cérébrales et de mettre en évidence des anomalies caractéristiques, telles que l'atrophie de l'hippocampe ou la diminution du volume cérébral [3], [10], [15]. Toutefois, l'interprétation de ces images reste complexe, en particulier aux premiers stades de la maladie, ce qui a conduit au développement de systèmes d'aide au diagnostic basés sur l'intelligence artificielle [6].

Au cours des dernières années, les progrès du Deep Learning ont profondément transformé l'analyse des images médicales. Les réseaux de neurones convolutifs (CNN) et les techniques de Transfer Learning, telles que MobileNetV2, permettent d'extraire automatiquement des caractéristiques pertinentes à partir des images IRM et d'améliorer les performances de classification [15]. Par ailleurs, les méthodes d'Explainable Artificial Intelligence (XAI), notamment Grad-CAM, renforcent l'interprétabilité des modèles en mettant en évidence les régions des images ayant influencé leurs prédictions.

Dans cette perspective, ce chapitre présente les bases théoriques nécessaires à la compréhension du présent travail. Il aborde d'abord les notions fondamentales relatives à la maladie d'Alzheimer et à l'Imagerie par Résonance Magnétique (IRM), puis les principaux concepts du Deep Learning appliqués à l'analyse des images médicales, notamment les réseaux de neurones convolutifs, le Transfer Learning et les approches d'intelligence artificielle explicable. Enfin, une revue de la littérature est réalisée afin d'analyser les travaux récents, d'identifier leurs principales limites et de justifier les choix méthodologiques retenus dans le cadre de ce projet.



## 1.2 Maladies neurodégénératives

### 1.2.1 Définition

Les maladies neurodégénératives constituent un ensemble de pathologies chroniques caractérisées par une détérioration progressive du système nerveux central. Elles se manifestent par une destruction graduelle des neurones ainsi que de leurs connexions synaptiques, entraînant une altération des fonctions cognitives, motrices ou comportementales [31].

Le processus neurodégénératif résulte généralement d'une accumulation anormale de protéines dans certaines régions du cerveau, provoquant un dysfonctionnement cellulaire puis la mort des neurones. Cette perte neuronale est irréversible et s'accroît progressivement au cours du temps, conduisant à une dégradation des capacités intellectuelles, de la mémoire, du langage, de la coordination motrice ou encore du comportement selon les régions cérébrales affectées.

Les causes exactes de ces maladies demeurent encore partiellement inconnues. Toutefois, plusieurs facteurs peuvent contribuer à leur apparition, notamment le vieillissement, les prédispositions génétiques, les facteurs environnementaux ainsi que certains mécanismes inflammatoires ou métaboliques. En raison de leur évolution lente et progressive, les maladies neurodégénératives nécessitent des méthodes de diagnostic précoce capables d'identifier les premiers signes de la maladie avant l'apparition de symptômes sévères.

L'utilisation de l'imagerie médicale et des techniques d'intelligence artificielle constitue aujourd'hui une approche prometteuse pour améliorer la détection précoce de ces pathologies et faciliter leur prise en charge clinique.

### 1.2.2 Classification des maladies neurodégénératives

Les maladies neurodégénératives regroupent plusieurs pathologies présentant des mécanismes biologiques différents mais ayant en commun une dégénérescence progressive des neurones. Parmi les plus étudiées figurent la maladie de Parkinson, la maladie de Huntington, la sclérose en plaques et la maladie d'Alzheimer [32].

#### Maladie de Parkinson

La maladie de Parkinson est une affection neurodégénérative caractérisée par la destruction progressive des neurones producteurs de dopamine situés dans la substance noire du cerveau. Cette diminution de dopamine entraîne principalement des troubles moteurs tels que les tremblements au repos, la rigidité musculaire, la lenteur des mouvements (bradykinésie) et les difficultés d'équilibre [9]. Avec l'évolution de la maladie, des troubles cognitifs et comportementaux peuvent également apparaître [36].

#### Maladie de Huntington

La maladie de Huntington est une maladie génétique héréditaire causée par une mutation du gène HTT. Elle provoque une dégénérescence progressive des cellules nerveuses, principalement dans les ganglions de la base. Les patients présentent des mouvements

involontaires appelés chorées, des troubles psychiatriques ainsi qu'une détérioration progressive des fonctions cognitives. Cette maladie évolue généralement sur plusieurs décennies et entraîne une perte progressive d'autonomie [37].

### Sclérose en Plaques (SEP)

La sclérose en plaques est une maladie auto-immune du système nerveux central caractérisée par une destruction de la myéline, la gaine protectrice entourant les fibres nerveuses. Cette démyélinisation perturbe la transmission des influx nerveux et provoque divers symptômes neurologiques tels que des troubles visuels, des difficultés motrices, des troubles de l'équilibre ou encore des déficits sensoriels. L'IRM constitue l'un des principaux outils utilisés pour son diagnostic et son suivi [38].

### Maladie d'Alzheimer

La maladie d'Alzheimer est la forme la plus fréquente de démence chez les personnes âgées. Elle se caractérise par une accumulation anormale de plaques amyloïdes et d'enchevêtrements neurofibrillaires dans le cerveau, entraînant une destruction progressive des neurones [15]. Les premiers symptômes concernent généralement la mémoire récente, puis s'étendent progressivement au langage, au raisonnement, à l'orientation et aux capacités quotidiennes. Les modifications anatomiques observées à l'IRM, notamment l'atrophie de l'hippocampe et la réduction du volume cérébral, en font une cible privilégiée pour les méthodes de diagnostic assisté par intelligence artificielle [35].

Tableau 1. : *Comparaison des maladies neurodégénératives.*

| MALADIE           | CAUSE PRINCIPALE                                   | ZONE DU CERVEAU AFFECTÉE           | PRINCIPAUX SYMPTÔMES                                           | TRANCHE D'ÂGE             |
|-------------------|----------------------------------------------------|------------------------------------|----------------------------------------------------------------|---------------------------|
| <b>ALZHEIMER</b>  | Accumulation de plaques amyloïdes et protéines Tau | Hippocampe, cortex cérébral        | Perte de mémoire, troubles cognitifs, désorientation           | Généralement après 65 ans |
| <b>PARKINSON</b>  | Dégénérescence des neurones dopaminergiques        | Substance noire (Substantia Nigra) | Tremblements, rigidité musculaire, lenteur des mouvements      | 45 à 75 ans               |
| <b>HUNTINGTON</b> | Mutation génétique du gène HTT                     | Ganglions de la base               | Mouvements involontaires, troubles cognitifs et psychiatriques | 30 à 50 ans               |

## SCLÉROSE EN PLAQUES

Destruction  
auto-immune de  
la myéline

Système  
nerveux central

Troubles  
moteurs, visuels  
et sensoriels

20 à 40 ans




Figure 1.1 : Illustration des principales maladies neurodégénératives [31]

Parmi les différentes maladies neurodégénératives présentées, la maladie d'Alzheimer constitue la pathologie la plus répandue et la plus étudiée dans le domaine de l'imagerie médicale et de l'intelligence artificielle. La section suivante est donc consacrée à une étude détaillée de cette maladie, de ses mécanismes biologiques et de ses manifestations cliniques.

## 1.3 Maladie d'Alzheimer

### 1.3.1 Définition

La maladie d'Alzheimer est une maladie neurodégénérative chronique et progressive caractérisée par une détérioration irréversible des fonctions cognitives, notamment la mémoire, le langage, le raisonnement et les capacités d'orientation. Elle constitue la forme la plus fréquente de démence chez les personnes âgées [14].

Selon l'Organisation Mondiale de la Santé (OMS), la démence touche plus de 55 millions de personnes dans le monde, et la maladie d'Alzheimer représente environ 60 à 70 % de l'ensemble des cas. Chaque année, près de 10 millions de nouveaux cas de démence sont diagnostiqués à l'échelle mondiale. Avec le vieillissement progressif de la population, ce nombre devrait augmenter considérablement au cours des prochaines décennies.

La maladie se développe progressivement au sein du cerveau plusieurs années avant l'apparition des premiers symptômes cliniques. Les lésions cérébrales provoquent une perte progressive des neurones et une altération des connexions synaptiques, entraînant une diminution des capacités cognitives et fonctionnelles du patient. À mesure que la maladie évolue, les personnes atteintes deviennent progressivement dépendantes pour la réalisation des activités quotidiennes [35].

En raison de son impact humain, social et économique considérable, la maladie d'Alzheimer représente aujourd'hui l'un des principaux enjeux de santé publique et constitue un domaine majeur de recherche en neurologie, en imagerie médicale et en intelligence artificielle.

### 1.3.2 Physiopathologie

La physiopathologie de la maladie d'Alzheimer repose principalement sur l'accumulation anormale de protéines dans le cerveau, conduisant à la destruction progressive des neurones et à l'altération des fonctions cognitives. Les deux mécanismes biologiques les plus importants sont la formation des plaques amyloïdes et l'accumulation des protéines Tau.

#### Plaques amyloïdes

Les plaques amyloïdes sont des dépôts extracellulaires constitués principalement de peptides bêta-amyloïdes (A $\beta$ ). Ces peptides proviennent du clivage anormal d'une protéine appelée APP (Amyloid Precursor Protein), naturellement présente dans les membranes neuronales.

Chez les individus sains, ces fragments sont éliminés naturellement par l'organisme. Cependant, chez les patients atteints de la maladie d'Alzheimer, les peptides bêta-amyloïdes s'accumulent progressivement et s'agrègent sous forme de plaques entre les neurones. Ces dépôts perturbent la communication neuronale, provoquent une inflammation cérébrale et favorisent la dégénérescence des cellules nerveuses [39].

#### Protéines Tau

Les protéines Tau sont des protéines intracellulaires impliquées dans la stabilisation des microtubules, structures essentielles au transport des nutriments et des informations à l'intérieur des neurones.

Dans la maladie d'Alzheimer, ces protéines subissent une hyperphosphorylation anormale qui modifie leur structure. Elles se détachent alors des microtubules et s'agrègent sous forme d'enchevêtrements neurofibrillaires à l'intérieur des neurones. Cette accumulation perturbe le fonctionnement cellulaire, bloque le transport intracellulaire et conduit progressivement à la mort neuronale [39].

#### Mort neuronale et déclin cognitif

L'accumulation simultanée des plaques amyloïdes et des enchevêtrements de protéines Tau entraîne une destruction progressive des neurones et des connexions synaptiques. Les régions cérébrales les plus touchées sont l'hippocampe, impliqué dans la mémoire, ainsi que le cortex cérébral responsable des fonctions cognitives supérieures.

Cette dégénérescence provoque une diminution progressive des capacités cognitives telles que la mémoire, l'apprentissage, le langage, le raisonnement et l'orientation spatiale. Avec l'évolution de la maladie, les dommages cérébraux deviennent irréversibles et conduisent à une perte importante d'autonomie.




Figure 1.2 : Formation des plaques amyloïdes

### 1.3.3 Facteurs de risque

La maladie d'Alzheimer résulte de l'interaction complexe entre plusieurs facteurs biologiques, génétiques, environnementaux et comportementaux. Bien que les mécanismes exacts de son apparition ne soient pas encore totalement élucidés, de nombreuses études ont permis d'identifier différents facteurs susceptibles d'augmenter le risque de développer cette pathologie. Ces facteurs sont généralement classés en deux catégories : les facteurs non modifiables, sur lesquels il n'est pas possible d'agir, et les facteurs modifiables, qui peuvent être contrôlés ou réduits par l'adoption d'un mode de vie sain.

#### 🌈 Âge

L'âge est considéré comme le facteur de risque le plus important de la maladie d'Alzheimer. En effet, le risque de développer la maladie augmente considérablement avec le vieillissement. Bien que la maladie puisse apparaître précocement dans certains cas rares, elle touche principalement les personnes âgées de plus de 65 ans. Après cet âge, la probabilité de développer la maladie double approximativement tous les cinq ans. Ce phénomène s'explique notamment par l'accumulation progressive de dommages cellulaires, le vieillissement des neurones et la diminution des mécanismes naturels de réparation du cerveau [40].

#### 🌈 Génétique

Les facteurs génétiques jouent également un rôle important dans le développement de la maladie. Certaines mutations héréditaires peuvent provoquer des formes familiales précoces de la maladie d'Alzheimer, bien que celles-ci restent relativement rares. Parmi les facteurs génétiques les plus étudiés figure le gène APOE (Apolipoprotéine E). La présence de l'allèle APOE- $\epsilon$ 4 est associée à une augmentation significative du risque de développer la maladie. Les

individus porteurs d'une ou deux copies de cet allèle présentent généralement une susceptibilité plus élevée à l'accumulation des plaques amyloïdes dans le cerveau. Toutefois, la présence de ce gène ne signifie pas nécessairement qu'une personne développera la maladie, mais elle augmente simplement le niveau de risque [40].

#### Hypertension artérielle

L'hypertension artérielle constitue un facteur de risque cardiovasculaire fortement associé au déclin cognitif. Une pression artérielle élevée pendant plusieurs années peut endommager les vaisseaux sanguins cérébraux et réduire l'apport en oxygène et en nutriments essentiels aux neurones [40]. Cette altération de la circulation sanguine favorise la détérioration progressive des cellules nerveuses et peut accélérer les mécanismes neurodégénératifs observés dans la maladie d'Alzheimer. Le contrôle régulier de la pression artérielle est donc considéré comme une mesure importante de prévention [41].

#### Diabète

Le diabète de type 2 est également reconnu comme un facteur augmentant le risque de développer la maladie d'Alzheimer. Les perturbations du métabolisme du glucose peuvent affecter le fonctionnement normal du cerveau et favoriser l'apparition de processus inflammatoires [40]. De plus, le diabète contribue à l'altération des vaisseaux sanguins, ce qui peut réduire l'irrigation cérébrale et accélérer la perte neuronale. Certaines études suggèrent même l'existence d'un lien étroit entre la résistance à l'insuline et l'accumulation des protéines impliquées dans la maladie d'Alzheimer [41].

#### Mode de vie

Le mode de vie influence fortement la santé cérébrale tout au long de la vie. Plusieurs habitudes peuvent augmenter le risque de développer la maladie d'Alzheimer. Le tabagisme favorise le stress oxydatif et les lésions vasculaires, tandis qu'une alimentation riche en graisses saturées et en sucres peut contribuer à l'apparition de troubles métaboliques. La sédentarité réduit la circulation sanguine cérébrale et limite les effets protecteurs de l'activité physique sur les neurones. L'obésité, particulièrement à l'âge moyen, est également associée à un risque accru de déclin cognitif. À l'inverse, une activité physique régulière, une alimentation équilibrée, des interactions sociales fréquentes et des activités intellectuelles stimulantes contribuent à préserver les fonctions cognitives et peuvent réduire le risque de développer la maladie [40].

Tableau 2. *Facteurs de risque de la maladie d'Alzheimer*

| CATÉGORIE                  | FACTEURS                                      | CARACTÈRE MODIFIABLE |
|----------------------------|-----------------------------------------------|----------------------|
| FACTEURS DÉMOGRAPHIQUES    | Âge avancé                                    | Non                  |
| FACTEURS GÉNÉTIQUES        | Gène APOE-ε4, antécédents familiaux           | Non                  |
| FACTEURS CARDIOVASCULAIRES | Hypertension artérielle, hypercholestérolémie | Oui                  |

|                                  |                                                                                      |               |
|----------------------------------|--------------------------------------------------------------------------------------|---------------|
| FACTEURS<br>MÉTABOLIQUES         | Diabète de type 2, obésité                                                           | Oui           |
| FACTEURS<br>COMPORTEMENTAUX      | Tabagisme, alcoolisme,<br>sédentarité                                                | Oui           |
| FACTEURS COGNITIFS<br>ET SOCIAUX | Isolement social, faible<br>niveau d'éducation, faible<br>stimulation intellectuelle | Partiellement |

### 1.3.4 Symptômes

Les symptômes de la maladie d'Alzheimer apparaissent progressivement et s'aggravent au fil du temps en raison de la destruction progressive des neurones et des connexions synaptiques. Les premiers signes sont souvent discrets et peuvent être confondus avec les effets normaux du vieillissement. Cependant, à mesure que la maladie évolue, les troubles deviennent plus fréquents et affectent significativement la vie quotidienne du patient [42].

#### Perte de mémoire

La perte de mémoire constitue généralement le symptôme le plus précoce et le plus caractéristique de la maladie d'Alzheimer. Les patients éprouvent des difficultés à retenir des informations récentes, à se souvenir d'événements récents ou à apprendre de nouvelles informations. Ils peuvent oublier des rendez-vous, répéter plusieurs fois les mêmes questions ou égarer régulièrement des objets. Cette altération de la mémoire est principalement liée à la détérioration de l'hippocampe, région cérébrale impliquée dans les mécanismes de mémorisation [42].

#### Désorientation

Avec la progression de la maladie, les patients présentent des troubles de l'orientation dans le temps et dans l'espace. Ils peuvent oublier la date, le jour de la semaine ou la saison en cours. Certains éprouvent des difficultés à reconnaître des lieux familiers ou à retrouver leur chemin dans des environnements pourtant connus. Cette désorientation peut progressivement compromettre leur autonomie et augmenter les risques d'accidents [42].

#### Troubles cognitifs

La maladie affecte également plusieurs fonctions cognitives supérieures. Les patients rencontrent des difficultés croissantes pour raisonner, résoudre des problèmes, prendre des décisions ou planifier des tâches complexes. Les capacités d'attention et de concentration diminuent progressivement, rendant difficiles certaines activités quotidiennes telles que la gestion financière, l'organisation des tâches ou la compréhension d'informations complexes [42].

#### Troubles du langage

Les troubles du langage apparaissent fréquemment au cours de l'évolution de la maladie. Les patients ont des difficultés à trouver les mots appropriés, à suivre une conversation ou à



comprendre certains messages. Le vocabulaire devient progressivement plus limité et les phrases peuvent être incomplètes ou incohérentes. Dans les stades avancés, la communication verbale peut devenir fortement altérée.

L'ensemble de ces symptômes évolue progressivement sur plusieurs années. Leur aggravation reflète l'étendue croissante des lésions cérébrales provoquées par l'accumulation des plaques amyloïdes, des protéines Tau et la mort neuronale associée [42].




Figure 1.3 : Évolution des symptômes [43]

### 1.3.5 Stades de la maladie

Dans les études de neuroimagerie et les bases de données telles que ADNI et OASIS, les sujets sont généralement répartis en trois catégories principales correspondant aux différents stades d'évolution de la maladie : les sujets cognitivement normaux (CN), les patients présentant un déficit cognitif léger (MCI) et les patients atteints de la maladie d'Alzheimer (AD) [6], [11].

#### ✚ CN (Cognitively Normal)

Les sujets classés dans la catégorie CN sont considérés comme cognitivement normaux. Ils ne présentent aucun déficit cognitif significatif et conservent une mémoire, un langage, une capacité de raisonnement et une autonomie comparables à ceux attendus pour leur âge. Les images IRM de ces individus montrent généralement une structure cérébrale normale sans signe majeur d'atrophie [6], [13].

#### ✚ MCI (Mild Cognitive Impairment)

Le déficit cognitif léger constitue un stade intermédiaire entre le vieillissement normal et la maladie d'Alzheimer. Les patients présentent principalement des troubles de mémoire plus importants que ceux observés lors du vieillissement normal, mais restent capables d'effectuer la plupart des activités quotidiennes de manière autonome. Tous les patients MCI n'évoluent pas nécessairement vers la maladie d'Alzheimer, mais cette catégorie est considérée comme une population à risque élevé [6],[15].

#### ✚ AD (Alzheimer's Disease)



Cette catégorie correspond aux patients atteints d'une maladie d'Alzheimer diagnostiquée cliniquement. Les déficits cognitifs deviennent importants et affectent significativement la mémoire, le langage, le raisonnement ainsi que l'autonomie du patient. Les examens IRM révèlent généralement une atrophie cérébrale plus prononcée, notamment au niveau de l'hippocampe et du cortex cérébral. Les patients nécessitent progressivement une assistance pour réaliser les activités quotidiennes [11],[15].

Tableau 3. Comparaison CN/MCI/AD.

| CRITÈRE                           | CN (SUJET SAIN)        | MCI (DÉFICIT COGNITIF LÉGER)        | AD (ALZHEIMER)          |
|-----------------------------------|------------------------|-------------------------------------|-------------------------|
| <b>MÉMOIRE</b>                    | Normale                | Légèrement altérée                  | Fortement altérée       |
| <b>ORIENTATION</b>                | Normale                | Légèrement perturbée                | Souvent altérée         |
| <b>LANGAGE</b>                    | Normal                 | Quelques difficultés occasionnelles | Difficultés importantes |
| <b>FONCTIONS COGNITIVES</b>       | Normales               | Modérément affectées                | Fortement affectées     |
| <b>AUTONOMIE</b>                  | Complète               | Majoritairement conservée           | Réduite                 |
| <b>ATROPHIE CÉRÉBRALE À L'IRM</b> | Absente ou très faible | Début d'atrophie hippocampique      | Atrophie marquée        |
| <b>RISQUE D'ÉVOLUTION</b>         | Faible                 | Élevé vers AD                       | Maladie installée       |

La compréhension des mécanismes physiopathologiques et des manifestations cliniques de la maladie d'Alzheimer met en évidence la nécessité de disposer d'outils de diagnostic précis et non invasifs. Dans ce contexte, l'imagerie médicale joue un rôle essentiel pour observer les modifications cérébrales associées à la maladie.

#### 1.4 Imagerie médicale

L'imagerie médicale regroupe un ensemble de techniques permettant de visualiser les structures internes du corps humain afin d'aider au diagnostic et au suivi des maladies. Dans le domaine des maladies neurodégénératives, elle joue un rôle essentiel dans l'observation du cerveau et la détection des anomalies associées à différentes pathologies. Parmi les principales techniques utilisées figurent la radiographie, le scanner (CT), la tomographie par émission de positons (PET) et l'imagerie par résonance magnétique (IRM). Chacune repose sur un principe physique différent et fournit des informations complémentaires sur l'anatomie ou le fonctionnement des tissus biologiques [10].

 Radiographie

La radiographie utilise les rayons X pour produire des images des structures internes du corps. Elle est principalement utilisée pour l'étude des os, mais son application à l'exploration cérébrale reste limitée en raison de son faible contraste pour les tissus mous [44].

#### Scanner CT

Le scanner ou tomodensitométrie repose également sur l'utilisation des rayons X, mais permet d'obtenir des images en coupes du corps humain. Il est couramment utilisé pour détecter les lésions cérébrales, les hémorragies ou les tumeurs [46].

#### PET

La tomographie par émission de positons (PET) est une technique d'imagerie fonctionnelle permettant d'observer l'activité métabolique du cerveau grâce à l'injection d'un traceur radioactif. Elle est particulièrement utile pour l'étude des maladies neurodégénératives [10].

#### IRM

L'imagerie par résonance magnétique (IRM) utilise un champ magnétique et des ondes radio pour produire des images détaillées des tissus biologiques sans exposition aux rayonnements ionisants. Grâce à sa haute résolution et à sa capacité à visualiser les structures cérébrales, elle constitue aujourd'hui l'une des techniques les plus utilisées pour le diagnostic et le suivi de la maladie d'Alzheimer [45].

*Tableau 4. Comparaison des techniques.*

| TECHNIQUE           | PRINCIPE                            | RAYON NEMEN T | VISUALISATION DU CERVEAU | AVANTAGES                             | LIMITES                     |
|---------------------|-------------------------------------|---------------|--------------------------|---------------------------------------|-----------------------------|
| <b>RADIOGRAPHIE</b> | Rayons X                            | Oui           | Faible                   | Rapide et peu coûteuse                | Peu adaptée aux tissus mous |
| <b>SCANNER CT</b>   | Rayons X multiples                  | Oui           | Moyenne                  | Acquisition rapide                    | Exposition aux rayonnements |
| <b>PET</b>          | Traceur radioactif                  | Oui           | Fonctionnelle            | Informations métaboliques             | Coût élevé                  |
| <b>IRM</b>          | Champ magnétique et radiofréquences | Non           | Excellente               | Très haute résolution des tissus mous | Acquisition plus longue     |




Figure 1.4 : Exemples des différentes techniques [47]

Parmi les différentes techniques d'imagerie présentées, l'IRM se distingue par sa capacité à fournir des images détaillées des tissus cérébraux sans exposition aux rayonnements ionisants. Pour cette raison, elle est largement utilisée dans les études portant sur la maladie d'Alzheimer.

## 1.5 Imagerie IRM

### 1.5.1 Principe

L'imagerie par résonance magnétique (IRM) est une technique d'imagerie médicale non invasive permettant d'obtenir des images détaillées des organes et des tissus du corps humain. Son fonctionnement repose sur les propriétés magnétiques des atomes d'hydrogène abondamment présents dans l'eau constituant les tissus biologiques [11],[15].

#### ✚ Champ magnétique

Lors de l'examen, le patient est placé à l'intérieur d'un puissant aimant générant un champ magnétique uniforme. Sous l'effet de ce champ, les noyaux d'hydrogène présents dans l'organisme s'alignent selon une direction privilégiée [45].

#### ✚ Résonance des protons

Une impulsion d'ondes radio est ensuite appliquée afin de perturber cet alignement. Les protons absorbent alors de l'énergie puis reviennent progressivement à leur état initial après l'arrêt de l'impulsion. Durant ce processus, ils émettent des signaux électromagnétiques qui sont captés par des antennes spécifiques [45].

#### ✚ Reconstruction des images

Les signaux recueillis sont traités par ordinateur grâce à des algorithmes mathématiques permettant de reconstruire des images détaillées des tissus observés. Les différences de réponse des tissus biologiques permettent d'obtenir un contraste élevé entre les différentes structures anatomiques du cerveau [45].



Figure 1.5 : Fonctionnement d'une IRM.

### 1.5.2 Types d'IRM

L'imagerie par résonance magnétique regroupe plusieurs modalités permettant d'étudier différentes caractéristiques du cerveau. Dans le domaine des maladies neurodégénératives, notamment la maladie d'Alzheimer, les principales modalités utilisées sont l'IRM structurelle, l'IRM fonctionnelle et l'IRM de diffusion.

#### ✚ IRM structurelle

L'IRM structurelle permet d'obtenir des images détaillées de l'anatomie cérébrale. Elle est principalement utilisée pour observer les structures du cerveau et détecter les modifications morphologiques associées aux maladies neurodégénératives [11], [15].

#### ✚ IRM fonctionnelle (fMRI)

L'IRM fonctionnelle (fMRI) permet d'étudier l'activité cérébrale en mesurant les variations du flux sanguin et de l'oxygénation dans les différentes régions du cerveau. Elle est utilisée pour analyser des fonctions cognitives telles que la mémoire, l'attention et le langage [48].

#### ✚ IRM de diffusion

L'IRM de diffusion étudie le déplacement des molécules d'eau à l'intérieur des tissus cérébraux. Elle permet d'analyser l'intégrité des fibres nerveuses et des connexions entre différentes

régions du cerveau. Cette modalité est particulièrement utile pour détecter des anomalies de la substance blanche associées aux processus neurodégénératifs.




Figure 1.6 : Exemples des types d'IRM [49]

### 1.5.3 IRM et Alzheimer

L'IRM joue un rôle essentiel dans le diagnostic et le suivi de la maladie d'Alzheimer en permettant de visualiser les modifications anatomiques du cerveau. Les chercheurs et les médecins s'intéressent particulièrement à certaines régions cérébrales dont les altérations sont fortement associées à la progression de la maladie.

L'analyse des images IRM dans le contexte de la maladie d'Alzheimer se concentre principalement sur certaines régions cérébrales particulièrement sensibles aux processus neurodégénératifs.

Parmi les structures les plus étudiées figurent :

#### ✚ Hippocampe

L'hippocampe est l'une des premières structures touchées par la maladie d'Alzheimer. Cette région est impliquée dans les mécanismes de mémorisation et d'apprentissage. Chez les patients atteints, une diminution progressive du volume de l'hippocampe est fréquemment observée sur les images IRM. Cette atrophie constitue l'un des principaux biomarqueurs utilisés pour la détection précoce de la maladie [3,5,20].

#### ✚ Cortex cérébral

Le cortex cérébral est responsable de nombreuses fonctions cognitives telles que le raisonnement, le langage, l'attention et la prise de décision. Avec l'évolution de la maladie, une réduction de l'épaisseur corticale et une perte de tissu cérébral peuvent être observées. Ces

modifications contribuent à l'apparition progressive des troubles cognitifs caractéristiques de la maladie d'Alzheimer [3,11,15].

#### Ventricules cérébraux

Les ventricules sont des cavités remplies de liquide céphalo-rachidien situées à l'intérieur du cerveau. À mesure que les neurones dégénèrent et que le volume cérébral diminue, les ventricules ont tendance à s'élargir. Cette augmentation de leur taille constitue un indicateur supplémentaire de l'atrophie cérébrale associée à la maladie d'Alzheimer [3,5,15].




Figure 1.7 : Zones cérébrales touchées [50]

Les informations fournies par l'IRM constituent une source de données particulièrement riche pour les méthodes d'intelligence artificielle. L'exploitation automatique de ces images permet aujourd'hui d'améliorer la détection précoce des maladies neurodégénératives.

## 1.6 Intelligence Artificielle

L'intelligence artificielle (IA) est une branche de l'informatique qui vise à développer des systèmes capables de reproduire certaines capacités humaines telles que l'apprentissage, le raisonnement, la prise de décision et la résolution de problèmes. Grâce aux progrès réalisés dans le traitement des données et la puissance de calcul, l'IA est devenue un domaine majeur de recherche et d'innovation dans de nombreux secteurs.

Dans le domaine médical, l'intelligence artificielle est aujourd'hui utilisée pour assister les professionnels de santé dans le diagnostic, la prédiction et le suivi des maladies. Elle permet d'analyser automatiquement les images médicales, de détecter certaines anomalies et d'améliorer la précision des diagnostics [15]. L'IA contribue également à la prise de décision clinique en fournissant un accès rapide aux informations médicales, aux résultats de recherche et aux recommandations thérapeutiques. Elle peut ainsi aider les médecins dans le choix des traitements, des médicaments et dans la prise en charge de différents besoins médicaux des patients [52].




Figure 1.8 : Relation entre l'intelligence artificielle, le Machine Learning et le Deep Learning [53]

Parmi les différentes branches de l'intelligence artificielle, le Machine Learning occupe une place centrale dans l'analyse des données médicales. Ses principes fondamentaux sont présentés dans la section suivante

## 1.7 Machine Learning

Le Machine Learning, ou apprentissage automatique, est un sous-domaine de l'intelligence artificielle qui permet aux systèmes informatiques d'apprendre à partir des données et d'améliorer leurs performances sans être explicitement programmés pour chaque tâche. Son objectif principal est d'identifier des relations, des tendances et des modèles cachés dans les données afin de réaliser des prédictions ou de prendre des décisions sur de nouvelles informations.

Les méthodes de machine learning peuvent être classées dans trois paradigmes d'apprentissage distincts : apprentissage supervisé, apprentissage non supervisé et apprentissage par renforcement, selon leurs objectifs d'entraînement et le type de données d'entraînement qu'elles impliquent [54].

### 🌐 Apprentissage supervisé

L'apprentissage supervisé est une approche du Machine Learning dans laquelle le modèle est entraîné à partir de données étiquetées afin d'apprendre la relation entre les données d'entrée et les résultats attendus [55]. Une fois entraîné, il est capable de réaliser des prédictions sur de nouvelles données. Les principales tâches de l'apprentissage supervisé sont la classification, qui consiste à attribuer une observation à une classe prédéfinie (par exemple classer une image IRM en CN, MCI ou AD), et la régression, qui vise à prédire une valeur numérique continue, telle que l'âge d'un patient ou l'évolution d'un biomarqueur médical.

### 🌐 Apprentissage non supervisé :



L'apprentissage non supervisé est une approche du Machine Learning qui exploite des données non étiquetées. Contrairement à l'apprentissage supervisé, le modèle ne dispose pas de classes ou de résultats prédéfinis ; il cherche à identifier automatiquement des structures, des similarités ou des relations cachées au sein des données [56]. Les principales techniques utilisées sont le clustering, qui regroupe les observations présentant des caractéristiques similaires, et la réduction de dimensionnalité, qui permet de diminuer le nombre de variables tout en conservant les informations les plus pertinentes. Cette approche est principalement utilisée pour l'exploration et l'analyse de grands ensembles de données.

#### Apprentissage par renforcement

L'apprentissage par renforcement est un paradigme dans lequel un agent apprend à effectuer des actions au sein d'un environnement en recevant des récompenses ou des pénalités selon les résultats obtenus. Cette approche est principalement utilisée dans les domaines de la robotique, des jeux vidéo et des systèmes autonomes. Bien qu'elle constitue un domaine important du Machine Learning, elle est peu utilisée dans le cadre de la classification des images médicales.




Figure 1.9 : Types d'apprentissage [58]

Bien que les méthodes de Machine Learning aient montré des résultats prometteurs, les progrès récents sont principalement liés à l'émergence du Deep Learning, capable d'apprendre automatiquement des représentations complexes à partir des données.

## 1.8 Deep Learning

Le Deep Learning, ou apprentissage profond, est une branche avancée du Machine Learning basée sur l'utilisation de réseaux de neurones artificiels comportant plusieurs couches de traitement. Contrairement aux méthodes classiques de Machine Learning, qui nécessitent généralement une extraction manuelle des caractéristiques, le Deep Learning est capable



d'apprendre automatiquement les représentations les plus pertinentes directement à partir des données brutes. Grâce à cette capacité d'apprentissage hiérarchique, les modèles peuvent identifier des caractéristiques simples dans les premières couches, puis construire progressivement des représentations de plus en plus complexes dans les couches profondes du réseau.

Le fonctionnement du Deep Learning repose sur des réseaux de neurones composés de plusieurs couches interconnectées : une couche d'entrée recevant les données, plusieurs couches cachées assurant l'extraction et la transformation des caractéristiques, ainsi qu'une couche de sortie produisant le résultat final. Au cours de la phase d'entraînement, les paramètres du réseau sont ajustés automatiquement grâce à des algorithmes d'optimisation tels que la rétropropagation (*Backpropagation*) et la descente de gradient (*Gradient Descent*), afin de minimiser l'erreur entre les prédictions du modèle et les résultats attendus [15].

Cette approche est particulièrement adaptée au traitement des images médicales, car elle permet d'analyser directement les informations contenues dans les images sans nécessiter de conception manuelle de descripteurs. Les réseaux de Deep Learning sont capables de détecter des motifs complexes, parfois imperceptibles à l'œil humain, ce qui améliore considérablement la précision des systèmes de diagnostic assisté par ordinateur. Dans le domaine de la maladie d'Alzheimer, ils sont largement utilisés pour analyser les images IRM, segmenter les structures cérébrales, identifier les biomarqueurs associés à la maladie et classer automatiquement les patients selon les différents stades de son évolution [15].

Par rapport aux méthodes traditionnelles de Machine Learning, le Deep Learning présente plusieurs avantages. Il automatise l'extraction des caractéristiques, améliore les performances sur les tâches complexes et s'adapte efficacement à de grands volumes de données. Ces propriétés expliquent son adoption dans de nombreux domaines tels que la vision par ordinateur, le traitement du langage naturel, la reconnaissance vocale et l'imagerie médicale. Toutefois, ces modèles nécessitent généralement des bases de données importantes, des ressources de calcul élevées ainsi qu'un temps d'entraînement plus conséquent que les approches classiques [14], [15].

Dans le cadre de ce projet, le Deep Learning constitue l'approche principale retenue pour la détection de la maladie d'Alzheimer à partir des images IRM. Les modèles développés reposent sur les réseaux de neurones convolutifs (*Convolutional Neural Networks* – CNN), complétés par des architectures de Transfer Learning telles que MobileNetV2 et EfficientNetB0, qui permettent de bénéficier de connaissances acquises sur de grandes bases d'images afin d'améliorer les performances de classification. Par ailleurs, des techniques d'intelligence artificielle explicable, notamment Grad-CAM, sont utilisées afin de visualiser les régions des images ayant influencé les décisions des modèles et de renforcer leur interprétabilité.

Les principales architectures de Deep Learning utilisées dans le traitement des images médicales sont présentées dans les sections suivantes, en commençant par les réseaux de neurones convolutifs (CNN), qui constituent la base de nombreux systèmes modernes de diagnostic assisté par ordinateur.

## 1.9 Réseaux de Neurones Convolutifs (CNN)

Les réseaux de neurones convolutifs (*Convolutional Neural Networks* – CNN) sont une catégorie de réseaux de neurones profonds spécialement conçus pour le traitement et l'analyse des images. Inspirés du fonctionnement du cortex visuel humain, ils sont capables d'extraire automatiquement des caractéristiques pertinentes à partir des images sans nécessiter une extraction manuelle des descripteurs. Grâce à cette capacité, les CNN sont devenus les modèles de référence pour des applications telles que la classification d'images, la détection d'objets, la segmentation d'images médicales et le diagnostic assisté par ordinateur [6], [59].

Le fonctionnement d'un CNN repose sur une succession de couches spécialisées qui transforment progressivement l'image d'entrée en une représentation de plus en plus abstraite. Les premières couches détectent des caractéristiques simples, telles que les contours ou les textures, tandis que les couches profondes identifient des structures plus complexes permettant de reconnaître les objets présents dans l'image. Cette hiérarchie de caractéristiques constitue l'un des principaux avantages des réseaux convolutifs.

### 🚦 Couche de convolution (Conv2D)

La couche de convolution constitue l'élément fondamental d'un CNN. Elle applique plusieurs filtres (*kernels*) sur l'image d'entrée afin d'extraire automatiquement des caractéristiques locales telles que les contours, les lignes, les textures ou les formes. Chaque filtre produit une nouvelle représentation de l'image appelée carte de caractéristiques (*Feature Map*). Les paramètres de ces filtres sont appris automatiquement au cours de l'entraînement, ce qui permet au réseau d'identifier les caractéristiques les plus pertinentes pour la tâche de classification [59].

### 🚦 Cartes de caractéristiques (Feature Maps)

Les Feature Maps sont les images intermédiaires produites après chaque opération de convolution. Elles représentent les différentes caractéristiques détectées par les filtres appliqués sur l'image d'entrée. Dans les premières couches du réseau, ces cartes mettent principalement en évidence des éléments simples, tels que les contours et les textures. À mesure que les données traversent les couches profondes, les Feature Maps deviennent plus abstraites et permettent d'identifier des structures plus complexes, contribuant ainsi à une meilleure représentation de l'image avant la phase de classification.

### 🚦 Fonction d'activation ReLU

Après chaque opération de convolution, une fonction d'activation est appliquée afin d'introduire de la non-linéarité dans le réseau. La fonction ReLU (*Rectified Linear Unit*) est la plus utilisée en Deep Learning. Elle remplace les valeurs négatives par zéro tout en conservant les valeurs positives, ce qui facilite l'apprentissage des caractéristiques complexes, accélère la convergence du modèle et réduit le problème de disparition du gradient (*Vanishing Gradient*) [59].

### 🚦 Couche de Pooling

La couche de Pooling intervient après la convolution et la fonction d'activation afin de réduire les dimensions spatiales des Feature Maps. Cette opération permet de diminuer le nombre de paramètres, de réduire le coût de calcul et de limiter le risque de surapprentissage (*Overfitting*). Les deux méthodes les plus courantes sont le Max Pooling, qui conserve la valeur maximale de chaque région analysée, et l'Average Pooling, qui calcule la valeur moyenne des pixels de cette région [62].

### 🚦 Batch Normalization

La Batch Normalization est une technique utilisée pour normaliser les activations entre les différentes couches du réseau. En réduisant les variations internes des données au cours de l'entraînement, elle améliore la stabilité de l'apprentissage, accélère la convergence et favorise une meilleure généralisation du modèle. Cette technique contribue également à limiter le surapprentissage et permet souvent d'obtenir de meilleures performances [61].

### 🚦 Couche Dense (Fully Connected Layer)

Après les différentes étapes d'extraction des caractéristiques, les informations obtenues sont transmises à une ou plusieurs couches entièrement connectées (*Fully Connected Layers*). Dans ces couches, chaque neurone est connecté à l'ensemble des neurones de la couche précédente, ce qui permet de combiner toutes les caractéristiques extraites afin de réaliser la décision finale. La dernière couche du réseau utilise généralement une fonction d'activation Softmax pour attribuer à chaque classe une probabilité, la classe présentant la probabilité la plus élevée étant retenue comme résultat final de la classification [60].

En combinant ces différentes couches, les réseaux de neurones convolutifs sont capables d'apprendre automatiquement des représentations hiérarchiques des images, ce qui explique leurs excellentes performances dans les tâches de classification d'images médicales. Dans le cadre de ce projet, les CNN constituent la base des modèles développés pour la détection des différents stades de la maladie d'Alzheimer à partir des images IRM.




Figure 1.10 : Principe de la convolution




Figure 1.11 : Opération de Max Pooling :




Figure 1.12 : Architecture générale d'un CNN [62]

## 1.10 Transfer Learning

Le Transfer Learning, ou apprentissage par transfert, est une technique de Deep Learning qui consiste à réutiliser un modèle préalablement entraîné sur une grande base de données afin de résoudre une nouvelle tâche. Au lieu d'entraîner un réseau de neurones depuis le début, cette approche exploite les connaissances déjà acquises lors d'un apprentissage précédent. Les premières couches du modèle, qui ont appris à détecter des caractéristiques générales telles que les contours, les textures ou les formes, sont réutilisées, tandis que les dernières couches sont adaptées au nouveau problème à résoudre.

Le Transfer Learning est particulièrement intéressant lorsque la quantité de données disponibles est limitée, comme c'est souvent le cas en imagerie médicale. En réutilisant un

modèle déjà entraîné sur une base de données de grande taille, il devient possible d'obtenir de bonnes performances avec un nombre réduit d'images d'entraînement. Cette approche permet également de limiter le risque de surapprentissage (*Overfitting*), fréquent lorsque les jeux de données sont de petite taille [15].

L'utilisation du Transfer Learning présente plusieurs avantages. Tout d'abord, elle réduit considérablement le temps d'entraînement, puisque le modèle possède déjà des connaissances générales acquises lors de son apprentissage initial. Ensuite, elle améliore les performances de classification lorsque les données disponibles sont insuffisantes pour entraîner un réseau profond à partir de zéro. Enfin, elle permet de réutiliser les caractéristiques apprises sur de grandes bases de données d'images, telles que ImageNet, qui contient plusieurs millions d'images appartenant à un grand nombre de catégories. Les caractéristiques extraites sur cette base restent pertinentes pour de nombreuses applications, y compris l'analyse d'images médicales.

Grâce à ces avantages, le Transfer Learning est aujourd'hui largement utilisé dans les applications de vision par ordinateur et constitue l'une des approches les plus employées pour le développement de systèmes d'aide au diagnostic basés sur les images IRM. Dans ce travail, l'architecture MobileNetV2 a été retenue en raison de sa légèreté, de son faible nombre de paramètres et de ses bonnes performances en classification.

MobileNetV2 est une architecture de réseau de neurones convolutif développée par Google afin de proposer un modèle à la fois léger et performant. Elle a été conçue pour fonctionner efficacement sur des appareils disposant de ressources limitées tout en conservant une bonne précision de classification.

Son architecture repose principalement sur deux innovations : les Depthwise Separable Convolutions, qui réduisent fortement le nombre de paramètres et le coût des calculs, et les Inverted Residual Blocks avec Linear Bottlenecks, qui améliorent la circulation de l'information dans le réseau tout en limitant la perte de caractéristiques importantes. Grâce à cette conception, MobileNetV2 offre un excellent compromis entre rapidité d'exécution, consommation mémoire et précision.

Dans le domaine médical, MobileNetV2 est largement utilisé pour la classification d'images radiologiques, la détection de tumeurs, l'analyse d'IRM cérébrales ainsi que le diagnostic assisté par ordinateur. Sa légèreté en fait également un modèle particulièrement adapté au déploiement sur des dispositifs embarqués ou à ressources limitées [63].




Figure 1.13: Architecture MobileNetV2 [64]

## 1.11 Explainable Artificial Intelligence (XAI)

L'amélioration constante des performances des modèles de Deep Learning s'accompagne souvent d'une diminution de leur interprétabilité. En effet, les réseaux de neurones profonds sont généralement considérés comme des « boîtes noires » (Black Boxes), car ils produisent des prédictions très précises sans fournir d'explication claire sur les raisons ayant conduit à ces décisions. Cette absence de transparence constitue un défi majeur, en particulier dans le domaine médical où chaque décision peut avoir des conséquences importantes sur la prise en charge des patients.

Afin de répondre à cette problématique, le domaine de l'Explainable Artificial Intelligence (XAI), ou intelligence artificielle explicable, s'est développé ces dernières années. Il regroupe un ensemble de méthodes permettant d'expliquer le fonctionnement des modèles d'intelligence artificielle et de rendre leurs décisions plus compréhensibles pour les utilisateurs. Contrairement aux approches classiques qui se limitent à fournir un résultat, les techniques de XAI cherchent à identifier les caractéristiques ou les régions des données ayant le plus influencé la prédiction du modèle [67].

L'objectif principal de l'Explainable AI est d'améliorer la transparence, la fiabilité et la confiance dans les systèmes d'intelligence artificielle. Dans le domaine médical, cette interprétabilité est particulièrement importante, car les professionnels de santé doivent pouvoir comprendre et justifier les recommandations produites par un modèle avant de les intégrer dans leur processus décisionnel. Les méthodes de XAI constituent ainsi un outil d'aide au diagnostic plutôt qu'un remplacement de l'expertise médicale.

Parmi les nombreuses techniques développées dans ce domaine, certaines sont spécifiquement conçues pour interpréter les modèles de Deep Learning, notamment les réseaux de neurones convolutifs. Les approches les plus utilisées sont Grad-CAM, SHAP et LIME, chacune reposant sur un principe d'explication différent.

### 🌈 Grad-CAM (Gradient-weighted Class Activation Mapping)

Grad-CAM (*Gradient-weighted Class Activation Mapping*) est l'une des méthodes d'interprétation les plus utilisées pour les réseaux de neurones convolutifs. Son principe consiste à exploiter les gradients calculés lors de la prédiction afin de déterminer quelles régions de l'image ont le plus contribué à la décision finale du modèle [68].

Le fonctionnement de Grad-CAM repose sur plusieurs étapes. Dans un premier temps, l'image est propagée dans le réseau convolutif jusqu'à l'obtention de la prédiction. Ensuite, les gradients de la classe prédite sont calculés par rapport aux cartes de caractéristiques (*Feature Maps*) de la dernière couche de convolution. Ces gradients permettent d'évaluer l'importance de chaque carte de caractéristiques. Les différentes cartes sont ensuite pondérées selon cette importance et combinées afin de produire une carte thermique (Heatmap) mettant en évidence les régions de l'image ayant le plus influencé la décision du modèle. Cette carte est finalement superposée à l'image d'origine afin de faciliter son interprétation. Dans le cadre de la maladie d'Alzheimer, Grad-CAM permet de visualiser les régions cérébrales sur lesquelles le modèle s'est principalement appuyé pour effectuer sa classification. Les zones fortement colorées correspondent aux régions considérées comme les plus importantes dans la prise de décision, ce qui permet au spécialiste de vérifier que le modèle s'intéresse bien aux structures cérébrales pertinentes.

L'utilisation de Grad-CAM présente plusieurs avantages. Elle améliore la transparence des modèles de Deep Learning, facilite leur validation par les experts médicaux, permet de détecter d'éventuelles erreurs d'apprentissage et renforce la confiance dans les systèmes d'aide au diagnostic. Pour ces raisons, Grad-CAM est aujourd'hui largement utilisé dans l'interprétation des modèles de classification d'images médicales.

### 🌈 SHAP (SHapley Additive exPlanations)

SHAP est une méthode d'explication basée sur la théorie des jeux. Elle mesure la contribution de chaque caractéristique à la prédiction réalisée par le modèle en attribuant une valeur d'importance à chacune d'elles. Cette approche permet d'obtenir une interprétation quantitative des décisions du modèle et d'identifier les variables ayant le plus influencé le résultat final.

### 🌈 LIME (Local Interpretable Model-agnostic Explanations)

LIME est une méthode d'interprétation locale capable d'expliquer individuellement chaque prédiction. Son principe consiste à construire un modèle simplifié autour d'une observation spécifique afin d'identifier les caractéristiques responsables de la décision du modèle. Contrairement à Grad-CAM, LIME peut être utilisé avec différents types de modèles d'intelligence artificielle et ne dépend pas de leur architecture interne.




Figure 1.14 : Exemple de Grad-CAM [69]

Tableau 5. Comparaison des méthodes XAI

| MÉTHODE         | PRINCIPE                                             | AVANTAGES                                      | LIMITES                       |
|-----------------|------------------------------------------------------|------------------------------------------------|-------------------------------|
| <b>GRAD-CAM</b> | Visualisation des régions importantes dans une image | Facile à interpréter pour les images médicales | Limité principalement aux CNN |
| <b>SHAP</b>     | Calcul de la contribution de chaque caractéristique  | Explications précises et quantitatives         | Coût de calcul élevé          |
| <b>LIME</b>     | Approximation locale du comportement du modèle       | Compatible avec différents modèles             | Résultats parfois instables   |

## 1.12 Revue bibliographique

Au cours des dernières années, les techniques de Deep Learning ont considérablement amélioré les performances de la détection précoce de la maladie d'Alzheimer à partir des images IRM. Les travaux récents s'articulent principalement autour de deux axes : la segmentation des structures cérébrales afin d'extraire les régions d'intérêt et la classification automatique permettant d'identifier les différents stades de la maladie. Cette revue bibliographique présente les principaux travaux publiés dans ce domaine.

✚ Travaux de classification



Après la segmentation, la classification représente l'étape permettant d'identifier automatiquement le stade de la maladie d'Alzheimer à partir des caractéristiques extraites des images IRM. Les recherches récentes utilisent principalement des architectures de Deep Learning afin d'améliorer la précision du diagnostic. Le Tableau 1.8 présente une comparaison des principaux travaux de classification.

Tableau 6. *Travaux de classification*

| RÉFÉRENCE                                | DATASET           | MÉTHODE               | ACCURACY                     | LIMITES                              |
|------------------------------------------|-------------------|-----------------------|------------------------------|--------------------------------------|
| <b>PAYAN ET MONTANA (2015) [13]</b>      | ADNI              | CNN 3D + Autoencodeur | Accuracy = 89.47%            | Architecture complexe                |
| <b>HOSSEINI-ASL ET AL. (2016) [5]</b>    | ADNI, CADDementia | Deeply Supervised CNN | Accuracy $\approx$ 75%       | Nécessite un grand volume de données |
| <b>SARRAF ET AL. (2017) [11]</b>         | ADNI              | DeepAD (CNN)          | Accuracy = 99.9%             | Risque de surapprentissage           |
| <b>KHAGI ET KWON (2020) [3]</b>          | ADNI              | CNN 3D                | Accuracy = 94.5%             | Validation sur un seul dataset       |
| <b>ALARJANI ET ALMUAIBED (2025) [4]</b>  | ADNI              | CNN 3D optimisé       | Accuracy = 95.39%            | Ressources de calcul élevées         |
| <b>DE FRANCESCO ET AL. (2023) [19]</b>   | ADNI + 4 bases    | SVM + SHAP            | AUC = 98 %, précision = 88 % | Dépend de FreeSurfer                 |
| <b>FATHI ET AL. (2023) [24]</b>          | ADNI              | Ensemble de 6 CNN     | Accuracy = 99.83%            | Modèle très lourd                    |
| <b>VINUKONDA ET JAGADESH (2025) [25]</b> | IRM Alzheimer     | Pipeline hybride      | Accuracy = 98.12%            | Temps d'exécution élevé              |

Les travaux de classification montrent une évolution progressive des approches basées sur le Machine Learning vers des architectures de Deep Learning capables d'extraire automatiquement les caractéristiques discriminantes des images IRM. Les premiers CNN 3D proposés par Payan et Montana ainsi que Hosseini-Asl et al. ont démontré la supériorité de l'apprentissage profond par rapport aux méthodes reposant sur l'extraction manuelle de caractéristiques.

Les performances ont ensuite été améliorées grâce à des architectures plus profondes et à des approches hybrides. Les modèles récents atteignent des précisions supérieures à 95 %, certaines

études rapportant même des performances proches de 100 %. Cependant, ces résultats sont souvent obtenus au prix d'une augmentation importante du nombre de paramètres et du temps d'entraînement.

Par ailleurs, la majorité des travaux sont évalués principalement sur la base ADNI, ce qui limite parfois la généralisation des modèles à d'autres populations. Une autre faiblesse fréquemment observée concerne le manque d'interprétabilité des systèmes proposés. Les approches intégrant SHAP ou d'autres techniques XAI restent encore minoritaires malgré leur importance dans le domaine médical.

Les tendances récentes s'orientent ainsi vers le développement de modèles plus légers, capables d'être déployés sur des environnements à ressources limitées tout en conservant un niveau élevé de performance. Cette orientation justifie le choix d'un modèle de Transfer Learning tel que MobileNetV2, associé à Grad-CAM pour l'explication visuelle des décisions.

### 1.12.1 Synthèse de la revue bibliographique

L'étude des travaux récents montre que le Deep Learning constitue aujourd'hui l'approche dominante pour l'analyse des images IRM dans le cadre du diagnostic de la maladie d'Alzheimer. Les architectures U-Net et ses variantes sont principalement utilisées pour la segmentation, tandis que les CNN et les modèles de Transfer Learning sont largement exploités pour la classification. Malgré les performances élevées obtenues, plusieurs défis subsistent, notamment la complexité computationnelle, la dépendance à des bases de données limitées et le manque d'interprétabilité de certains modèles.

### 1.13 Synthèse critique

L'analyse des travaux présentés dans la littérature met en évidence les progrès considérables réalisés dans le domaine du diagnostic assisté par ordinateur de la maladie d'Alzheimer à partir des images IRM. Les approches fondées sur le Deep Learning, notamment les réseaux de neurones convolutifs (CNN), les architectures de Transfer Learning et les modèles de segmentation, ont démontré leur capacité à extraire automatiquement des caractéristiques pertinentes et à obtenir des performances élevées pour la classification des différents stades de la maladie.

Les études récentes montrent également que l'utilisation de modèles pré-entraînés permet d'améliorer la précision tout en réduisant le temps d'entraînement, ce qui constitue un avantage important lorsque les bases de données médicales sont de taille limitée. Par ailleurs, les méthodes d'intelligence artificielle explicable, telles que Grad-CAM, apportent une meilleure compréhension des décisions prises par les modèles et renforcent la confiance des professionnels de santé dans les systèmes d'aide au diagnostic.

Malgré ces résultats prometteurs, plusieurs limites demeurent. Tout d'abord, de nombreuses architectures présentent une complexité computationnelle élevée, nécessitant des ressources matérielles importantes pour l'entraînement et l'inférence. Cette contrainte limite leur déploiement dans des environnements réels ou sur des dispositifs à ressources limitées. De plus,

une grande partie des travaux est évaluée principalement sur le jeu de données ADNI, ce qui peut limiter la capacité de généralisation des modèles à d'autres populations ou à des images acquises dans différents centres hospitaliers.

Par ailleurs, bien que les performances obtenues soient souvent très élevées, plusieurs études utilisent une seule architecture de Deep Learning, ce qui rend difficile l'évaluation comparative des différentes approches. Enfin, de nombreux modèles restent peu interprétables et fonctionnent comme des « boîtes noires », sans fournir d'explication claire sur les régions de l'image ayant conduit à la décision finale. Cette absence d'explicabilité constitue un frein important à leur adoption dans le domaine médical, où les décisions doivent être justifiées et validées par les spécialistes.

Afin de répondre à ces limitations, ce projet propose une étude comparative basée sur deux approches de Deep Learning : un CNN développé spécifiquement pour la classification des images IRM et une architecture de Transfer Learning, MobileNetV2. Cette comparaison permettra d'évaluer leurs performances respectives en termes de précision, de coût computationnel et de capacité de généralisation.

En complément, la méthode Grad-CAM est intégrée afin d'améliorer l'interprétabilité des prédictions en mettant en évidence les régions des images IRM ayant le plus influencé les décisions des modèles. Cette approche permet de vérifier que les modèles s'appuient sur des structures cérébrales pertinentes, tout en renforçant la confiance des utilisateurs dans les résultats obtenus.

Ainsi, le projet proposé vise à combiner de bonnes performances de classification, une complexité computationnelle maîtrisée et une meilleure interprétabilité des décisions. Cette démarche s'inscrit dans la continuité des travaux existants tout en apportant une contribution basée sur la comparaison de deux architectures de Deep Learning et sur l'intégration d'une méthode d'intelligence artificielle explicable, constituant ainsi une transition logique vers le chapitre suivant consacré à la méthodologie adoptée.

Au regard des différentes approches présentées dans ce chapitre, ce projet repose sur deux modèles de Deep Learning destinés à la classification des images IRM cérébrales : un réseau de neurones convolutif (CNN) développé spécifiquement pour cette application et une architecture de Transfer Learning, MobileNetV2. Une comparaison sera réalisée afin d'évaluer leurs performances en termes de précision, de robustesse et de coût computationnel. Par ailleurs, la méthode Grad-CAM sera utilisée afin d'interpréter les décisions du modèle en mettant en évidence les régions cérébrales ayant le plus influencé les prédictions.

## 1.14 Conclusion

Au cours de ce chapitre, les principaux concepts théoriques nécessaires à la compréhension de ce travail ont été présentés. Dans un premier temps, la maladie d'Alzheimer a été étudiée à travers sa définition, ses causes, ses symptômes ainsi que ses différents stades d'évolution. Le rôle de l'Imagerie par Résonance Magnétique (IRM) dans le diagnostic de cette maladie a

ensuite été mis en évidence, en soulignant son importance dans l'observation des modifications anatomiques du cerveau.

Le chapitre a également permis de présenter les fondements de l'intelligence artificielle, du Machine Learning et, plus particulièrement, du Deep Learning, qui constitue aujourd'hui l'une des approches les plus performantes pour l'analyse des images médicales. Les réseaux de neurones convolutifs (CNN), les techniques de Transfer Learning basées sur MobileNetV2, ainsi que les méthodes d'intelligence artificielle explicable, notamment Grad-CAM, ont été étudiés afin de mettre en évidence leur intérêt pour la classification des images IRM et l'amélioration de l'interprétabilité des modèles.

L'analyse de la littérature scientifique montre que les approches actuelles offrent des performances prometteuses pour la détection de la maladie d'Alzheimer. Toutefois, des défis persistent, notamment la complexité de certains modèles, leur dépendance à des jeux de données spécifiques et leur manque d'explicabilité. Ces constats justifient l'approche adoptée dans ce projet, fondée sur une comparaison entre un modèle CNN et une architecture de Transfer Learning basée sur MobileNetV2, complétée par la méthode Grad-CAM pour interpréter les prédictions.

L'ensemble des notions présentées dans ce chapitre constitue ainsi le fondement théorique du travail réalisé. Le chapitre suivant sera consacré à la méthodologie adoptée, en présentant le jeu de données utilisé, les étapes de préparation des images, la conception des différents modèles de Deep Learning, les paramètres d'entraînement ainsi que les méthodes d'évaluation mises en œuvre pour comparer leurs performances

## CHAPITRE 2 : MÉTHODOLOGIE PROPOSÉE

## CHAPITRE 2 : MÉTHODOLOGIE PROPOSÉE

### 2.1 Introduction

Après avoir présenté dans le chapitre précédent les concepts fondamentaux liés à la maladie d'Alzheimer, à l'imagerie par résonance magnétique (IRM) ainsi qu'aux techniques d'intelligence artificielle appliquées à l'analyse des images médicales, ce chapitre est consacré à la méthodologie adoptée pour la réalisation de ce projet.

L'objectif principal de ce travail est de développer un système intelligent capable d'assister au diagnostic de la maladie d'Alzheimer à partir d'images IRM cérébrales. Les données exploitées proviennent de la base ADNI (Alzheimer's Disease Neuroimaging Initiative), qui constitue aujourd'hui l'une des principales références internationales pour la recherche sur les maladies neurodégénératives. Afin d'obtenir des modèles fiables et performants, plusieurs étapes sont mises en œuvre, depuis la préparation des données jusqu'à l'évaluation des performances des modèles développés.

La méthodologie proposée débute par l'organisation et le prétraitement des images IRM afin d'améliorer leur qualité et de les rendre compatibles avec les modèles de Deep Learning [15]. Ces opérations comprennent notamment le redimensionnement, la normalisation et la préparation des données, permettant de faciliter l'extraction des caractéristiques pertinentes nécessaires à la classification.

Par la suite, un réseau de neurones convolutif (CNN) est développé comme modèle de référence. Une approche de Transfer Learning basée sur MobileNetV2 est ensuite mise en œuvre afin de tirer parti des connaissances acquises sur de grandes bases d'images et d'améliorer les performances de classification tout en réduisant le temps d'entraînement. Enfin, la méthode d'Explainable Artificial Intelligence (XAI) Grad-CAM est utilisée afin d'interpréter les décisions du modèle en mettant en évidence les régions des images IRM ayant le plus contribué aux prédictions [23].

L'objectif final est de classifier automatiquement les images IRM en trois catégories : Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN). Les différentes étapes de la méthodologie, notamment l'environnement de développement, la description du jeu de données, les techniques de prétraitement, les modèles proposés ainsi que les méthodes d'évaluation utilisées pour mesurer leurs performances, sont détaillées dans les sections suivantes.

### 2.2 Environnement de travail

La réalisation de ce projet a nécessité l'utilisation d'un ensemble d'outils matériels et logiciels dédiés au traitement des données médicales et au développement de modèles d'intelligence artificielle. Ces outils ont permis d'assurer les différentes étapes du projet, depuis la préparation des images IRM jusqu'à l'entraînement et l'évaluation des modèles de Deep Learning. Le choix de ces technologies repose sur leur efficacité, leur popularité dans la communauté scientifique ainsi que leur compatibilité avec les exigences du traitement d'images médicales.

L'ensemble du développement a été réalisé dans un environnement Python en s'appuyant sur plusieurs bibliothèques spécialisées dans le calcul scientifique, le traitement d'images et l'apprentissage profond. Les expérimentations ont été exécutées sur Google Colab, tandis que GitHub a été utilisé pour la gestion et le suivi du code source du projet.

### 2.2.1 Environnement matériel

Le développement et l'entraînement des modèles de Deep Learning ont nécessité l'utilisation d'un environnement matériel capable de traiter efficacement un grand volume d'images IRM et d'exécuter des calculs intensifs. Afin de réduire le temps d'entraînement des réseaux de neurones convolutifs et de bénéficier d'une puissance de calcul adaptée, l'ensemble des expérimentations a été réalisé sur la plateforme Google Colaboratory (Google Colab).

Google Colab est une plateforme de calcul en cloud développée par Google, permettant d'exécuter des notebooks Python directement à partir d'un navigateur web, sans installation préalable de logiciels [70]. Cet environnement met à disposition des ressources matérielles performantes, notamment des processeurs graphiques (GPU) et des unités de traitement tensoriel (TPU), particulièrement adaptés aux applications d'apprentissage profond. Les principales caractéristiques de l'environnement matériel utilisé dans ce travail sont présentées dans le Tableau 7.

Dans le cadre de cette étude, un GPU NVIDIA T4 a été utilisé pour accélérer les différentes phases de prétraitement des données, d'entraînement et d'évaluation des modèles développés. L'exploitation de cette ressource matérielle a permis de réduire considérablement le temps d'apprentissage des modèles CNN et MobileNetV2 par rapport à une exécution réalisée uniquement sur processeur (CPU), tout en facilitant le traitement des milliers d'images IRM utilisées dans cette étude.

Par ailleurs, Google Drive a été utilisé comme espace de stockage afin d'héberger la base de données ADNI, les modèles entraînés, les courbes d'apprentissage, les métriques d'évaluation ainsi que l'ensemble des résultats expérimentaux. Son intégration native avec Google Colab facilite le partage, la sauvegarde et la réutilisation des fichiers tout au long du processus de développement, garantissant ainsi une meilleure organisation du projet.

L'association de Google Colab, de l'accélération matérielle par GPU et de Google Drive constitue une solution performante et flexible pour le développement de projets basés sur le Deep Learning. Cet environnement offre un bon compromis entre puissance de calcul, facilité d'utilisation et accessibilité, ce qui explique son adoption croissante dans les travaux de recherche en intelligence artificielle et en imagerie médicale.

Tableau 7. *Configuration matérielle*

| COMPOSANT | CARACTÉRISTIQUES                                                                       |
|-----------|----------------------------------------------------------------------------------------|
| CPU       | Processeur Intel Xeon (fourni par Google Colab, selon la disponibilité des ressources) |
| RAM       | Environ 12 à 13 Go                                                                     |

| GPU      | NVIDIA T4 (16 Go de mémoire GPU)                                                                              |
|----------|---------------------------------------------------------------------------------------------------------------|
| STOCKAGE | Google Drive (stockage cloud utilisé pour la base ADNI, les modèles entraînés et les résultats expérimentaux) |

Au-delà des ressources matérielles, le développement de cette étude s'appuie sur plusieurs outils logiciels et bibliothèques spécialisés, dont les principales caractéristiques sont présentées dans la section suivante.

### 2.2.2 Environnement logiciel

Le développement du système intelligent proposé dans cette étude a été réalisé à l'aide d'un ensemble d'outils logiciels et de bibliothèques spécialisées dans le traitement de données, la vision par ordinateur et le Deep Learning. Ces outils ont été sélectionnés en raison de leur robustesse, de leur large adoption au sein de la communauté scientifique et de leur compatibilité avec les différentes étapes de développement, depuis le prétraitement des images jusqu'à l'entraînement et l'évaluation des modèles.

Le langage de programmation Python a été retenu comme environnement principal de développement. Sa syntaxe simple, sa richesse en bibliothèques scientifiques et son importante communauté d'utilisateurs en font aujourd'hui l'un des langages les plus utilisés dans les domaines de l'intelligence artificielle, du Machine Learning et du Deep Learning. Les expérimentations ont été réalisées à l'aide de Google Colab, qui a permis l'exécution des notebooks Python dans un environnement cloud tout en facilitant l'accès aux ressources matérielles nécessaires à l'entraînement des modèles.

Le développement des architectures de Deep Learning a été assuré à l'aide de TensorFlow, tandis que Keras a été utilisé comme interface de haut niveau pour la conception, l'entraînement et l'évaluation des réseaux de neurones convolutifs. Ces deux bibliothèques offrent un ensemble complet de fonctionnalités permettant de construire rapidement des modèles de Deep Learning, d'intégrer des architectures pré-entraînées telles que MobileNetV2 et d'exploiter efficacement les capacités de calcul des GPU.

Les différentes étapes de préparation des données ont également nécessité l'utilisation de plusieurs bibliothèques scientifiques. NumPy a été employée pour les calculs numériques et la manipulation des tableaux multidimensionnels, tandis que Pandas a permis l'organisation, la manipulation et l'analyse des jeux de données. Les opérations de lecture et de prétraitement des images IRM ont été réalisées grâce à OpenCV et Pydicom, cette dernière étant spécifiquement dédiée à la manipulation des fichiers médicaux au format DICOM.

Enfin, les bibliothèques Matplotlib et Seaborn ont été utilisées pour la visualisation des données, des courbes d'apprentissage et des résultats expérimentaux. Les différentes métriques d'évaluation, notamment la matrice de confusion, les rapports de classification ainsi que les indicateurs de performance, ont été calculées à l'aide de la bibliothèque Scikit-learn, largement utilisée dans les applications de Machine Learning et d'analyse de données.



Tableau 8. *Logiciels et bibliothèques utilisés*

| OUTIL               | VERSION             | UTILISATION                                                                                               |
|---------------------|---------------------|-----------------------------------------------------------------------------------------------------------|
| <b>PYTHON</b>       | 3.12.13             | Langage principal utilisé pour le développement de l'ensemble du projet.                                  |
| <b>GOOGLE COLAB</b> | Environnement Cloud | Développement et exécution des notebooks Python avec accès aux ressources de calcul GPU.                  |
| <b>TENSORFLOW</b>   | 2.20.0              | Développement, entraînement et évaluation des modèles de Deep Learning.                                   |
| <b>KERAS</b>        | 3.13.2              | Conception et implémentation des architectures CNN, MobileNetV2 et EfficientNetB0.                        |
| <b>NUMPY</b>        | 2.0.2               | Manipulation des tableaux multidimensionnels et calcul scientifique.                                      |
| <b>PANDAS</b>       | 2.2.2               | Organisation, manipulation et analyse des jeux de données.                                                |
| <b>OPENCV</b>       | 4.13.0              | Prétraitement et traitement des images IRM.                                                               |
| <b>PYDICOM</b>      | 3.0.2               | Lecture et manipulation des images médicales au format DICOM.                                             |
| <b>MATPLOTLIB</b>   | 3.10.0              | Génération des graphiques et visualisation des données et des résultats expérimentaux.                    |
| <b>SEABORN</b>      | 0.13.2              | Visualisation statistique des données et des performances des modèles.                                    |
| <b>SCIKIT-LEARN</b> | 1.6.1               | Calcul des métriques d'évaluation, génération de la matrice de confusion et du rapport de classification. |

## 2.3 Présentation du Dataset

### 2.3.1 Source du Dataset

Les données utilisées dans cette étude proviennent de la base Alzheimer's Disease Neuroimaging Initiative (ADNI), l'une des bases de données de référence dans le domaine de la recherche sur la maladie d'Alzheimer. Lancée en 2004, cette initiative internationale a pour objectif de constituer une collection de données cliniques, biologiques et d'imagerie médicale destinée à améliorer la compréhension des mécanismes de la maladie, à favoriser son diagnostic précoce et à soutenir le développement de nouvelles méthodes d'analyse.

La base ADNI rassemble différents types de données, notamment des images d'Imagerie par Résonance Magnétique (IRM), des images de Tomographie par Émission de Positons (TEP),

des évaluations cliniques, des tests neuropsychologiques ainsi que des informations biologiques et génétiques. Grâce à la qualité de ses données et à la standardisation de ses protocoles d'acquisition, cette base constitue aujourd'hui une référence internationale pour le développement et l'évaluation des méthodes de Deep Learning appliquées au diagnostic des maladies neurodégénératives.

Dans le cadre de ce travail, seules les images IRM cérébrales ont été retenues. Ces images permettent de mettre en évidence les modifications anatomiques provoquées par la maladie d'Alzheimer, telles que l'atrophie de certaines structures cérébrales, la diminution du volume du cerveau ou encore la dilatation des ventricules. Elles représentent ainsi une source d'information essentielle pour la classification automatique des différents stades du déclin cognitif.

Pour les besoins de cette étude, un sous-ensemble équilibré de la base ADNI, intitulé `Dataset_balanced`, a été utilisé. Ce jeu de données regroupe exclusivement des examens IRM appartenant à trois catégories cliniques : les patients atteints de la maladie d'Alzheimer (Alzheimer's Disease – AD), les patients présentant un trouble cognitif léger (Mild Cognitive Impairment – MCI) et les sujets cognitivement normaux (Cognitively Normal – CN). Les images sont conservées au format DICOM (Digital Imaging and Communications in Medicine) et sont organisées selon une structure hiérarchique de dossiers permettant leur chargement automatique. Dans l'implémentation développée, l'ensemble des images disponibles dans ce jeu de données est parcouru et utilisé pour les différentes étapes de prétraitement, d'entraînement et d'évaluation des modèles de Deep Learning, sans appliquer de sélection supplémentaire des coupes IRM. Cette organisation garantit une exploitation cohérente des données tout en facilitant leur intégration dans le pipeline de traitement proposé.

### 2.3.2 Organisation du Dataset

Le jeu de données utilisé dans cette étude est organisé selon une structure hiérarchique de dossiers, permettant une gestion claire des données ainsi qu'un accès simplifié aux images lors des différentes étapes du traitement. Cette organisation facilite le stockage des examens IRM, tout en assurant une séparation rigoureuse des différentes catégories cliniques, condition essentielle pour l'entraînement et l'évaluation des modèles de Deep Learning.

À la racine du jeu de données se trouve le dossier principal `Dataset_balanced`, qui regroupe l'ensemble des examens IRM utilisés dans cette étude. Ce répertoire est subdivisé en trois sous-dossiers correspondant aux classes cliniques considérées : AD (Alzheimer's Disease), MCI (Mild Cognitive Impairment) et CN (Cognitively Normal). Chaque sous-dossier contient exclusivement les examens des patients appartenant à la classe correspondante, garantissant ainsi une séparation claire entre les différentes catégories diagnostiques.

Au sein de chaque classe, les données sont organisées par patient. Chaque dossier porte un identifiant unique conforme à la nomenclature de la base ADNI (par exemple `010_S_10868`) et regroupe l'ensemble des images IRM associées à ce patient. Les images sont enregistrées au format DICOM (.dcm), qui constitue le format standard en imagerie médicale. Ce format permet non seulement de préserver la qualité des images, mais également de conserver les informations techniques et les métadonnées relatives à leur acquisition.

Cette organisation hiérarchique présente plusieurs avantages. Elle facilite l'identification des patients, garantit la traçabilité des examens et préserve la structure originale des données médicales. En outre, elle favorise une gestion efficace des images et simplifie leur exploitation au sein du pipeline de traitement développé dans cette étude. Grâce à cette organisation, les données peuvent être parcourues de manière structurée et intégrées facilement aux différentes étapes du prétraitement, de l'entraînement et de l'évaluation des modèles.

La Figure 2.1 présente l'organisation hiérarchique du jeu de données utilisé dans cette étude.

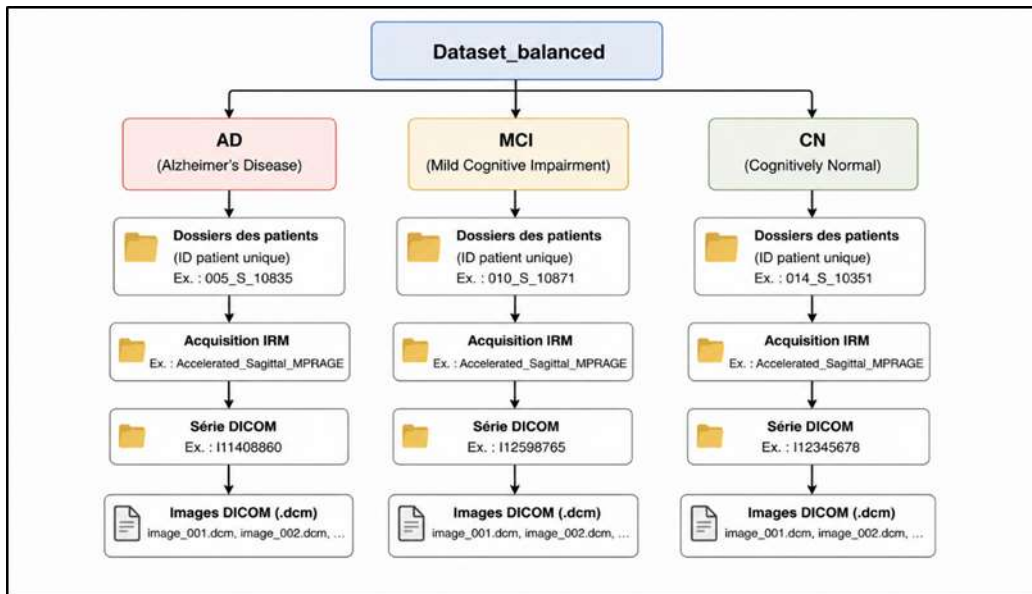


Figure 2.1 : Organisation du Dataset

### 2.3.3 Description des classes

Le jeu de données utilisé dans cette étude est constitué de trois classes représentant les principaux états cognitifs rencontrés dans le cadre du diagnostic de la maladie d'Alzheimer. Cette classification permet d'entraîner les modèles de Deep Learning à distinguer les différentes phases de l'évolution de la maladie à partir des images IRM cérébrales. Les trois catégories retenues sont Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN).

#### 🚩 Alzheimer's Disease (AD)

La classe Alzheimer's Disease (AD) regroupe les images IRM des patients diagnostiqués avec la maladie d'Alzheimer. Il s'agit d'une maladie neurodégénérative progressive caractérisée par une détérioration irréversible des fonctions cognitives, notamment la mémoire, le langage, l'attention et les capacités de raisonnement.

Sur les images IRM, cette pathologie se manifeste généralement par des modifications anatomiques importantes, telles qu'une atrophie de l'hippocampe, une réduction du volume cortical ainsi qu'une dilatation des ventricules cérébraux. Ces changements constituent des

biomarqueurs essentiels permettant aux modèles de Deep Learning d'apprendre les caractéristiques associées aux stades avancés de la maladie.

#### Mild Cognitive Impairment (MCI)

La classe Mild Cognitive Impairment (MCI) correspond aux patients présentant un trouble cognitif léger. Cette affection représente un stade intermédiaire entre le vieillissement cognitif normal et la maladie d'Alzheimer. Les patients atteints de MCI présentent des troubles de la mémoire ou d'autres fonctions cognitives, sans pour autant perdre leur autonomie dans les activités quotidiennes.

Du point de vue anatomique, les images IRM montrent des modifications plus discrètes que celles observées chez les patients atteints de la maladie d'Alzheimer. Ces différences étant souvent peu marquées, la distinction entre les classes MCI et CN constitue l'un des principaux défis des méthodes automatiques de classification.

#### Cognitively Normal (CN)

La classe Cognitively Normal (CN) regroupe les sujets ne présentant aucun signe clinique de déficience cognitive. Ces individus possèdent des fonctions cognitives considérées comme normales pour leur âge et servent de groupe de référence dans les études comparatives.

Les images IRM appartenant à cette catégorie ne présentent pas les altérations anatomiques caractéristiques des maladies neurodégénératives. Elles permettent ainsi aux modèles d'apprentissage profond d'identifier les caractéristiques associées à un cerveau sain et de les distinguer des modifications observées chez les patients atteints de MCI ou de la maladie d'Alzheimer.

La répartition des images entre les trois classes est présentée dans le Tableau 2.3.

Tableau 9. *Répartition des images*

| CLASSE                                 | NOMBRE D'IMAGES |
|----------------------------------------|-----------------|
| <b>AD (ALZHEIMER'S DISEASE)</b>        | 3 746           |
| <b>MCI (MILD COGNITIVE IMPAIRMENT)</b> | 4 382           |
| <b>CN (COGNITIVELY NORMAL)</b>         | 3 806           |
| <b>TOTAL</b>                           | 11 934          |

Le Tableau 9 présente la répartition des images entre les trois classes du jeu de données. On observe que la classe MCI contient le plus grand nombre d'images (4 382), suivie de la classe CN (3 806) et de la classe AD (3 746). Bien que les effectifs ne soient pas parfaitement identiques, cette répartition reste relativement équilibrée, ce qui permet de limiter le biais lié au déséquilibre des classes et de favoriser un apprentissage plus robuste des modèles de Deep Learning.

### 2.3.4 Format des images

Les images utilisées dans cette étude sont enregistrées au format DICOM (Digital Imaging and Communications in Medicine), qui constitue le standard international pour le stockage, la transmission et l'échange des données d'imagerie médicale. Développé par le comité DICOM, ce standard assure l'interopérabilité entre les différents équipements d'imagerie médicale (IRM, scanner, radiographie, échographie, etc.) ainsi que les systèmes d'information hospitaliers. Grâce à cette normalisation, les images peuvent être partagées et exploitées sur différents dispositifs tout en conservant leur qualité et leur intégrité [73].

Contrairement aux formats d'images classiques tels que JPEG, PNG ou BMP, un fichier DICOM ne contient pas uniquement les valeurs des pixels constituant l'image. Il intègre également un ensemble de métadonnées décrivant les caractéristiques de l'examen médical. Ces informations comprennent notamment les paramètres d'acquisition, les dimensions de l'image, la résolution spatiale, le type de modalité, les informations relatives à l'appareil d'imagerie ainsi que diverses données techniques permettant une interprétation correcte des examens. Cette richesse d'informations fait du format DICOM une référence incontournable dans les applications d'imagerie médicale.

Dans le cadre de ce projet, les examens IRM cérébraux sont directement exploités dans leur format d'origine afin de préserver l'ensemble des informations disponibles. Les fichiers DICOM sont lus à l'aide de la bibliothèque PyDicom, qui permet d'accéder aux données des pixels ainsi qu'aux métadonnées associées [74].

L'utilisation du format DICOM présente plusieurs avantages dans cette étude. En conservant les images dans leur format natif, il est possible de préserver leur qualité sans perte d'information liée à une compression. De plus, l'accès aux métadonnées facilite la gestion des examens et garantit une meilleure traçabilité des données utilisées. Ces caractéristiques font du format DICOM un choix particulièrement adapté aux applications de diagnostic assisté par intelligence artificielle, où la qualité et la fiabilité des données constituent des éléments essentiels pour obtenir des performances de classification élevées.




Figure 2.2 : Exemple d'une image IRM DICOM

## 2.4 Prétraitement des images

Le prétraitement des images constitue une étape essentielle dans le développement d'un système de classification basé sur le Deep Learning. Les images IRM issues de la base ADNI sont acquises dans des conditions variées et présentent des différences en termes de dimensions, d'intensité des pixels et de format de stockage. Une préparation adéquate des données est donc indispensable afin de garantir l'homogénéité des images utilisées lors de l'entraînement des modèles.

L'objectif principal du prétraitement est de transformer les images brutes en un format standardisé compatible avec les architectures de réseaux de neurones convolutifs utilisées dans cette étude. Cette étape permet non seulement d'améliorer la qualité des données exploitées, mais également d'optimiser le processus d'apprentissage en réduisant les variations non pertinentes entre les images.

Dans cette étude, le pipeline de prétraitement comprend quatre étapes principales : la lecture des images DICOM, le redimensionnement des images à une taille uniforme de  $224 \times 224$  pixels, la normalisation des intensités des pixels dans l'intervalle  $[0,1]$ , puis la conversion des images en trois canaux RGB afin de répondre aux exigences des architectures de Deep Learning utilisées. Les différentes étapes sont décrites dans les sections suivantes.

### 2.4.1 Lecture des images DICOM

La première étape du prétraitement consiste à charger les examens d'imagerie médicale enregistrés au format DICOM (Digital Imaging and Communications in Medicine). Ce format étant spécifiquement conçu pour le domaine médical, il nécessite l'utilisation d'une bibliothèque spécialisée permettant d'accéder aux informations contenues dans chaque fichier.

Dans cette étude, la lecture des images est réalisée à l'aide de la bibliothèque PyDicom, une bibliothèque Python largement utilisée pour la manipulation des fichiers DICOM. Celle-ci permet de lire les fichiers sans modifier leur contenu et d'accéder aussi bien aux métadonnées qu'aux données de l'image. Les métadonnées regroupent diverses informations relatives à l'examen, telles que les paramètres d'acquisition, les dimensions de l'image ou encore les caractéristiques de l'appareil d'imagerie, tandis que les données de pixels représentent les intensités constituant l'image IRM.

Dans l'implémentation développée, chaque fichier DICOM est ouvert individuellement à l'aide de la fonction `pydicom.dcmread()`. Les valeurs des pixels sont ensuite extraites à partir de l'attribut `pixel_array`, qui convertit automatiquement les données du fichier en une matrice numérique exploitable par les bibliothèques de traitement d'images et les frameworks de Deep Learning. Cette représentation matricielle constitue la base des étapes de prétraitement réalisées par la suite.

Le recours à PyDicom présente plusieurs avantages. Il permet de conserver les images dans leur format d'origine, d'éviter toute perte d'information liée à une conversion préalable et de garantir

une lecture fidèle des examens IRM. Cette approche assure également une compatibilité avec les outils de traitement d'images utilisés dans les étapes suivantes du pipeline.




Figure 2.3: Lecture d'une image DICOM

#### 2.4.2 Redimensionnement des images

Après la lecture des fichiers DICOM, les images IRM présentent des dimensions variables qui ne sont pas directement compatibles avec les architectures de Deep Learning utilisées dans cette étude. Afin d'assurer une homogénéité des données d'entrée, toutes les images sont redimensionnées à une résolution fixe de  $224 \times 224$  pixels.

Ce redimensionnement est réalisé à l'aide de la fonction `cv2.resize()` de la bibliothèque OpenCV. Cette opération consiste à adapter les dimensions de chaque image tout en conservant les informations anatomiques essentielles nécessaires à la classification. Le choix de la taille  $224 \times 224$  pixels n'est pas arbitraire. Il correspond à la dimension d'entrée standard de l'architecture MobileNetV2 et est également adapté au modèle CNN développé dans cette étude.

L'utilisation d'une taille uniforme présente plusieurs avantages. Elle garantit la compatibilité des données avec les modèles de Deep Learning, facilite le traitement par lots (*batch processing*) lors de l'entraînement et réduit le coût computationnel associé au traitement d'images de grande résolution. De plus, le redimensionnement permet d'obtenir un jeu de données homogène, condition indispensable pour assurer la stabilité du processus d'apprentissage.




Figure 2.4 : Redimensionnement

### 2.4.3 Normalisation

Après le redimensionnement, une étape de normalisation est appliquée afin d'homogénéiser les valeurs d'intensité des pixels et de faciliter l'apprentissage des modèles de Deep Learning. Contrairement à une simple division par une constante, cette étude utilise une normalisation Min-Max, qui consiste à ramener les intensités des pixels de chaque image dans l'intervalle  $[0,1]$  en tenant compte des valeurs minimale et maximale présentes dans cette image.

La normalisation est réalisée selon l'équation suivante :

$$I_{\text{norm}} = \frac{I - I_{\min}}{I_{\max} - I_{\min} + \epsilon}$$

Où :

- ✚ I : valeur originale du pixel ;
- ✚ I min : représente la valeur minimale des pixels de l'image ;
- ✚ I max : représente la valeur maximale des pixels de l'image ;
- ✚  $\epsilon=10^{-8}$  : est une très petite constante ajoutée au dénominateur afin d'éviter une division par zéro lorsque toutes les valeurs de l'image sont identiques.

Cette méthode garantit que la plus faible intensité de l'image est ramenée à 0, tandis que la plus élevée est ramenée à 1. Les autres valeurs sont alors réparties proportionnellement entre ces deux bornes, ce qui permet de préserver les contrastes présents dans chaque image tout en uniformisant leur plage de valeurs.



L'utilisation de la normalisation Min-Max améliore la stabilité numérique des calculs réalisés lors de l'entraînement des réseaux de neurones et favorise une convergence plus rapide des algorithmes d'optimisation. Elle contribue également à limiter l'influence des variations d'intensité entre les différentes acquisitions IRM, ce qui permet aux modèles de se concentrer davantage sur les caractéristiques.

#### 2.4.4 Conversion en RGB

Les images IRM extraites des fichiers DICOM sont initialement représentées en niveaux de gris et ne possèdent qu'un seul canal d'intensité. Cependant, les modèles de Deep Learning utilisés dans cette étude requièrent des images d'entrée composées de trois canaux. Une étape de conversion est donc réalisée afin d'obtenir des images de dimensions  $224 \times 224 \times 3$ .

Dans l'implémentation développée, cette conversion est effectuée à l'aide de la fonction `numpy.stack()`, qui consiste à dupliquer l'image en niveaux de gris sur trois canaux identiques. Plus précisément, la même matrice de pixels est empilée trois fois selon le dernier axe afin de former une image RGB.

Cette opération est réalisée selon l'instruction suivante :

```
image = np.stack([image, image, image], axis=-1)
```

Contrairement à une véritable image couleur, cette transformation ne modifie pas les intensités des pixels ni les informations anatomiques contenues dans l'image. Les trois canaux Rouge (R), Vert (G) et Bleu (B) contiennent exactement les mêmes valeurs. L'objectif de cette conversion est uniquement de respecter le format d'entrée attendu par les architectures de Deep Learning utilisées dans cette étude.




Figure 2.5 : Conversion RGB

### 2.4.5 Data Augmentation

La quantité et la diversité des données d'entraînement jouent un rôle déterminant dans les performances des modèles de Deep Learning. Cependant, dans les applications médicales, le nombre d'images disponibles est souvent limité en raison des contraintes liées à l'acquisition des examens et à la confidentialité des données. Afin de pallier cette limitation et d'améliorer la capacité de généralisation des modèles, une technique de Data Augmentation est appliquée au cours de la phase d'entraînement.

La Data Augmentation consiste à générer automatiquement de nouvelles images à partir des images originales en leur appliquant différentes transformations géométriques, tout en conservant leur étiquette de classe. Ces transformations permettent d'augmenter artificiellement la diversité du jeu de données sans modifier les caractéristiques anatomiques essentielles présentes dans les examens IRM. Les modèles sont ainsi exposés à un plus grand nombre de variations visuelles, ce qui les rend plus robustes face aux nouvelles données et réduit le risque de surapprentissage (*overfitting*).

Dans cette étude, les opérations de Data Augmentation sont réalisées à l'aide de la classe ImageDataGenerator de la bibliothèque TensorFlow/Keras. Les transformations appliquées correspondent directement à celles définies dans l'implémentation du projet et comprennent :

- ✚ Rotation : les images sont soumises à de légères rotations aléatoires afin de simuler les variations d'orientation pouvant apparaître lors de l'acquisition des examens IRM.
- ✚ Zoom : un agrandissement ou une réduction modérée est appliqué afin de rendre les modèles moins sensibles aux différences d'échelle entre les images.
- ✚ Translation : les images sont déplacées horizontalement et verticalement sur une faible distance afin de reproduire de légères variations de position du cerveau dans le champ d'acquisition.
- ✚ Flip horizontal : une inversion horizontale est réalisée de manière aléatoire afin d'accroître la diversité des données d'entraînement tout en conservant les caractéristiques générales de l'image.

Il est important de souligner que ces transformations sont appliquées uniquement aux images du jeu d'entraînement. Les ensembles de validation et de test ne subissent aucune augmentation afin de garantir une évaluation objective des performances des modèles sur des données non modifiées.




Figure 2.6 : Exemples de Data Augmentation

## 2.5 Préparation des données

### 2.5.1 Division des données

Après les différentes étapes de prétraitement, le jeu de données est divisé en deux ensembles distincts à l'aide de la fonction `train_test_split()` de la bibliothèque Scikit-learn. Cette division permet de séparer les données destinées à l'entraînement du modèle de celles utilisées pour l'évaluation de ses performances.

Dans cette étude, 80 % des images sont affectées au jeu d'entraînement (Train), tandis que les 20 % restantes constituent le jeu de test (Test). La séparation est réalisée en utilisant le paramètre `test_size = 0.20`, ce qui garantit une répartition fixe des données entre les deux ensembles.

Afin de préserver la distribution des différentes classes cliniques (AD, MCI et CN) dans chacun des ensembles, une division stratifiée est appliquée grâce au paramètre `stratify = df["Label"]`. Cette stratégie permet de conserver des proportions similaires de chaque classe dans les jeux d'entraînement et de test, limitant ainsi les déséquilibres susceptibles d'influencer les performances des modèles.

Par ailleurs, le paramètre `random_state = 42` est utilisé afin d'assurer la reproductibilité des expériences. Ainsi, la même répartition des données est obtenue à chaque exécution du programme, ce qui facilite la comparaison des résultats expérimentaux.

Au cours de l'entraînement, le jeu de test est également utilisé comme ensemble de validation grâce au paramètre `validation_data` de la fonction `model.fit()`. À la fin de chaque époque, les performances du modèle sont évaluées sur cet ensemble afin de calculer les métriques de validation, notamment la perte de validation (Validation Loss) et la précision de validation (Validation Accuracy). Ces informations permettent de suivre l'évolution de l'apprentissage et sont utilisées par les mécanismes d'optimisation tels que Early Stopping et ReduceLROnPlateau, qui interrompent l'entraînement ou ajustent automatiquement le taux d'apprentissage lorsque les performances cessent de s'améliorer.

Tableau 10. *Répartition des données*

| ENSEMBLE                                  | POURCENTAGE | NOMBRE D'IMAGES |
|-------------------------------------------|-------------|-----------------|
| ENTRAÎNEMENT (TRAIN)                      | 80 %        | 9 547           |
| TEST (UTILISÉ ÉGALEMENT COMME VALIDATION) | 20 %        | 2 387           |
| TOTAL                                     | 100 %       | 11 934          |

### 2.5.2 Pipeline de préparation

Après la division du jeu de données, les images sont prises en charge par un pipeline de préparation développé pour alimenter automatiquement les modèles de Deep Learning. Ce

pipeline repose sur une classe personnalisée, DicomDataGenerator, qui assure le chargement progressif des images DICOM au cours de l'entraînement.

À partir des ensembles `train_df` et `test_df`, le générateur lit les chemins des images et leurs étiquettes, puis applique successivement les différentes étapes de prétraitement, à savoir la lecture des fichiers DICOM, le redimensionnement à  $224 \times 224$  pixels, la normalisation des intensités et la conversion en trois canaux RGB. Pour le jeu d'entraînement, les techniques de Data Augmentation sont également appliquées afin d'augmenter la diversité des données et de renforcer la capacité de généralisation des modèles. En revanche, les images du jeu de test, utilisé également comme ensemble de validation, ne subissent aucune augmentation et sont uniquement prétraitées avant leur utilisation.

Les images sont ensuite regroupées en lots de 32 images (batch size = 32) avant d'être transmises aux différents modèles de Deep Learning. Cette stratégie permet d'optimiser l'utilisation de la mémoire, d'accélérer le processus d'entraînement et de traiter efficacement un grand volume d'images.

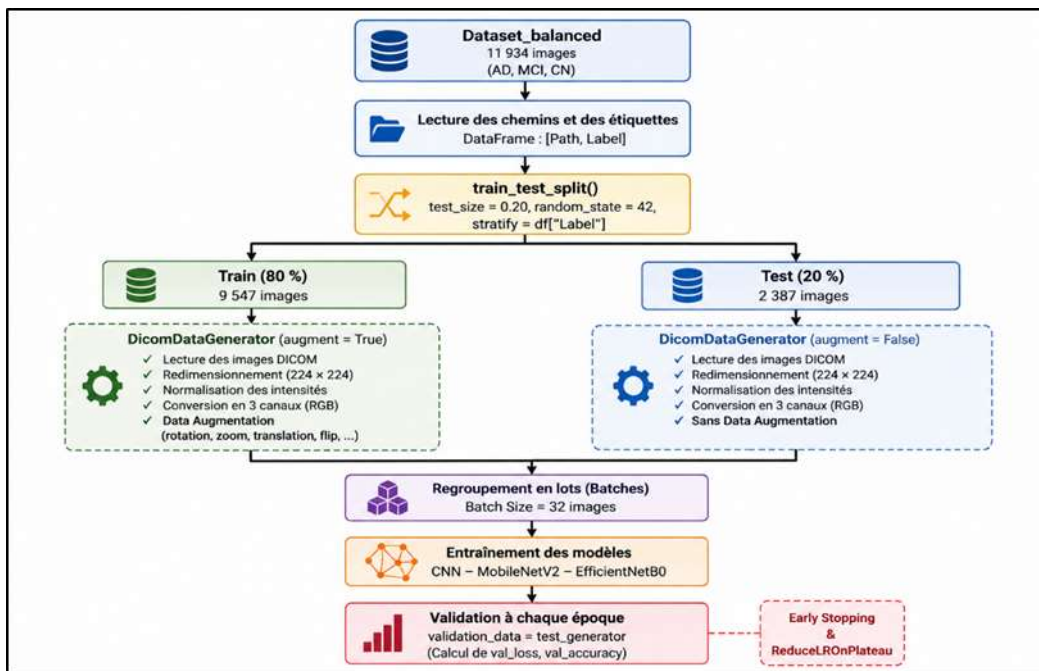


Figure 2.7 : Pipeline de préparation des données

## 2.6 Développement des modèles de Deep Learning

Dans le cadre de cette étude, deux architectures de Deep Learning ont été développées et évaluées pour la classification automatique des images IRM cérébrales en trois catégories cliniques : AD, MCI et CN. L'objectif est de comparer les performances d'un réseau de neurones convolutif (CNN) conçu spécifiquement pour cette application à celles d'une architecture de Transfer Learning basée sur MobileNetV2.

Le premier modèle correspond à un Convolutional Neural Network (CNN) développé à l'aide de la bibliothèque TensorFlow/Keras. Son architecture a été conçue pour extraire

progressivement les caractéristiques discriminantes des images IRM grâce à une succession de couches de convolution, de normalisation, de pooling et de classification.

Les deux autres modèles reposent sur des architectures pré-entraînées sur la base de données ImageNet. Le recours au Transfer Learning permet de réutiliser les connaissances acquises lors d'un apprentissage préalable afin d'améliorer les performances de classification tout en réduisant le temps d'entraînement et les besoins en données annotées.

Les sous-sections suivantes présentent en détail l'architecture de chacun des modèles, leur principe de fonctionnement ainsi que les adaptations réalisées dans cette étude.

### 2.6.1 Architecture du modèle CNN

Les Convolutional Neural Networks (CNN) constituent aujourd'hui l'une des architectures les plus utilisées pour l'analyse et la classification des images. Leur principe repose sur l'extraction automatique des caractéristiques visuelles directement à partir des données d'entrée, sans nécessiter la définition manuelle de descripteurs. Contrairement aux méthodes classiques de traitement d'images, les CNN apprennent progressivement les représentations les plus pertinentes au cours de la phase d'entraînement, ce qui leur permet d'obtenir d'excellentes performances dans de nombreuses applications, notamment en imagerie médicale.

Dans cette étude, un modèle CNN a été développé à l'aide de la bibliothèque TensorFlow/Keras afin de réaliser la classification automatique des images IRM cérébrales en trois catégories cliniques : AD, MCI et CN. L'architecture retenue reçoit en entrée des images prétraitées de dimensions  $224 \times 224 \times 3$ . Le réseau est constitué d'une succession de blocs de convolution permettant d'extraire progressivement les caractéristiques anatomiques présentes dans les images, suivis d'une étape de classification réalisée par des couches entièrement connectées.

Le modèle débute par une première couche de convolution composée de 16 filtres de taille  $3 \times 3$  utilisant la fonction d'activation ReLU. Cette couche apprend les caractéristiques les plus simples de l'image, telles que les contours, les transitions d'intensité et certaines textures locales. Une couche de Batch Normalization est ensuite appliquée afin de stabiliser la distribution des activations, ce qui améliore la vitesse de convergence et favorise un apprentissage plus stable. Les cartes de caractéristiques obtenues sont ensuite réduites grâce à une couche de MaxPooling2D, qui diminue leur résolution spatiale tout en conservant les informations les plus significatives.

Le même principe est reproduit dans les trois blocs suivants, avec un nombre de filtres progressivement augmenté à 32, 64 puis 128. Cette augmentation graduelle permet au réseau d'apprendre des représentations de plus en plus complexes. Alors que les premières couches détectent principalement des motifs élémentaires, les couches profondes capturent des structures anatomiques plus élaborées susceptibles d'être associées aux différentes phases de la maladie d'Alzheimer.

À l'issue du dernier bloc convolutif, les cartes de caractéristiques sont transformées par une couche GlobalAveragePooling2D. Cette stratégie réduit considérablement le nombre de paramètres du modèle tout en limitant le risque de surapprentissage.

Le vecteur obtenu est ensuite transmis à une couche entièrement connectée (Dense) composée de 128 neurones utilisant la fonction d'activation ReLU. Cette couche combine les caractéristiques apprises afin de construire une représentation discriminante adaptée au problème de classification.

Afin d'améliorer la capacité de généralisation du réseau, une couche de Dropout avec un taux de 0,4 est introduite avant la couche de sortie. Pendant l'entraînement, cette technique désactive aléatoirement une partie des neurones, empêchant ainsi le modèle de devenir trop dépendant de certaines connexions et réduisant le phénomène de surapprentissage.

Enfin, la couche de sortie est constituée de trois neurones correspondant aux trois classes cliniques étudiées (AD, MCI et CN). Cette couche utilise la fonction d'activation Softmax, qui transforme les scores produits par le réseau en probabilités de classification. La classe prédite correspond alors à celle présentant la probabilité la plus élevée.




Figure 2.8 : Architecture du CNN

Tableau 11. Description des couches du CNN

| COUCHE                   | PARAMÈTRES                                                                            | FONCTION                                                            |
|--------------------------|---------------------------------------------------------------------------------------|---------------------------------------------------------------------|
| <b>ENTRÉE (INPUT)</b>    | $224 \times 224 \times 3$                                                             | Reçoit les images IRM prétraitées.                                  |
| <b>BLOC CONVOLUTIF 1</b> | Conv2D (16, $3 \times 3$ , ReLU) + BatchNormalization + MaxPooling2D ( $2 \times 2$ ) | Extraction des caractéristiques de bas niveau (contours, textures). |
| <b>BLOC CONVOLUTIF 2</b> | Conv2D (32, $3 \times 3$ , ReLU) + BatchNormalization + MaxPooling2D ( $2 \times 2$ ) | Extraction de caractéristiques plus complexes.                      |

|                               |                                                                         |                                                                          |
|-------------------------------|-------------------------------------------------------------------------|--------------------------------------------------------------------------|
| <b>BLOC CONVOLUTIF 3</b>      | Conv2D (64, 3×3, ReLU) + BatchNormalization + MaxPooling2D (2×2)        | Apprentissage de structures anatomiques plus élaborées.                  |
| <b>BLOC CONVOLUTIF 4</b>      | Conv2D (128, 3×3, ReLU) + BatchNormalization + MaxPooling2D (2×2)       | Extraction de caractéristiques de haut niveau.                           |
| <b>GLOBALAVERAGEPOOLING2D</b> | Taille du pool : globale (moyenne sur chaque carte de caractéristiques) | Réduit les cartes de caractéristiques en un vecteur de caractéristiques. |
| <b>DENSE</b>                  | 128 neurones, ReLU                                                      | Combine les caractéristiques extraites pour la classification.           |
| <b>DROPOUT</b>                | Taux = 0,4                                                              | Réduit le risque de surapprentissage.                                    |
| <b>DENSE (SORTIE)</b>         | 3 neurones, Softmax                                                     | Produit les probabilités des classes AD, MCI et CN.                      |

### 2.6.2 Architecture de MobileNetV2

Le deuxième modèle utilisé dans cette étude est MobileNetV2, une architecture de réseau de neurones convolutif proposée par Google. Contrairement au CNN développé spécifiquement pour ce projet, MobileNetV2 est un modèle pré-entraîné sur la base de données ImageNet, qui contient plusieurs millions d'images appartenant à un grand nombre de catégories. Son utilisation repose sur la technique du Transfer Learning (apprentissage par transfert), qui consiste à réutiliser les connaissances acquises lors d'un apprentissage préalable afin de résoudre un nouveau problème de classification.

Les couches du modèle pré-entraîné sont ensuite gelées (`base_model.trainable = False`), ce qui signifie que leurs poids ne sont pas modifiés durant l'entraînement. Seules les nouvelles couches ajoutées sont entraînées sur le jeu de données utilisé dans cette étude. Cette stratégie permet de préserver les caractéristiques générales déjà apprises par MobileNetV2 tout en adaptant le modèle au problème de classification des images IRM cérébrales.

Après le réseau MobileNetV2, une couche GlobalAveragePooling2D est utilisée afin de convertir les cartes de caractéristiques extraites en un vecteur de caractéristiques compact. Ce vecteur est ensuite transmis à une couche Dense de 256 neurones utilisant la fonction d'activation ReLU, suivie d'une couche Dropout avec un taux de 0,5 afin de limiter le



surapprentissage. Une seconde couche Dense de 128 neurones, également associée à la fonction ReLU, est ensuite appliquée, suivie d'une nouvelle couche Dropout de 0,3. Enfin, la couche de sortie comporte trois neurones utilisant la fonction d'activation Softmax, permettant de produire les probabilités d'appartenance aux trois classes cliniques étudiées.

L'architecture complète du modèle MobileNetV2 adaptée à cette étude est illustrée dans la Figure 2.9.

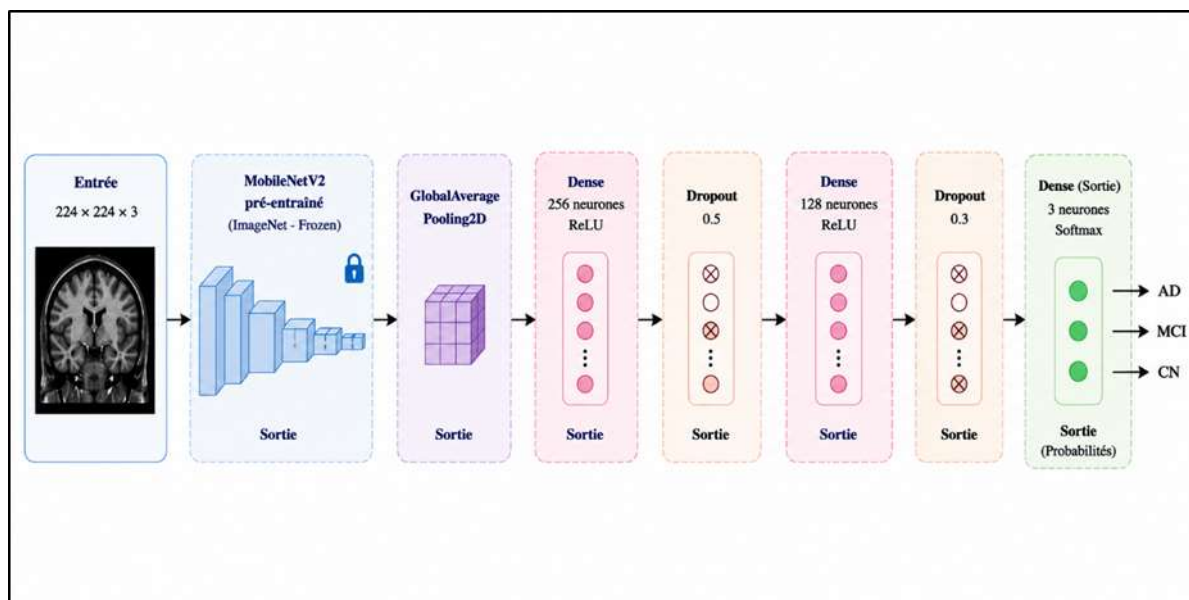


Figure 2.9 : Architecture MobileNetV2

## 2.7 Paramètres d'entraînement

Les trois modèles de Deep Learning développés dans cette étude ont été entraînés à l'aide d'une configuration commune afin de garantir une comparaison équitable de leurs performances. Les principaux hyperparamètres utilisés influencent directement la qualité de l'apprentissage, la vitesse de convergence ainsi que la capacité de généralisation des modèles.

Les différentes configurations retenues sont présentées dans le Tableau 2.6, puis détaillées dans les sous-sections suivantes.

Tableau 12. Paramètres d'entraînement des modèles

| PARAMÈTRE                | VALEUR UTILISÉE | DESCRIPTION                                                                      |
|--------------------------|-----------------|----------------------------------------------------------------------------------|
| <b>TAILLE DES IMAGES</b> | 224 × 224 × 3   | Dimensions des images IRM fournies en entrée des modèles après le prétraitement. |
| <b>BATCH SIZE</b>        | 32              | Nombre d'images traitées simultanément lors de chaque itération d'entraînement.  |



|                          |                                                                  |                                                                                                                                                                               |
|--------------------------|------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>NOMBRE D'ÉPOQUES</b>  | 20                                                               | Nombre maximal de passages sur l'ensemble des données d'entraînement lors de la phase initiale.                                                                               |
| <b>LEARNING RATE</b>     | $1 \times 10^{-4}$ (0,0001)                                      | Taux d'apprentissage initial utilisé par l'optimiseur Adam.                                                                                                                   |
| <b>OPTIMIZER</b>         | Adam                                                             | Algorithme d'optimisation utilisé pour ajuster les poids des réseaux de neurones.                                                                                             |
| <b>FONCTION DE PERTE</b> | Sparse Categorical Crossentropy                                  | Fonction de coût adaptée à un problème de classification multiclasse avec des étiquettes codées sous forme d'entiers.                                                         |
| <b>EARLYSTOPPING</b>     | Patience = 5                                                     | Interrompt automatiquement l'entraînement si la perte de validation ( <i>val_loss</i> ) ne s'améliore plus pendant cinq époques consécutives et restaure les meilleurs poids. |
| <b>REDUCELRONPLATEAU</b> | Facteur = 0,2 ;<br>Patience = 3 ; Min<br>LR = $1 \times 10^{-6}$ | Réduit automatiquement le taux d'apprentissage lorsque la perte de validation stagne afin d'améliorer la convergence.                                                         |
| <b>MODELCHECKPOINT</b>   | save_best_only = True                                            | Sauvegarde automatiquement le modèle présentant les meilleures performances sur les données de validation.                                                                    |

Les sous-sections suivantes présentent le rôle et l'importance de chacun de ces paramètres dans le processus d'apprentissage.

#### Taille des images

Avant l'entraînement, toutes les images IRM sont redimensionnées à une résolution de  $224 \times 224$  pixels puis converties en trois canaux (RGB), ce qui conduit à une dimension finale de  $224 \times 224 \times 3$ . Cette taille est utilisée de manière uniforme pour les trois modèles développés dans cette étude, à savoir le CNN, MobileNetV2 et EfficientNetB0. L'utilisation d'une dimension commune garantit une homogénéité des données d'entrée et facilite la comparaison des performances des différentes architectures.

#### Batch Size

Le Batch Size représente le nombre d'images traitées simultanément avant la mise à jour des poids du réseau. Dans cette étude, une valeur de 32 est utilisée. Ce choix permet d'obtenir un bon compromis entre la stabilité de l'apprentissage, le temps d'entraînement et l'utilisation de la mémoire disponible sur la machine de calcul.

#### ✚ Nombre d'époques

Le nombre maximal d'époques est fixé à 20 pour la première phase d'entraînement des modèles. Une époque correspond à un passage complet sur l'ensemble du jeu de données d'entraînement. Toutefois, grâce au mécanisme EarlyStopping, l'entraînement peut être interrompu automatiquement avant d'atteindre cette limite lorsque les performances sur les données de validation ne progressent plus.

#### ✚ Learning Rate

Le Learning Rate contrôle l'amplitude des mises à jour des poids effectuées par l'optimiseur à chaque itération. Dans cette étude, un taux d'apprentissage initial de  $1 \times 10^{-4}$  (0,0001) est utilisé. Cette valeur permet une convergence progressive et stable du modèle tout en limitant les risques de divergence durant l'apprentissage.

#### ✚ Optimizer

Les trois modèles sont entraînés à l'aide de l'optimiseur Adam (Adaptive Moment Estimation). Cet algorithme est largement utilisé en Deep Learning grâce à sa capacité à adapter automatiquement le taux d'apprentissage de chaque paramètre du réseau. Il combine les avantages des méthodes Momentum et RMSProp, ce qui favorise une convergence rapide et stable, même pour des problèmes de classification complexes comme celui traité dans cette étude.

#### ✚ Fonction de perte

La fonction de perte utilisée est Sparse Categorical Crossentropy, adaptée aux problèmes de classification multiclasse lorsque les étiquettes des données sont représentées par des valeurs entières. Cette fonction mesure l'écart entre les probabilités prédites par le modèle et les classes réelles, puis guide l'optimiseur afin de minimiser cette erreur au cours de l'entraînement.

#### ✚ EarlyStopping

Afin d'éviter le phénomène de surapprentissage (*overfitting*), un callback EarlyStopping est intégré au processus d'entraînement. Dans cette étude, ce mécanisme surveille la perte de validation (val\_loss) avec une patience de 5 époques. Si aucune amélioration n'est observée durant cinq époques consécutives, l'entraînement est automatiquement interrompu. De plus, l'option restore\_best\_weights=True permet de restaurer les poids correspondant au meilleur modèle obtenu pendant l'entraînement.

#### ✚ ReduceLROnPlateau

Le callback ReduceLROnPlateau est utilisé afin d'ajuster automatiquement le taux d'apprentissage lorsque les performances du modèle cessent de progresser. Dans cette étude, la

perte de validation (val\_loss) est surveillée et, après trois époques sans amélioration, le Learning Rate est multiplié par un facteur de 0,2, avec une valeur minimale fixée à  $1 \times 10^{-6}$ . Cette stratégie favorise une convergence plus fine du modèle vers une solution optimale.

#### ModelCheckpoint

Le callback ModelCheckpoint est utilisé afin de sauvegarder automatiquement le modèle présentant les meilleures performances au cours de l'entraînement. Dans cette implémentation, la sauvegarde est réalisée en fonction de la précision de validation (val\_accuracy), et l'option save\_best\_only=True garantit que seul le modèle offrant les meilleurs résultats est conservé. Cette approche permet d'utiliser, lors de la phase d'évaluation, le modèle le plus performant obtenu durant l'entraînement.

## 2.8 Méthodes d'évaluation

L'évaluation des modèles de Deep Learning constitue une étape essentielle afin de mesurer leur capacité à classifier correctement les images IRM selon les trois catégories cliniques étudiées. Dans cette étude, plusieurs indicateurs de performance sont utilisés afin d'obtenir une analyse complète des résultats. Ces métriques permettent d'évaluer la qualité des prédictions sous différents aspects, notamment la précision globale, la capacité de détection des différentes classes et la discrimination entre les catégories diagnostiques.

#### Accuracy

L'Accuracy (exactitude) représente le pourcentage de prédictions correctement réalisées par le modèle par rapport au nombre total d'échantillons. Il s'agit de l'un des indicateurs les plus utilisés pour évaluer les performances globales d'un modèle de classification.

La formule de l'Accuracy est donnée par :

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

Où TP (True Positives) représente le nombre de prédictions positives correctes, TN (True Negatives) le nombre de prédictions négatives correctes, FP (False Positives) les faux positifs et FN (False Negatives) les faux négatifs.

Une valeur d'Accuracy élevée indique que le modèle classe correctement une grande proportion des images. Toutefois, lorsque les classes sont déséquilibrées, cette métrique ne suffit pas à elle seule pour évaluer les performances du modèle.

#### Precision

La Precision mesure la proportion des prédictions positives qui sont réellement correctes. Elle permet d'évaluer la fiabilité des prédictions effectuées par le modèle lorsqu'il attribue une image à une classe donnée.

Elle est définie par la formule suivante :

$$Precision = \frac{TP}{TP + FP}$$

Une précision élevée signifie que le modèle produit peu de faux positifs et que les prédictions positives sont généralement fiables.

#### ✚ Recall

Le Recall, mesure la capacité du modèle à identifier correctement les échantillons appartenant réellement à une classe.

Sa formule est :

$$Recall = \frac{TP}{TP + FN}$$

Une valeur élevée de Recall indique que le modèle détecte efficacement les cas positifs et génère peu de faux négatifs. Dans le domaine médical, cette métrique est particulièrement importante, car elle permet de limiter le risque de ne pas détecter des patients réellement atteints de la maladie.

#### ✚ F1-score

Le F1-score combine la Precision et le Recall en une seule métrique. Il correspond à leur moyenne harmonique et fournit une évaluation plus équilibrée des performances du modèle, notamment lorsque les classes sont déséquilibrées.

Il est calculé selon la formule suivante :

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall}$$

Une valeur élevée du F1-score traduit un bon compromis entre la capacité du modèle à détecter correctement les cas positifs et la fiabilité de ses prédictions.

#### ✚ Matrice de confusion

La matrice de confusion est un tableau permettant de visualiser les performances d'un modèle de classification en comparant les classes prédites aux classes réelles. Elle met en évidence les classifications correctes ainsi que les erreurs commises entre les différentes catégories. Dans cette étude, elle permet d'analyser les confusions éventuelles entre les classes AD, MCI et CN, et d'identifier les catégories pour lesquelles le modèle présente les meilleures ou les moins bonnes performances.

#### ✚ Courbe ROC

La courbe ROC (*Receiver Operating Characteristic*) est une représentation graphique illustrant les performances d'un modèle de classification pour différents seuils de décision. Elle met en

relation le taux de vrais positifs (True Positive Rate) et le taux de faux positifs (False Positive Rate). Plus la courbe se rapproche du coin supérieur gauche du graphique, meilleures sont les performances du modèle.

## AUC

L'AUC (Area Under the Curve) correspond à l'aire située sous la courbe ROC. Cet indicateur résume les performances globales du modèle en une seule valeur comprise entre 0 et 1. Une valeur proche de 1 indique une excellente capacité de discrimination entre les différentes classes, tandis qu'une valeur proche de 0,5 correspond à un classificateur dont les performances sont comparables à un choix aléatoire.

Dans cette étude, l'AUC est utilisée en complément de la courbe ROC afin d'évaluer et de comparer les capacités de discrimination des différents modèles de Deep Learning.




Figure 2.10 : Architecture globale du système proposé

## 2.10 Conclusion

La mise en œuvre d'un système de classification fiable des images IRM repose sur une méthodologie rigoureuse couvrant l'ensemble des étapes du processus de développement, depuis la préparation des données jusqu'à l'évaluation des modèles. Dans cette perspective, ce chapitre a permis de définir le cadre méthodologique adopté pour cette étude en présentant les différentes procédures mises en œuvre afin de garantir la qualité des données, la pertinence des modèles développés ainsi que la fiabilité des résultats obtenus.

Une attention particulière a été accordée au prétraitement des images afin d'assurer l'homogénéité des données d'entrée et d'optimiser l'apprentissage des modèles de Deep Learning. Deux architectures ont été évaluées : un réseau de neurones convolutif (CNN) développé spécifiquement pour cette étude et une approche de Transfer Learning basée sur MobileNetV2. Les paramètres d'entraînement ont également été soigneusement définis afin d'améliorer les performances des modèles tout en limitant le risque de surapprentissage.

Par ailleurs, le choix des différentes métriques d'évaluation, incluant l'Accuracy, la Precision, le Recall, le F1-score, la matrice de confusion, la courbe ROC et l'AUC, permettra de réaliser une analyse complète des performances de chaque modèle. L'utilisation de plusieurs indicateurs complémentaires offre une évaluation plus objective que l'emploi d'une seule métrique et facilite une comparaison pertinente entre les architectures étudiées. En complément, l'intégration de la méthode Grad-CAM apportera une dimension interprétable au système proposé en mettant en évidence les régions des images IRM ayant le plus influencé les décisions du modèle.

Ainsi, l'ensemble des choix méthodologiques présentés dans ce chapitre constitue une base expérimentale solide pour la réalisation de cette étude. Ils permettront d'évaluer de manière rigoureuse les performances des différentes architectures de Deep Learning tout en mettant en évidence leurs forces et leurs limites dans le contexte de la classification des images IRM de la maladie d'Alzheimer. Le chapitre suivant sera consacré à la présentation, à l'analyse et à la discussion des résultats expérimentaux obtenus, afin d'identifier le modèle le plus performant et d'évaluer sa capacité à fournir une aide fiable et interprétable au diagnostic de la maladie d'Alzheimer.

## CHAPITRE3 :

# IMPLÉMENTATION ET RÉSULTATS

## CHAPITRE 3 : IMPLÉMENTATION ET RÉSULTATS

### 3.1 Introduction

Après avoir présenté, dans le chapitre précédent, la méthodologie adoptée pour la conception du système de classification de la maladie d'Alzheimer, ce chapitre est consacré à la mise en œuvre des modèles de Deep Learning ainsi qu'à l'analyse des résultats expérimentaux obtenus. L'objectif est d'évaluer leurs performances et leur capacité à classer automatiquement les images d'Imagerie par Résonance Magnétique (IRM).

Deux modèles de classification sont étudiés : un réseau de neurones convolutif (CNN) développé spécifiquement pour cette étude et une architecture de Transfer Learning basée sur MobileNetV2. Les deux modèles ont été entraînés dans les mêmes conditions expérimentales afin de permettre une comparaison objective de leurs performances.

L'évaluation repose sur plusieurs indicateurs complémentaires, notamment les courbes d'apprentissage (Accuracy et Loss), les matrices de confusion, le rapport de classification (Accuracy, Precision, Recall et F1-score) ainsi que les courbes ROC et les valeurs d'AUC. Ces métriques permettent d'analyser la capacité des modèles à distinguer les trois classes étudiées : Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN).

Une comparaison des performances obtenues est ensuite réalisée afin d'identifier le modèle offrant le meilleur compromis entre précision, capacité de généralisation et stabilité. Les résultats sont également confrontés à ceux de travaux récents de la littérature afin de situer les performances de l'approche proposée.

Enfin, une analyse basée sur la méthode Grad-CAM est appliquée au modèle le plus performant afin de visualiser les régions des images IRM ayant le plus influencé ses prédictions. Cette étape permet d'améliorer l'interprétabilité des résultats et de renforcer la confiance dans l'utilisation de l'intelligence artificielle comme outil d'aide au diagnostic de la maladie d'Alzheimer.

### 3.2 Implémentation du système

Cette section présente l'implémentation pratique du système développé pour la classification des images IRM de la maladie d'Alzheimer. Après la phase de préparation des données décrite dans le chapitre précédent, les différents modèles de Deep Learning ont été développés, entraînés et évalués dans un environnement de calcul adapté afin de mesurer leurs performances sur la tâche de classification.

L'implémentation repose sur deux architectures complémentaires. Un premier modèle basé sur un réseau de neurones convolutif (CNN) a été conçu comme modèle de référence. Une architecture de Transfer Learning, MobileNetV2, a ensuite été implémentée afin d'exploiter les connaissances acquises lors de son pré-entraînement sur une large base de données d'images. Les deux modèles ont été développés selon une méthodologie identique afin de garantir une comparaison objective de leurs performances.



Les sous-sections suivantes présentent successivement l'implémentation de chaque modèle ainsi que les principales étapes de leur processus d'entraînement.

### 3.2.1 Implémentation du modèle CNN

Le premier modèle développé dans le cadre de cette étude est un réseau de neurones convolutif (Convolutional Neural Network – CNN), utilisé comme modèle de référence pour la classification des images d'IRM cérébrales en trois catégories. Son implémentation a été réalisée à l'aide d'un notebook Python développé dans l'environnement Google Colab, qui offre un environnement de calcul adapté aux applications de Deep Learning grâce à l'utilisation de ressources de calcul accélérées. Le développement du modèle s'appuie principalement sur les bibliothèques TensorFlow et Keras pour la conception et l'entraînement du réseau de neurones, PyDicom et OpenCV pour la manipulation des images médicales, ainsi que NumPy, Pandas et Scikit-learn pour le traitement des données et l'évaluation des performances.

Le notebook a été conçu selon une organisation claire et progressive permettant de suivre l'ensemble des étapes nécessaires à la réalisation du système de classification. Dans un premier temps, l'environnement d'exécution est configuré par l'importation des différentes bibliothèques et la connexion à Google Drive, où sont stockés le jeu de données ADNI ainsi que les résultats générés au cours des différentes expérimentations. Cette organisation facilite la gestion des données, assure leur disponibilité tout au long du processus d'entraînement et permet de sauvegarder automatiquement les modèles ainsi que les fichiers de résultats.

Une deuxième étape est consacrée au chargement des images IRM et à la préparation du jeu de données. Les fichiers DICOM sont parcourus, les chemins d'accès aux images sont enregistrés et chaque image est associée à sa classe correspondante. Les informations sont ensuite regroupées dans une structure de type DataFrame, permettant une manipulation plus simple des données avant leur utilisation dans les différentes phases d'apprentissage.

Les images sont ensuite soumises aux opérations de prétraitement décrites dans le chapitre précédent. Cette étape comprend la lecture des fichiers DICOM, le redimensionnement des images, la normalisation des intensités des pixels, la conversion des images vers une représentation RGB ainsi que l'application de la Data Augmentation sur les données d'entraînement. Une fois ces opérations terminées, un générateur de données (Data Generator) est mis en place afin de charger les images par lots (batches) au cours de l'entraînement, ce qui permet d'optimiser l'utilisation de la mémoire tout en appliquant automatiquement les transformations nécessaires aux données.

L'architecture du réseau CNN est ensuite construite à l'aide de l'API Keras Sequential. Elle est composée de plusieurs couches de convolution (Conv2D) destinées à extraire progressivement les caractéristiques discriminantes des images IRM, suivies de couches de normalisation (Batch Normalization) et de sous-échantillonnage (Max Pooling) permettant d'améliorer la stabilité de l'apprentissage et de réduire la dimension des cartes de caractéristiques. Les informations extraites sont ensuite regroupées par une couche Global Average Pooling, avant d'être transmises à une couche entièrement connectée (Dense) chargée de la classification finale. Une couche Dropout est également intégrée afin de limiter le risque de surapprentissage, tandis que

la couche de sortie utilise la fonction d'activation Softmax pour prédire la probabilité d'appartenance de chaque image à l'une des trois classes étudiées.

Après la construction de l'architecture, le modèle est compilé à l'aide de l'optimiseur Adamet de la fonction de perte Sparse Categorical Crossentropy. La phase d'entraînement est ensuite lancée en intégrant plusieurs mécanismes de contrôle, notamment Early Stopping, Model Checkpoint et Reduce Learning Rate on Plateau, qui permettent respectivement d'interrompre automatiquement l'entraînement lorsque les performances cessent de s'améliorer, de conserver la meilleure version du modèle et d'ajuster dynamiquement le taux d'apprentissage afin d'obtenir une convergence plus efficace.

Enfin, une phase d'évaluation est réalisée sur l'ensemble des données de test afin de mesurer les performances du modèle. Plusieurs indicateurs sont calculés, notamment l'Accuracy, la Precision, le Recall, le F1-score, l'AUC, la matrice de confusion, les courbes ROC ainsi que le rapport de classification. Les différents résultats obtenus sont ensuite sauvegardés avec le modèle entraîné, facilitant ainsi leur exploitation et leur comparaison avec les architectures MobileNetV2 et EfficientNetB0 présentées dans les sections suivantes.




Figure 3.1 : Pipeline d'entraînement du CNN

### 3.2.2 Implémentation de MobileNetV2

Après l'implémentation du modèle CNN, une seconde approche fondée sur le Transfer Learning a été développée en utilisant l'architecture MobileNetV2. Ce modèle a été retenu en raison de son excellent compromis entre précision, rapidité d'exécution et faible nombre de paramètres. Contrairement au CNN conçu entièrement dans cette étude, MobileNetV2 exploite un réseau pré-entraîné sur la base de données ImageNet, ce qui permet de réutiliser des caractéristiques visuelles déjà apprises et d'améliorer les performances de classification tout en réduisant le temps d'entraînement.

L'implémentation a été réalisée sous Google Colab en s'appuyant principalement sur les bibliothèques TensorFlow, Keras, PyDicom, OpenCV, NumPy, Pandas et Scikit-learn. Dans un premier temps, l'environnement d'exécution est configuré par l'installation et l'importation des bibliothèques nécessaires, la connexion à Google Drive ainsi que la vérification des ressources matérielles disponibles, notamment l'accélération GPU. Cette étape permet de préparer un environnement de calcul adapté à l'entraînement du modèle.

Les images IRM issues de la base de données ADNI sont ensuite chargées et organisées. Les fichiers DICOM sont parcourus, chaque image est associée à sa classe correspondante (AD, MCI ou CN) puis les informations sont regroupées dans un DataFrame, facilitant ainsi leur manipulation et leur préparation avant l'apprentissage.

Une phase de prétraitement est ensuite appliquée aux images. Elle comprend la lecture des fichiers DICOM, le redimensionnement des images à une taille de  $224 \times 224$  pixels, la normalisation des intensités des pixels ainsi que leur conversion en trois canaux RGB. Les données sont ensuite divisées en ensembles d'entraînement et de test selon une stratégie de séparation stratifiée. Afin d'améliorer la capacité de généralisation du modèle, des techniques de Data Augmentation, telles que la rotation, le zoom, la translation et le retournement horizontal, sont appliquées aux images d'entraînement. Enfin, un Data Generator personnalisé est utilisé afin de charger les images par lots (batches) durant l'apprentissage et d'optimiser l'utilisation de la mémoire.

L'architecture de classification est ensuite construite à partir de MobileNetV2 pré-entraîné sur ImageNet, utilisé comme extracteur de caractéristiques. Dans une première phase, les couches du modèle de base sont figées (Freeze) afin de conserver les connaissances acquises lors du pré-entraînement. Une nouvelle tête de classification est ensuite ajoutée. Celle-ci est constituée d'une couche Global Average Pooling, de deux couches entièrement connectées (Dense) séparées par des couches Dropout, puis d'une couche de sortie utilisant la fonction d'activation Softmax pour la classification des trois catégories étudiées.

Le modèle est ensuite compilé à l'aide de l'optimiseur Adam et de la fonction de perte Sparse Categorical Crossentropy. La phase de Transfer Learning est réalisée en intégrant plusieurs mécanismes de contrôle, notamment Early Stopping, Model Checkpoint et Reduce Learning Rate on Plateau, afin d'améliorer la convergence de l'apprentissage, d'éviter le surapprentissage et de conserver automatiquement la meilleure version du modèle. Le temps total d'entraînement est également mesuré afin d'évaluer l'efficacité de cette architecture.

Afin d'améliorer davantage les performances obtenues, une phase de Fine-Tuning est ensuite réalisée. Cette étape consiste à dégeler les trente dernières couches de MobileNetV2, tandis que les couches précédentes restent figées. Le modèle est alors réentraîné avec un taux d'apprentissage plus faible, permettant d'adapter progressivement les caractéristiques apprises aux spécificités des images IRM utilisées dans cette étude.

Enfin, les performances du modèle sont évaluées à l'aide de plusieurs indicateurs, notamment l'Accuracy, la Precision, le Recall, le F1-score, l'AUC, la matrice de confusion, les courbes ROC ainsi que le rapport de classification. Le modèle final ainsi que l'ensemble des résultats

expérimentaux sont ensuite sauvegardés afin de faciliter leur exploitation et leur comparaison avec les autres architectures étudiées.

La Figure 3.2 présente le pipeline général d'implémentation du modèle MobileNetV2. Elle illustre les principales étapes du processus, depuis la configuration de l'environnement de travail et la préparation des données jusqu'à la phase de Fine-Tuning, l'évaluation des performances et la sauvegarde du modèle entraîné.

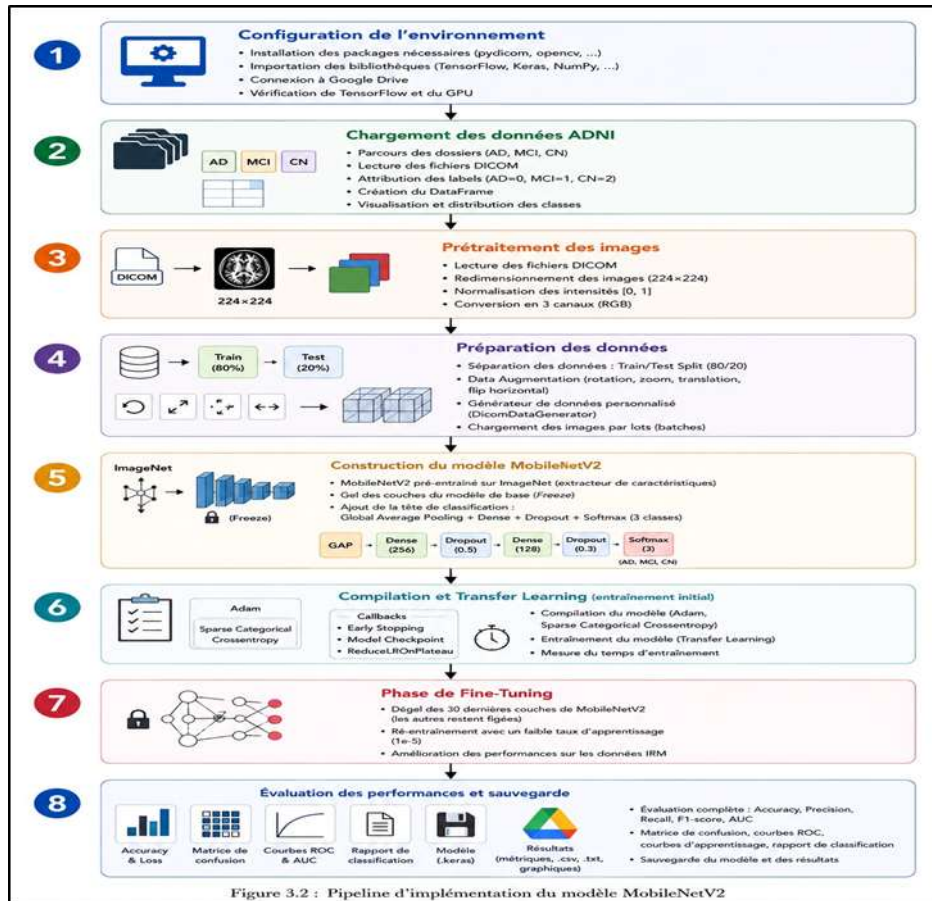


Figure 3.2 : Pipeline d'implémentation du modèle MobileNetV2

### 3.3 Résultats expérimentaux du CNN

L'entraînement du modèle CNN a permis d'obtenir un ensemble de résultats mettant en évidence son comportement durant l'apprentissage ainsi que ses performances en classification des images d'IRM cérébrales. L'analyse de ces résultats est essentielle pour vérifier la capacité du modèle à apprendre les caractéristiques discriminantes des trois catégories étudiées (AD, MCI et CN) et pour apprécier son aptitude à généraliser sur des données qui n'ont pas été utilisées lors de l'entraînement.

L'évaluation repose sur plusieurs outils complémentaires. Les courbes d'apprentissage permettent d'étudier la convergence du modèle au cours des différentes époques, tandis que la matrice de confusion, les courbes ROC, le rapport de classification et les différentes métriques

de performance offrent une analyse plus approfondie de la qualité de la classification obtenue. L'ensemble de ces résultats servira également de référence pour la comparaison avec les modèles de Transfer Learning et l'architecture GRAP proposés dans les sections suivantes.

### 3.3.1 Courbes Accuracy et Loss

Le suivi de l'évolution de l'Accuracy et de la Loss constitue une étape importante dans l'analyse des performances d'un modèle de Deep Learning. Ces deux indicateurs permettent d'observer le comportement du réseau de neurones pendant toute la phase d'apprentissage et de vérifier si celui-ci parvient à apprendre efficacement les caractéristiques présentes dans les images IRM. L'étude simultanée de ces courbes fournit également des informations précieuses sur la stabilité de l'entraînement, la vitesse de convergence du modèle ainsi que sa capacité à généraliser sur des données non vues.




Figure 3.3 : Courbe accuracy

La Figure 3.3 illustre l'évolution de l'Accuracy sur les ensembles d'entraînement et de validation au cours des différentes époques. Dès les premières itérations, les performances du modèle progressent de manière continue, traduisant une amélioration progressive de la qualité des prédictions. Cette évolution montre que le réseau de neurones parvient progressivement à extraire des représentations de plus en plus pertinentes des images IRM et à mieux distinguer les trois catégories de patients.

La courbe de validation suit une tendance proche de celle observée sur les données d'entraînement. Bien que quelques fluctuations apparaissent au cours de certaines époques, celles-ci restent modérées et ne remettent pas en cause la dynamique générale de l'apprentissage. Ce comportement est fréquemment observé dans les applications de Deep Learning en imagerie médicale, où la diversité anatomique des patients et la complexité des images peuvent entraîner de légères variations des performances entre deux époques

successives. Malgré ces fluctuations, les performances de validation demeurent proches de celles obtenues sur les données d'entraînement, ce qui traduit une bonne capacité de généralisation du modèle.




Figure 3.4 : Courbe loss

L'évolution de la fonction de perte, représentée dans la Figure 3.4, confirme les observations réalisées à partir de l'Accuracy. Au début de l'entraînement, la valeur de la Loss est relativement élevée, ce qui est normal puisque les paramètres du réseau sont initialisés aléatoirement et que le modèle ne dispose encore d'aucune connaissance sur les données d'entrée. Au fur et à mesure des époques, la Loss diminue progressivement aussi bien sur les données d'entraînement que sur les données de validation, traduisant une réduction continue des erreurs de classification.

Comme pour l'Accuracy, la courbe de validation présente quelques variations locales au cours de l'apprentissage. Toutefois, ces oscillations restent limitées et la tendance globale demeure clairement décroissante. La proximité entre les courbes d'entraînement et de validation indique que le modèle ne présente pas de phénomène marqué de surapprentissage. Les mécanismes de régularisation intégrés dans l'architecture, notamment les couches Batch Normalization et Dropout, ainsi que les callbacks Early Stopping et Reduce Learning Rate on Plateau, ont probablement contribué à maintenir un apprentissage stable tout en améliorant les capacités de généralisation du réseau.

L'analyse conjointe des courbes d'Accuracy et de Loss montre ainsi que le modèle CNN converge progressivement vers une solution stable. L'amélioration régulière de la précision, accompagnée d'une diminution continue de la fonction de perte, témoigne d'un apprentissage efficace des caractéristiques discriminantes présentes dans les images IRM. Les résultats obtenus indiquent que le modèle est capable de produire des prédictions cohérentes tout en conservant un bon équilibre entre les performances d'entraînement et celles de validation. Cette première analyse sera complétée dans les sections suivantes par l'étude de la matrice de

confusion, des courbes ROC et des différentes métriques de classification, qui permettront d'évaluer plus précisément la qualité des prédictions réalisées pour chacune des trois classes.

### 3.3.2 Matrice de confusion

La matrice de confusion constitue un outil d'évaluation permettant d'analyser les performances du modèle de classification pour chacune des classes étudiées. Contrairement à l'Accuracy globale, qui fournit une mesure générale des performances, cette matrice met en évidence le nombre de prédictions correctes ainsi que les erreurs de classification réalisées entre les différentes catégories. Elle permet ainsi d'identifier les classes les mieux reconnues par le modèle et celles qui présentent davantage de confusions.

La Figure 3.5 présente la matrice de confusion obtenue après l'évaluation du modèle CNN sur l'ensemble des données de test.




Figure 3.5 : Matrice de confusion

Les valeurs situées sur la diagonale principale correspondent aux images correctement classifiées par le modèle. On observe que 592 images appartenant à la classe AD, 772 de la classe MCI et 712 de la classe CN ont été correctement reconnues. Ces résultats montrent que le réseau de neurones est capable d'identifier efficacement les caractéristiques discriminantes propres à chacune des trois catégories d'images IRM cérébrales.

En revanche, certaines erreurs de classification sont observées en dehors de la diagonale principale. La confusion la plus importante concerne les classes AD et MCI. En effet, 120 images appartenant réellement à la classe AD ont été prédites comme MCI, tandis que 84 images de la classe MCI ont été classées comme AD. Cette confusion peut s'expliquer par la proximité des altérations anatomiques observées chez les patients atteints de la maladie d'Alzheimer et ceux présentant un Mild Cognitive Impairment (MCI). Ces deux stades partagent en effet plusieurs caractéristiques morphologiques, ce qui rend leur distinction plus difficile, notamment aux phases précoces de la maladie.



Les erreurs impliquant la classe CN sont, en revanche, moins nombreuses. Seules 37 images de la classe AD ont été classées comme CN, 43 images CN ont été prédites comme AD, 21 images MCI ont été classées comme CN et seulement 6 images CN ont été identifiées comme MCI. Ces faibles taux de confusion indiquent que le modèle parvient à distinguer de manière satisfaisante les sujets cognitivement normaux des patients présentant une atteinte neurodégénérative.

Dans l'ensemble, la forte concentration des valeurs sur la diagonale principale traduit une bonne capacité de classification du modèle. Les erreurs observées concernent essentiellement les classes AD et MCI, ce qui est cohérent avec les observations rapportées dans la littérature, où ces deux catégories sont fréquemment les plus difficiles à différencier en raison de la progression graduelle de la maladie d'Alzheimer.

Dans l'ensemble, la matrice de confusion met en évidence une forte concentration des valeurs sur la diagonale principale, ce qui traduit une bonne qualité de classification. Les erreurs observées concernent principalement les classes AD et MCI, dont les frontières cliniques et les caractéristiques des images IRM sont généralement plus difficiles à différencier. Ces résultats confirment les bonnes performances du modèle CNN et complètent l'analyse réalisée à partir des courbes d'Accuracy et de Loss.

### 3.3.3 Courbe ROC et AUC

La Figure 3.6 présente les courbes ROC obtenues pour les trois classes Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN). La courbe ROC permet d'évaluer la capacité du modèle à distinguer correctement les différentes classes en représentant le taux de vrais positifs (*True Positive Rate*) en fonction du taux de faux positifs (*False Positive Rate*) pour différents seuils de décision. L'aire sous la courbe (AUC) constitue un indicateur synthétique de cette capacité de discrimination : plus sa valeur est proche de 1, meilleures sont les performances du modèle.

L'analyse de la Figure 3.6 montre que les trois courbes ROC se situent largement au-dessus de la diagonale représentant une classification aléatoire et se rapprochent rapidement du coin supérieur gauche du graphique. Cette observation traduit une excellente capacité du modèle à distinguer les différentes catégories d'images IRM avec un faible taux de faux positifs et un taux élevé de vrais positifs.

Les valeurs d'AUC obtenues confirment ces bonnes performances. La classe CN présente la meilleure capacité de discrimination avec une AUC de 0,987, suivie de la classe MCI (0,967) puis de la classe AD (0,955). Bien que la classe AD affiche une valeur légèrement inférieure à celles des deux autres classes, son AUC reste largement supérieure à 0,90, ce qui traduit un excellent pouvoir discriminant du modèle.

Les différences observées entre les trois courbes demeurent relativement faibles, ce qui indique que le modèle présente un comportement homogène sur l'ensemble des classes étudiées. Les performances légèrement supérieures obtenues pour la classe CN sont cohérentes avec les résultats observés dans la matrice de confusion, où cette catégorie présentait le plus faible nombre d'erreurs de classification.



Dans l'ensemble, les courbes ROC et les valeurs d'AUC confirment les performances déjà mises en évidence par les courbes d'apprentissage et la matrice de confusion. Elles montrent que le modèle CNN possède une excellente capacité à discriminer les trois stades cognitifs étudiés, ce qui confirme sa pertinence pour la classification automatique des images IRM dans le cadre du diagnostic assisté de la maladie d'Alzheimer.




Figure 3.6 : Courbe ROC

### 3.3.4 Rapport de classification

Le rapport de classification permet d'évaluer les performances du modèle pour chacune des classes étudiées en s'appuyant sur plusieurs indicateurs complémentaires, notamment la précision (Precision), le rappel (Recall) et le F1-score. Ces métriques offrent une analyse plus détaillée que l'exactitude globale en mettant en évidence la qualité de la classification pour chaque catégorie d'images.

Les résultats présentés dans le Tableau 13 montrent que le modèle CNN obtient des performances satisfaisantes sur les trois classes. La meilleure performance est observée pour la classe CN, qui enregistre un F1-score de 0,93, accompagné d'une précision de 0,92 et d'un rappel de 0,94. Ces résultats indiquent que le modèle reconnaît avec une grande fiabilité les sujets cognitivement normaux et commet un nombre limité d'erreurs de classification pour cette catégorie.

La classe MCI présente également de très bonnes performances, avec un F1-score de 0,87. Cette classe représente généralement un défi important en raison de sa position intermédiaire entre les sujets sains et les patients atteints de la maladie d'Alzheimer. Malgré cette difficulté, le modèle parvient à identifier correctement la majorité des cas de déficience cognitive légère, ce qui témoigne de sa capacité à extraire des caractéristiques discriminantes pertinentes.

Les résultats obtenus pour la classe AD sont légèrement inférieurs à ceux des deux autres classes, avec un F1-score de 0,81. Cette différence peut être attribuée aux similitudes observées entre certaines images des classes AD et MCI, qui rendent leur séparation plus délicate. Néanmoins, les performances restent satisfaisantes et montrent que le modèle est capable de reconnaître efficacement les patients atteints de la maladie d'Alzheimer.

L'exactitude globale (Accuracy) atteint 87 %, tandis que les moyennes Macro Average et Weighted Average affichent également une valeur de 0,87 pour la précision, le rappel et le F1-score. La proximité de ces indicateurs traduit un comportement équilibré du modèle sur l'ensemble des classes et confirme que les performances ne sont pas dominées par une seule catégorie.

Ces résultats viennent renforcer les observations effectuées à partir des courbes d'apprentissage, de la matrice de confusion et des courbes ROC. L'ensemble des métriques montre que le modèle CNN offre une bonne capacité de classification des images IRM selon les trois catégories AD, MCI et CN, ce qui confirme son efficacité pour la détection des différents stades de la maladie d'Alzheimer.

Tableau 13. *Rapport de classification du modèle CNN*

| CLASSE           | PRECISION | RECALL | F1-SCORE | SUPPORT |
|------------------|-----------|--------|----------|---------|
| AD               | 0,82      | 0,79   | 0,81     | 749     |
| MCI              | 0,86      | 0,88   | 0,87     | 877     |
| CN               | 0,92      | 0,94   | 0,93     | 761     |
| ACCURACY         | -         | -      | 0,87     | 2387    |
| MACRO AVERAGE    | 0,87      | 0,87   | 0,87     | 2387    |
| WEIGHTED AVERAGE | 0,87      | 0,87   | 0,87     | 2387    |

### 3.3.5 Analyse des résultats

L'ensemble des résultats expérimentaux obtenus met en évidence les bonnes performances du modèle CNN développé dans le cadre de cette étude pour la classification des images IRM en trois catégories : Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN). Les différentes métriques d'évaluation montrent que le modèle est capable d'apprendre efficacement les caractéristiques discriminantes des images cérébrales et de les exploiter pour réaliser une classification fiable.

Les courbes d'apprentissage ont montré une évolution régulière de l'accuracy ainsi qu'une diminution progressive de la fonction de perte tout au long de l'entraînement. La faible différence observée entre les performances obtenues sur les ensembles d'entraînement et de

validation traduit une bonne capacité de généralisation du modèle et suggère l'absence de surapprentissage significatif. Cette stabilité est notamment favorisée par les techniques de régularisation mises en œuvre au cours de l'entraînement, telles que EarlyStopping et ReduceLROnPlateau, qui ont permis d'optimiser le processus d'apprentissage.

L'analyse de la matrice de confusion révèle que la majorité des images ont été correctement classifiées, les erreurs étant principalement concentrées entre les classes AD et MCI. Cette observation est cohérente avec les connaissances médicales, puisque le Mild Cognitive Impairment représente un stade intermédiaire entre le vieillissement cognitif normal et la maladie d'Alzheimer. Les similitudes anatomiques observées sur les images IRM rendent donc leur distinction plus complexe que celle impliquant la classe CN, qui présente le plus faible nombre de classifications erronées.

Les courbes ROC ainsi que les valeurs d'AUC confirment également la qualité du modèle. Les AUC obtenues, respectivement de 0,955 pour AD, 0,967 pour MCI et 0,987 pour CN, témoignent d'une excellente capacité de discrimination entre les différentes classes. Ces résultats indiquent que le modèle est capable de maintenir un taux élevé de vrais positifs tout en limitant le nombre de faux positifs, ce qui constitue un critère essentiel dans le contexte du diagnostic assisté par ordinateur.

Le rapport de classification confirme ces observations. Avec une Accuracy de 86,97 %, une Precision de 86,90 %, un Recall de 86,97 % et un F1-score de 86,92 %, le modèle présente des performances équilibrées sur l'ensemble des classes. La proximité entre ces différentes métriques traduit une bonne stabilité du classificateur et montre que les performances ne sont pas obtenues au détriment d'une classe particulière.

Dans l'ensemble, ces résultats démontrent que le CNN proposé constitue une base de référence performante pour la classification des images IRM liées à la maladie d'Alzheimer. Malgré les confusions observées entre les classes AD et MCI, les performances obtenues restent élevées et confirment la capacité du modèle à extraire automatiquement des caractéristiques pertinentes à partir des images cérébrales. Les résultats obtenus serviront de référence pour la comparaison avec les architectures de Transfer Learning, MobileNetV2 et EfficientNetB0, présentées dans les sections suivantes. Cette comparaison permettra d'identifier le modèle offrant le meilleur compromis entre précision, robustesse et efficacité computationnelle.

Le modèle présentant les meilleures performances fera ensuite l'objet d'une analyse d'interprétabilité à l'aide de la méthode Grad-CAM, afin de mettre en évidence les régions des images IRM ayant le plus influencé ses prédictions.

### 3.4 Résultats expérimentaux de MobileNetV2

Après l'entraînement du modèle MobileNetV2 sur les images IRM, plusieurs indicateurs ont été utilisés afin d'évaluer ses performances. L'analyse repose sur les courbes d'Accuracy et de Loss, la matrice de confusion, la courbe ROC accompagnée de l'aire sous la courbe (AUC), ainsi que le rapport de classification. Ces résultats permettent d'évaluer la qualité de l'apprentissage du modèle, sa capacité de généralisation et ses performances pour la classification des trois classes étudiées : AD, MCI et CN.

### 3.4.1 Courbes Accuracy et Loss

Les courbes présentées dans les Figures 3.7 et 3.98 illustrent l'évolution de la précision (Accuracy) et de la fonction de perte (Loss) du modèle MobileNetV2 au cours des différentes époques d'entraînement. Elles permettent d'observer le comportement du modèle pendant la phase d'apprentissage ainsi que sa capacité à généraliser sur les données de validation.




Figure 3.7 : Évolution de l'Accuracy du modèle MobileNetV2

La Figure 3.7 montre une augmentation progressive de l'accuracy sur l'ensemble d'entraînement. La précision passe d'environ 40 % lors de la première époque à près de 85 % à la fin de l'entraînement. Cette évolution traduit un apprentissage continu des caractéristiques discriminantes des images IRM, permettant au modèle d'améliorer progressivement ses performances de classification.

L'accuracy de validation présente également une progression régulière tout au long de l'entraînement. Après une augmentation rapide durant les premières époques, elle continue de croître jusqu'à atteindre une valeur proche de 91 %. Les courbes d'entraînement et de validation restent relativement proches, sans écart important, ce qui indique que le modèle conserve une bonne capacité de généralisation sur les données non utilisées pendant l'apprentissage. Les légères fluctuations observées sur la courbe de validation sont limitées et restent compatibles avec les variations habituellement observées lors de l'entraînement des réseaux de neurones profonds.




Figure 3.8 : Évolution de la fonction de perte (Loss) du modèle MobileNetV2

La Figure 3.8 présente l'évolution de la fonction de perte. La perte d'entraînement diminue progressivement d'environ 1,12 à 0,37, montrant que les erreurs de prédiction sont progressivement réduites au cours de l'apprentissage. Cette diminution régulière traduit une optimisation efficace des paramètres du modèle.

La perte de validation suit également une tendance décroissante, passant d'environ 0,98 au début de l'entraînement à près de 0,26 lors de la dernière époque. Contrairement aux situations de surapprentissage où la perte de validation recommence à augmenter, la courbe observée continue de diminuer de manière régulière, ce qui indique que le modèle maintient de bonnes performances sur les données de validation.

L'analyse conjointe des courbes d'Accuracy et de Loss montre que le modèle MobileNetV2 converge progressivement vers une solution stable. L'augmentation continue de la précision, associée à la diminution régulière de la fonction de perte, confirme que le réseau apprend efficacement les caractéristiques des images IRM tout en conservant une bonne capacité de généralisation. Ces résultats constituent une première indication des bonnes performances du modèle, qui seront ensuite confirmées par l'analyse de la matrice de confusion, de la courbe ROC et du rapport de classification dans les sections suivantes.

### 3.4.2 Matrice de confusion

La matrice de confusion présentée dans la Figure 3.9 permet d'évaluer en détail les performances du modèle MobileNetV2 en comparant les classes réelles aux classes prédites. Les éléments situés sur la diagonale principale correspondent aux images correctement classifiées, tandis que les valeurs situées en dehors de cette diagonale représentent les erreurs de classification.




Figure 3.9 : Matrice de confusion du modèle MobileNetV2.

Celui-ci a correctement classé 649 images AD, 815 images MCI et 703 images CN, ce qui montre sa capacité à distinguer efficacement les différentes catégories.

Les erreurs de classification restent relativement limitées et concernent principalement les classes AD et MCI. En effet, 63 images AD ont été classées comme MCI, tandis que 43 images MCI ont été prédites comme AD. Cette confusion peut s'expliquer par les similitudes anatomiques existant entre ces deux stades de la maladie, les patients atteints d'un trouble cognitif léger présentant parfois des caractéristiques proches de celles observées chez les patients atteints de la maladie d'Alzheimer.

Les confusions impliquant la classe CN sont moins fréquentes. Le modèle a classé 37 images AD et 19 images MCI comme CN, tandis que 32 images CN ont été prédites comme AD et 26 images CN comme MCI. Ces résultats montrent que les sujets cognitivement normaux sont généralement bien distingués des patients présentant une atteinte neurodégénérative.

Dans l'ensemble, la forte concentration des valeurs sur la diagonale principale traduit une bonne capacité de classification de MobileNetV2. Les erreurs observées restent principalement localisées entre les classes AD et MCI, qui représentent les catégories les plus difficiles à différencier en raison de la proximité de leurs caractéristiques cérébrales sur les images IRM.

### 3.4.3 Courbe ROC et AUC

Afin d'évaluer la capacité discriminante du modèle MobileNetV2, une analyse des courbes ROC (Receiver Operating Characteristic) a été réalisée pour chacune des trois classes étudiées (AD, MCI et CN). Contrairement aux indicateurs classiques de performance tels que l'accuracy, la courbe ROC permet d'apprécier le comportement du modèle pour différents seuils de décision en mettant en relation le taux de vrais positifs (True Positive Rate) et le taux de faux positifs (False Positive Rate). L'aire située sous cette courbe (AUC – Area Under the Curve) constitue

un indicateur synthétique de la capacité du modèle à distinguer correctement les différentes classes. Plus sa valeur est proche de 1 plus les performances de classification sont élevées.




Figure 3.10 : Courbe ROC

Les résultats obtenus mettent en évidence d'excellentes capacités de discrimination pour l'ensemble des catégories étudiées. Les trois courbes ROC se situent largement au-dessus de la diagonale représentant un classificateur aléatoire ( $AUC = 0,5$ ) et se rapprochent rapidement du coin supérieur gauche du graphique. Cette configuration traduit simultanément un taux élevé de vrais positifs et un faible taux de faux positifs, confirmant ainsi l'efficacité du modèle dans la reconnaissance des différentes catégories d'images IRM.

Pour la classe AD (Alzheimer's Disease), le modèle obtient une valeur d'AUC de 0,977, ce qui traduit une excellente capacité à distinguer les patients atteints de la maladie d'Alzheimer des autres catégories. Bien que cette valeur soit légèrement inférieure à celles des deux autres classes, elle demeure très élevée et confirme la robustesse du modèle pour cette tâche de classification.

Concernant la classe MCI (Mild Cognitive Impairment), une AUC de 0,985 est obtenue. Ce résultat est particulièrement satisfaisant puisque cette catégorie correspond à un stade intermédiaire de la maladie, dont les caractéristiques anatomiques sont souvent proches de celles des patients atteints d'Alzheimer ou des sujets cognitivement normaux. Malgré cette difficulté, MobileNetV2 parvient à maintenir un excellent niveau de discrimination.

La meilleure performance est observée pour la classe CN (Cognitively Normal), avec une AUC de 0,991. Cette valeur, très proche de 1, indique que le modèle identifie avec une très grande précision les sujets ne présentant pas de déficit cognitif, tout en limitant les erreurs de classification.

Dans l'ensemble, les valeurs d'AUC obtenues pour les trois classes sont toutes supérieures à 0,97, ce qui témoigne de l'excellent pouvoir discriminant de MobileNetV2. Ces résultats

confirment que les caractéristiques extraites par le réseau permettent une séparation efficace entre les différentes catégories d'images IRM. Cette analyse complète les observations issues des courbes d'Accuracy, de Loss et de la matrice de confusion, en confirmant la fiabilité du modèle pour la classification des trois catégories étudiées (AD, MCI et CN).

#### 3.4.4 Rapport de classification

Afin d'évaluer plus précisément les performances du modèle MobileNetV2, un rapport de classification a été généré. Contrairement à l'accuracy globale, qui fournit une mesure générale des performances, ce rapport permet d'analyser séparément chaque classe à l'aide de la précision (Precision), du rappel (Recall) et du score F1 (F1-score). Ces indicateurs offrent une évaluation détaillée de la capacité du modèle à reconnaître correctement chacune des trois catégories étudiées (AD, MCI et CN).

Les résultats obtenus montrent que le modèle atteint une accuracy globale de 91 %, ce qui confirme les bonnes performances déjà observées à travers les courbes d'apprentissage, la matrice de confusion et la courbe ROC. Cette valeur indique que la grande majorité des images IRM a été correctement classifiée.

Pour la classe AD (Alzheimer's Disease), le modèle obtient une précision de 0,90, un rappel de 0,87 et un score F1 de 0,88. Ces résultats montrent que le modèle identifie correctement la majorité des patients atteints de la maladie d'Alzheimer, même si quelques images de cette classe sont encore confondues avec les autres catégories.

La classe MCI (Mild Cognitive Impairment) présente une précision de 0,90, un rappel de 0,93 et un score F1 de 0,92. Le rappel élevé traduit une excellente capacité du modèle à détecter les patients présentant un trouble cognitif léger, malgré la proximité de cette classe avec les deux autres.

Concernant la classe CN (Cognitively Normal), le modèle obtient une précision de 0,93, un rappel de 0,92 et un score F1 de 0,93. Ces résultats montrent que les sujets cognitivement normaux sont reconnus avec une très grande fiabilité, le modèle limitant efficacement les erreurs de classification pour cette catégorie.

Les moyennes macro et pondérée (weighted average) atteignent toutes deux 0,91 pour la précision, le rappel et le score F1. La similitude entre ces deux moyennes indique que les performances du modèle sont homogènes sur l'ensemble des classes et qu'aucune catégorie n'est favorisée au détriment des autres.

Dans l'ensemble, le rapport de classification confirme la robustesse de MobileNetV2 pour la classification des images IRM. Les valeurs élevées de la précision, du rappel et du score F1, associées à une accuracy globale de 91 %, montrent que le modèle est capable de distinguer efficacement les trois catégories (AD, MCI et CN) tout en maintenant un bon équilibre entre



sensibilité et précision. Ces résultats confirment les performances observées précédemment à travers la matrice de confusion et la courbe ROC.

Tableau 14. *Rapport de classification du modèle MobileNetV2*

| CLASSE              | PRECISION | RECALL | F1-SCORE | SUPPORT |
|---------------------|-----------|--------|----------|---------|
| AD                  | 0,90      | 0,87   | 0,88     | 749     |
| MCI                 | 0,90      | 0,93   | 0,92     | 877     |
| CN                  | 0,93      | 0,92   | 0,93     | 761     |
| ACCURACY            | -         | -      | 0,91     | 2387    |
| MACRO L<br>AVERAGE  | 0,9       | 0,91   | 0,91     | 2387    |
| WEIGHTED<br>AVERAGE | 0,91      | 0,91   | 0,91     | 2387    |

### 3.4.5 Analyse des résultats

L'ensemble des résultats expérimentaux obtenus met en évidence les très bonnes performances de MobileNetV2 pour la classification des images IRM en trois catégories : Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN). Les différentes métriques d'évaluation montrent que le modèle apprend efficacement les caractéristiques discriminantes des images cérébrales et fournit des prédictions fiables sur le jeu de test. Ces résultats confirment l'intérêt du Transfer Learning dans le domaine de l'imagerie médicale, où les jeux de données sont généralement limités.

Les courbes d'apprentissage montrent une augmentation progressive de l'accuracy au cours des différentes époques d'entraînement. Parallèlement, les courbes de perte (Loss) diminuent régulièrement, traduisant une convergence stable du modèle. L'évolution des courbes d'entraînement et de validation reste cohérente, sans écart important entre les deux ensembles, ce qui indique une bonne capacité de généralisation et l'absence de surapprentissage significatif.

L'analyse de la matrice de confusion confirme également la qualité de la classification. La majorité des prédictions est concentrée sur la diagonale principale, avec 649 images correctement classifiées pour la classe AD, 815 pour la classe MCI et 703 pour la classe CN. Les principales erreurs de classification concernent les classes AD et MCI, avec 63 images AD prédites comme MCI et 43 images MCI classifiées comme AD, ce qui s'explique par les similitudes anatomiques entre ces deux stades de la maladie. Les confusions impliquant la classe CN restent relativement limitées (37 images AD classées comme CN, 19 images MCI classées comme CN, 32 images CN prédites comme AD et 26 comme MCI), montrant que le

modèle distingue efficacement les sujets cognitivement normaux des patients atteints de troubles neurodégénératifs.

Les courbes ROC mettent également en évidence l'excellente capacité de discrimination du modèle. Les trois courbes se situent largement au-dessus de la diagonale représentant une classification aléatoire et se rapprochent rapidement du coin supérieur gauche du graphique, traduisant un taux élevé de vrais positifs associé à un faible taux de faux positifs. Les valeurs de l'aire sous la courbe (AUC) atteignent 0,977 pour la classe AD, 0,985 pour la classe MCI et 0,991 pour la classe CN. Ces valeurs, toutes très proches de 1, confirment l'excellente aptitude de MobileNetV2 à distinguer les trois catégories d'images IRM étudiées.

Le rapport de classification confirme ces observations avec une accuracy globale de 91 %. La classe AD obtient une précision de 90 %, un rappel de 87 % et un score F1 de 88 %, montrant que la majorité des patients atteints de la maladie d'Alzheimer sont correctement identifiés malgré quelques confusions avec la classe MCI. La classe MCI présente une précision de 90 %, un rappel de 93 % et un score F1 de 92 %, traduisant une excellente capacité du modèle à reconnaître ce stade intermédiaire de la maladie. La classe CN obtient les meilleures performances avec une précision de 93 %, un rappel de 92 % et un score F1 de 93 %, ce qui montre que les sujets cognitivement normaux sont identifiés avec une grande fiabilité. Les moyennes macro et pondérée, toutes deux égales à 0,91, confirment la stabilité et l'homogénéité des performances sur l'ensemble des classes.

Comparativement au modèle CNN développé précédemment, MobileNetV2 obtient des performances supérieures, aussi bien en termes d'accuracy que de capacité de discrimination. Cette amélioration s'explique par l'utilisation du Transfer Learning, qui permet d'exploiter les connaissances acquises lors du pré-entraînement sur ImageNet afin d'extraire des caractéristiques plus représentatives des images IRM. Cette approche améliore la qualité de la classification tout en réduisant le temps d'entraînement et le nombre de paramètres à optimiser.

Dans l'ensemble, les résultats obtenus démontrent que MobileNetV2 constitue une architecture performante et robuste pour la classification automatique des images IRM dans le cadre de la détection de la maladie d'Alzheimer. Son excellent compromis entre précision, capacité de généralisation et faible complexité computationnelle en fait une solution particulièrement adaptée aux systèmes d'aide au diagnostic assisté par intelligence artificielle. Les performances obtenues serviront de référence pour la comparaison avec le modèle CNN présentée dans la section suivante.

### 3.6 Comparaison des modèles

Après avoir analysé individuellement les performances du modèle CNN et de MobileNetV2, il est nécessaire de réaliser une comparaison globale afin d'identifier l'architecture la plus adaptée à la classification des images IRM cérébrales. Cette comparaison repose sur plusieurs critères quantitatifs, notamment les performances de classification (Accuracy, Precision, Recall, F1-score et AUC), le temps d'entraînement ainsi que le nombre de paramètres. L'objectif est

d'évaluer non seulement la qualité des prédictions, mais également la complexité de chaque architecture et son coût computationnel.

### 3.6.1 Comparaison quantitative

Le tableau 15 présente une comparaison des performances obtenues par les deux modèles étudiés. Les résultats montrent que MobileNetV2 surpasse le CNN sur l'ensemble des métriques de classification.

Tableau 15. *Comparaison des performances*

| CRITÈRE                        | CNN     | MOBILENETV2 |
|--------------------------------|---------|-------------|
| ACCURACY                       | 87 %    | 91 %        |
| PRECISION                      | 0,87    | 0,91        |
| RECALL                         | 0,87    | 0,91        |
| F1-SCORE                       | 0,87    | 0,91        |
| AUC                            | 0,970   | 0,984       |
| TEMPS<br>D'ENTRAÎNEMENT<br>(S) | —       | 15 233      |
| NOMBRE DE<br>PARAMÈTRES        | 111 171 | 2 613 827   |

En termes d'accuracy, MobileNetV2 atteint 91 %, contre 87 % pour le CNN, soit une amélioration de 4 points de pourcentage. Cette différence montre que l'utilisation du Transfer Learning permet au modèle d'extraire des caractéristiques plus représentatives des images IRM, améliorant ainsi la qualité de la classification.

Les métriques de Precision, Recall et F1-score confirment cette tendance. Alors que le CNN obtient une valeur moyenne de 0,87 pour chacun de ces indicateurs, MobileNetV2 atteint 0,91, traduisant une meilleure capacité à reconnaître correctement les différentes classes tout en réduisant les erreurs de classification.

La comparaison des valeurs de l'AUC met également en évidence les meilleures performances de MobileNetV2. Avec une valeur de 0,984, contre 0,970 pour le CNN, le modèle présente une meilleure capacité à distinguer les trois catégories d'images IRM (AD, MCI et CN). Les courbes ROC obtenues précédemment confirment cette excellente capacité de discrimination.

En revanche, cette amélioration des performances s'accompagne d'une augmentation de la complexité du modèle. Le CNN comporte 111 171 paramètres, tandis que MobileNetV2 en possède 2 613 827, soit un nombre de paramètres nettement plus élevé. Cette différence explique également un temps d'entraînement plus important pour MobileNetV2, qui nécessite environ 15 233 secondes pour compléter son apprentissage.

Malgré cette complexité supplémentaire, les résultats montrent que MobileNetV2 offre le meilleur compromis entre précision et capacité de généralisation. L'exploitation des

connaissances acquises lors du pré-entraînement permet d'améliorer significativement les performances de classification, faisant de MobileNetV2 une architecture particulièrement adaptée à la détection automatique de la maladie d'Alzheimer à partir des images IRM.

### 3.6.2 Comparaison graphique

Les figures suivantes permettent de visualiser les différences de performances entre le modèle CNN développé à partir de zéro et le modèle MobileNetV2 basé sur le Transfer Learning. Cette représentation graphique facilite l'interprétation des différents indicateurs de performance.




Figure 3.11 : Accuracy Comparaison

La Figure 3.11 montre que MobileNetV2 obtient une accuracy supérieure à celle du CNN. Alors que le CNN atteint une précision globale de 87 %, MobileNetV2 atteint 91 %, soit un gain de 4 points de pourcentage. Cette amélioration traduit une meilleure capacité de généralisation du modèle pré-entraîné, qui extrait des caractéristiques plus pertinentes des images IRM grâce au Transfer Learning.




Figure 3.12 : Precision Comparaison

La Figure 3.12 met en évidence une amélioration de la précision avec MobileNetV2. Le CNN obtient une Précision moyenne de 0,87, tandis que MobileNetV2 atteint 0,91. Cette progression indique que le nombre de faux positifs est réduit avec MobileNetV2, ce qui améliore la fiabilité des prédictions et limite les erreurs de classification.




Figure 3.13: Recall Comparaison

Comme l'illustre la Figure 3.13, MobileNetV2 présente également un meilleur Recall (0,91) que le CNN (0,87). Cette différence montre que MobileNetV2 détecte un plus grand nombre d'images appartenant réellement aux différentes classes, réduisant ainsi le nombre de faux négatifs. Cette propriété est particulièrement importante dans le contexte médical, où il est essentiel de ne pas manquer des patients atteints de la maladie.




Figure 3.14 : F1-score Comparaison

La Figure 3.14 montre que le F1-score passe de 0,87 pour le CNN à 0,91 pour MobileNetV2. Cette amélioration traduit un meilleur équilibre entre la précision et le rappel. Elle confirme que MobileNetV2 est plus performant pour reconnaître correctement les trois catégories d'IRM tout en limitant les erreurs de classification.




Figure 3.15 : AUC Comparaison

La Figure 3.15 compare les valeurs de l'aire sous la courbe ROC (AUC). Le CNN obtient une AUC moyenne de 0,970, tandis que MobileNetV2 atteint 0,984. Les deux modèles présentent un excellent pouvoir discriminant, mais MobileNetV2 se rapproche davantage de la valeur idéale (AUC = 1), ce qui traduit une meilleure capacité à distinguer les classes AD, MCI et CN.



Figure 3.16 : Training Time Comparaison

La Figure 3.16 présente le temps total d'entraînement de MobileNetV2. Celui-ci est d'environ 15 300 secondes (près de 4 h 15 min). Bien que ce temps soit plus important que celui du CNN en raison de la complexité de l'architecture et du nombre plus élevé de paramètres (2,61 millions contre environ 108 mille pour le CNN), ce coût supplémentaire est compensé par une amélioration significative des performances de classification. MobileNetV2 offre ainsi un meilleur compromis entre précision et robustesse pour la détection des stades de la maladie d'Alzheimer.

### 3.6.3 Comparaison avec les travaux de la littérature

Le Tableau 16 compare les performances obtenues dans cette étude avec plusieurs travaux récents portant sur la classification de la maladie d'Alzheimer à partir d'images IRM. Tous les travaux retenus utilisent le jeu de données ADNI, ce qui permet une comparaison plus pertinente des résultats.

Tableau 16. *Comparaison avec les travaux existants*

| Référence                                                               | Modèle                          | Accuracy | Dataset |
|-------------------------------------------------------------------------|---------------------------------|----------|---------|
| <b>Payan et Montana (2015) [13]</b>                                     | CNN 3D +<br>Autoencodeur        | 89,47 %  | ADNI    |
| <b>Ghosh, Palash, Yousuf, Hamid, Monowar &amp; Alassafi (2023) [31]</b> | MobileNet<br>(approche fédérée) | 81,94%   | ADNI    |
| <b>Bricaud &amp; Masala (2026) [17]</b>                                 | MobileNetV2                     | 69,31%   | ADNI    |
| <b>Notre travail</b>                                                    | MobileNetV2                     | 91,00 %  | ADNI    |

Le tableau ci-dessus présente une comparaison entre plusieurs travaux de recherche portant sur la détection de la maladie d'Alzheimer à partir des images IRM en utilisant la base de données ADNI.

Les résultats montrent que les performances varient selon les modèles employés. Par exemple, le modèle CNN 3D associé à un Autoencodeur, proposé par Payan et Montana (2015), atteint une précision de 89,47 %, tandis que l'approche fédérée basée sur MobileNet de Ghosh et al. (2023) obtient 81,94 %. Plus récemment, Bricaud et Masala (2026) ont utilisé MobileNetV2 et obtenu une précision de 69,31 %.

Dans le cadre de notre travail, nous avons également adopté MobileNetV2, qui a permis d'atteindre une précision de 91,00 % sur la base de données ADNI. Ce résultat est supérieur à ceux des travaux comparés, ce qui montre l'efficacité de notre approche pour la classification des images IRM dans le cadre de la détection précoce de la maladie d'Alzheimer.



## 3.7 Interprétabilité du modèle (Grad-CAM)

### 3.7.1 Principe de Grad-CAM

Bien que les modèles de Deep Learning offrent des performances élevées en classification d'images médicales, ils sont souvent considérés comme des boîtes noires, car il est difficile de comprendre les éléments ayant conduit à une décision de classification. Dans le domaine médical, cette absence d'explicabilité peut limiter la confiance des professionnels de santé envers les systèmes d'intelligence artificielle.

Afin d'améliorer l'interprétabilité du modèle proposé, la méthode Gradient-weighted Class Activation Mapping (Grad-CAM) a été utilisée. Cette technique permet de visualiser les régions de l'image qui ont le plus influencé la prédiction du réseau de neurones [75].

Le principe de Grad-CAM consiste à calculer les gradients de la classe prédite par rapport aux cartes de caractéristiques de la dernière couche convolutionnelle du réseau. Ces gradients sont ensuite utilisés pour pondérer les cartes d'activation, produisant une carte thermique (Heatmap) mettant en évidence les zones les plus importantes pour la décision du modèle. Enfin, cette carte est superposée à l'image IRM originale afin de faciliter l'interprétation visuelle des résultats.

L'utilisation de Grad-CAM permet ainsi de vérifier que le modèle prend sa décision en se basant sur des structures anatomiques pertinentes plutôt que sur des régions sans intérêt clinique.




Figure 3.17: Image IRM originale

La Figure 3.17 présente l'image IRM originale utilisée comme entrée du modèle. Cette image correspond à une coupe sagittale du cerveau sur laquelle le réseau effectue la prédiction.




Figure 3.18: Carte thermique (Heatmap) générée par Grad-CAM

La Figure 3.18 montre la carte thermique (Heatmap) générée par Grad-CAM. Les différentes couleurs représentent le niveau de contribution des régions de l'image à la décision du modèle. Les zones apparaissant en rouge et en jaune correspondent aux régions ayant exercé la plus forte influence sur la prédiction, tandis que les zones en bleu et en vert traduisent une faible contribution.




Figure 3.19 : Superposition (Overlay) de la carte thermique sur l'image IRM

Enfin, la Figure 3.19 présente la superposition (Overlay) de la carte thermique sur l'image IRM originale. Cette représentation permet de visualiser simultanément les structures anatomiques du cerveau et les régions sur lesquelles MobileNetV2 s'est principalement concentré lors de la classification. On observe que les activations importantes se situent majoritairement au niveau de la région cérébrale, ce qui montre que le modèle exploite les informations présentes dans le cerveau plutôt que les zones situées en arrière-plan de l'image.

### 3.7.3 Analyse des cartes d'activation

L'analyse des cartes d'activation générées par Grad-CAM permet de mieux comprendre le processus de décision adopté par le modèle MobileNetV2 lors de la classification des images

IRM. Contrairement aux métriques quantitatives, cette approche offre une interprétation visuelle des régions ayant le plus contribué à la prédiction.

Sur la Figure 3.19, les zones représentées en rouge et en jaune correspondent aux régions auxquelles le modèle a accordé la plus grande importance pour établir sa décision, tandis que les zones en bleu et en vert présentent une contribution plus faible. Les activations les plus marquées sont principalement localisées dans la région cérébrale visible sur l'image IRM, ce qui indique que le modèle s'appuie sur les informations anatomiques du cerveau plutôt que sur les zones situées en arrière-plan.

Cette observation constitue un résultat important, car elle montre que le réseau de neurones apprend à exploiter les caractéristiques présentes dans les images médicales plutôt que des éléments parasites ou du bruit. L'utilisation de Grad-CAM permet ainsi de vérifier que les décisions du modèle reposent sur des régions pertinentes de l'image, ce qui renforce la crédibilité de ses prédictions.

Toutefois, il convient de souligner que Grad-CAM fournit une interprétation qualitative de la décision du modèle. Les cartes d'activation mettent en évidence les régions ayant influencé la classification, sans pour autant identifier précisément les biomarqueurs anatomiques associés à la maladie d'Alzheimer. Une interprétation clinique détaillée nécessite donc l'expertise d'un radiologue ou d'un neurologue.

Dans le cadre de cette étude, l'intégration de Grad-CAM apporte une dimension d'explicabilité au modèle MobileNetV2. En complément des performances quantitatives obtenues (Accuracy, Precision, Recall, F1-score et AUC), cette méthode permet de renforcer la confiance dans l'image IRM. Cette approche constitue un atout important pour le développement de systèmes d'aide au diagnostic assistés par intelligence artificielle, où la transparence des décisions est devenue un critère essentiel.

## 3.8 Discussion générale

### 3.8.1 Analyse comparative des modèles

Les expérimentations réalisées montrent que les deux architectures sont capables de classifier efficacement les images IRM cérébrales, mais leurs approches d'apprentissage diffèrent sensiblement. Le CNN développé dans cette étude apprend directement les caractéristiques discriminantes à partir du jeu de données disponible. Bien qu'il obtienne des performances satisfaisantes, son apprentissage dépend fortement de la quantité et de la diversité des données d'entraînement.

À l'inverse, MobileNetV2 exploite le principe du Transfer Learning, qui consiste à réutiliser des connaissances acquises lors d'un pré-entraînement sur une vaste base d'images. Cette stratégie permet au modèle d'extraire des représentations visuelles plus pertinentes et plus robustes, ce qui améliore sa capacité à distinguer les trois classes étudiées (AD, MCI et CN).

Les résultats obtenus montrent que cette architecture offre une meilleure stabilité de l'apprentissage ainsi qu'une meilleure capacité de généralisation sur les données de test.

L'utilisation de MobileNetV2 présente toutefois un coût computationnel plus important que celui du CNN en raison d'un nombre plus élevé de paramètres et d'un temps d'entraînement supérieur. Malgré cela, cette architecture reste beaucoup plus légère que de nombreux réseaux profonds classiques grâce aux Depthwise Separable Convolutions, qui réduisent considérablement les opérations de calcul tout en conservant un niveau élevé de précision.

Ainsi, le choix de MobileNetV2 apparaît comme un compromis intéressant entre performances de classification, robustesse du modèle et efficacité computationnelle, ce qui en fait une architecture particulièrement adaptée à la détection assistée par intelligence artificielle de la maladie d'Alzheimer à partir d'images IRM.

### 3.8.2 Avantages et limites

Les résultats obtenus montrent que les deux modèles présentent des caractéristiques complémentaires. Le CNN développé dans cette étude se distingue par sa simplicité architecturale et son faible nombre de paramètres, ce qui réduit le temps d'entraînement et facilite sa mise en œuvre. Toutefois, ses performances restent légèrement inférieures à celles de MobileNetV2, ce qui montre les limites d'un apprentissage réalisé uniquement à partir des données disponibles.

À l'inverse, MobileNetV2 bénéficie de l'approche Transfer Learning, qui lui permet d'exploiter des connaissances acquises lors de son pré-entraînement sur ImageNet. Cette stratégie améliore la qualité des caractéristiques extraites et favorise une meilleure capacité de généralisation, ce qui explique les performances supérieures obtenues sur le jeu de test. Malgré un nombre de paramètres plus élevé que le CNN, MobileNetV2 demeure une architecture légère et adaptée aux applications nécessitant des ressources de calcul limitées.

L'un des points forts de cette étude réside également dans l'intégration de Grad-CAM, qui apporte une interprétation visuelle des prédictions réalisées par le modèle. Cette méthode permet de vérifier que les décisions sont principalement fondées sur les régions cérébrales présentes dans les images IRM, ce qui renforce la transparence et la confiance dans le système proposé.

Néanmoins, certaines limites doivent être prises en compte. Les expérimentations ont été réalisées uniquement sur la base de données ADNI, ce qui ne permet pas de garantir les mêmes performances sur d'autres jeux de données ou dans un contexte clinique réel. De plus, les modèles ont été entraînés sur des coupes IRM 2D, alors que les examens médicaux sont naturellement tridimensionnels. Enfin, bien que Grad-CAM améliore l'interprétabilité des prédictions, les cartes d'activation fournissent une analyse qualitative qui doit être complétée par l'expertise d'un professionnel de santé.

### 3.8.3 Perspectives d'amélioration

Les résultats obtenus dans cette étude ouvrent plusieurs perspectives pour améliorer davantage le système proposé et étendre son domaine d'application.

Dans un premier temps, il serait intéressant d'évaluer EfficientNetB0 dans le cadre de la classification des images IRM de la maladie d'Alzheimer. Cette architecture, fondée sur le principe du *Compound Scaling*, optimise simultanément la profondeur, la largeur et la résolution du réseau. Une étude comparative entre MobileNetV2 et EfficientNetB0 permettrait de déterminer si cette architecture peut offrir un meilleur compromis entre précision, robustesse et coût computationnel.

Une deuxième perspective concerne l'utilisation des Vision Transformers (ViT), qui reposent sur un mécanisme d'attention permettant d'exploiter les relations globales entre les différentes régions d'une image. Ces architectures ont récemment démontré des performances prometteuses dans plusieurs applications d'imagerie médicale et pourraient constituer une alternative intéressante aux réseaux de neurones convolutifs.

Par ailleurs, le développement d'une application Web ou mobile intégrant le modèle MobileNetV2 représenterait une évolution importante de ce travail. Une telle application pourrait permettre aux professionnels de santé de charger une image IRM, d'obtenir automatiquement une prédiction et de visualiser les régions d'intérêt grâce à Grad-CAM, facilitant ainsi l'utilisation du système dans un contexte clinique.

Enfin, il serait pertinent de valider l'approche proposée sur d'autres bases de données médicales, telles que OASIS ou AIBL, afin d'évaluer la capacité de généralisation du modèle sur des données acquises dans des conditions différentes. Cette validation contribuerait à renforcer la robustesse du système et à confirmer son potentiel pour une utilisation dans des environnements cliniques variés.

## 3.9 Conclusion

Ce chapitre a présenté la mise en œuvre des modèles de Deep Learning ainsi que l'analyse des résultats obtenus pour la classification des images IRM cérébrales en trois catégories : Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN).

Les expérimentations ont permis de comparer un réseau de neurones convolutif (CNN) développé spécifiquement pour cette étude à une architecture de Transfer Learning basée sur MobileNetV2. Les résultats obtenus montrent que les deux modèles sont capables de classifier efficacement les images IRM, mais que MobileNetV2 offre les meilleures performances grâce à sa capacité à extraire des caractéristiques plus discriminantes tout en conservant une architecture légère.

L'analyse des courbes d'apprentissage, des matrices de confusion, des courbes ROC et des différents indicateurs d'évaluation (Accuracy, Precision, Recall, F1-score et AUC) a confirmé la robustesse et la capacité de généralisation du modèle MobileNetV2. Par ailleurs, l'utilisation de Grad-CAM a permis d'améliorer l'interprétabilité des prédictions en mettant en évidence les régions des images ayant le plus influencé les décisions du modèle.

Enfin, la discussion des résultats a permis d'identifier les principaux avantages et les limites de l'approche proposée, tout en présentant plusieurs perspectives d'amélioration, notamment l'évaluation d'architectures plus récentes telles qu'EfficientNetB0 et les Vision Transformers (ViT), le développement d'une application Web ou mobile ainsi que la validation du modèle sur d'autres bases de données médicales.

Dans l'ensemble, les résultats obtenus montrent que l'approche proposée constitue une solution prometteuse pour la détection assistée de la maladie d'Alzheimer à partir d'images IRM, en combinant de bonnes performances de classification et une meilleure interprétabilité des décisions grâce aux techniques d'intelligence artificielle explicable.

## CONCLUSION ET PERSPECTIVE

Ce travail a permis de mettre en évidence l'intérêt des techniques de Deep Learning pour le développement d'outils d'aide au diagnostic de la maladie d'Alzheimer à partir d'images IRM. Les résultats obtenus montrent qu'il est possible de concevoir un système capable d'identifier efficacement les différents stades de la maladie tout en offrant un bon compromis entre performances de classification, coût de calcul et interprétabilité.

Au-delà des performances obtenues, cette étude souligne également l'importance d'intégrer des méthodes d'explicabilité dans les systèmes d'intelligence artificielle appliqués au domaine médical. En effet, la visualisation des régions cérébrales ayant contribué aux décisions du modèle constitue un élément essentiel pour renforcer la confiance des professionnels de santé et favoriser l'acceptation de ces outils dans la pratique clinique.

Les résultats obtenus restent néanmoins liés aux conditions expérimentales retenues dans cette étude. L'utilisation d'une seule base de données et d'images IRM bidimensionnelles ne permet pas de couvrir toute la diversité des situations rencontrées en pratique. De plus, même si les performances sont encourageantes, un système d'intelligence artificielle ne peut se substituer à l'expertise médicale ; il doit être considéré comme un outil d'assistance destiné à accompagner le spécialiste dans sa prise de décision.

Dans cette perspective, plusieurs prolongements peuvent être envisagés. L'évaluation d'architectures plus récentes, telles qu'**EfficientNetB0**, permettrait d'étudier leur contribution à l'amélioration des performances de classification. L'intégration de **Vision Transformers (ViT)** représente également une piste prometteuse pour exploiter plus efficacement les informations présentes dans les images IRM. Par ailleurs, la validation de l'approche sur d'autres bases de données médicales, ainsi que son déploiement sous forme d'une application Web ou mobile, constitueraient des étapes importantes vers une utilisation dans un environnement clinique réel.

En définitive, ce travail confirme que l'association du Deep Learning et de l'intelligence artificielle explicable représente une approche prometteuse pour le développement de systèmes d'aide au diagnostic de la maladie d'Alzheimer. Si de nombreux défis restent à relever avant une intégration complète dans la pratique médicale, les résultats obtenus montrent que ces technologies disposent d'un potentiel réel pour accompagner les professionnels de santé et contribuer, à terme, à une prise en charge plus précoce et plus efficace des patients.

## Références

### Bibliographie :

|      |                                                                                                                     |
|------|---------------------------------------------------------------------------------------------------------------------|
| [3]  | 3D CNN Design for the Classification of Alzheimer's Disease Using Brain MRI and PET                                 |
| [5]  | Alzheimer's Disease Diagnostics by a Deeply Supervised Adaptable 3D Convolutional Network                           |
| [6]  | Automated Identification of Dementia Using Medical Imaging: A Survey from a Pattern Classification Perspective      |
| [9]  | Artificial Intelligence for Alzheimer's Disease                                                                     |
| [10] | Imagerie cérébrale et maladie d'Alzheimer (article du Bulletin de l'Académie Nationale de Médecine)                 |
| [11] | DeepAD: Alzheimer's Disease Classification via Deep Convolutional Neural Networks Using MRI and Fmri                |
| [13] | Predicting Alzheimer's Disease: A Neuroimaging Study with 3D Convolutional Neural Networks                          |
| [14] | Deep Learning-Based Alzheimer's Disease Detection Using MRI: A Review                                               |
| [15] | Early Detection of Alzheimer's Disease Based on the State-of-the-Art Deep Learning Approach: A Comprehensive Survey |
| [20] | Convolutional Neural Network Image Segmentation of Alzheimer's Disease Based on Multi-Order 3D U-Net                |

### webographie :

| RÉF. | SOURCE                                                                    | LIEN                                                                        |
|------|---------------------------------------------------------------------------|-----------------------------------------------------------------------------|
| [31] | National Institute on Aging – <i>What Are Neurodegenerative Diseases?</i> | <a href="https://www.nia.nih.gov/health">https://www.nia.nih.gov/health</a> |
| [32] | National Institute of Neurological                                        | <a href="https://www.ninds.nih.gov">https://www.ninds.nih.gov</a>           |



|      |                                                                                               |                                                                                                                                                                                                         |
|------|-----------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|      | <b>Disorders and Stroke (NINDS)</b>                                                           |                                                                                                                                                                                                         |
| [35] | <b>World Health Organization – <i>Dementia</i></b>                                            | <a href="https://www.who.int/news-room/fact-sheets/detail/dementia">https://www.who.int/news-room/fact-sheets/detail/dementia</a>                                                                       |
| [36] | <b>Parkinson's Foundation – <i>What is Parkinson's Disease?</i></b>                           | <a href="https://www.parkinson.org/understanding-parkinsons/what-is-parkinsons">https://www.parkinson.org/understanding-parkinsons/what-is-parkinsons</a>                                               |
| [37] | <b>Huntington's Disease Society of America</b>                                                | <a href="https://hdsa.org/what-is-hd/">https://hdsa.org/what-is-hd/</a>                                                                                                                                 |
| [38] | <b>National Multiple Sclerosis Society</b>                                                    | <a href="https://www.nationalmssociety.org/What-is-MS">https://www.nationalmssociety.org/What-is-MS</a>                                                                                                 |
| [39] | <b>National Institute on Aging – <i>What Happens to the Brain in Alzheimer's Disease?</i></b> | <a href="https://www.nia.nih.gov/health/alzheimers-and-dementia/what-happens-brain-alzheimers-disease">https://www.nia.nih.gov/health/alzheimers-and-dementia/what-happens-brain-alzheimers-disease</a> |
| [40] | <b>Alzheimer's Association – <i>Risk Factors for Alzheimer's Disease</i></b>                  | <a href="https://www.alz.org/alzheimers-dementia/what-is-alzheimers/risk-factors">https://www.alz.org/alzheimers-dementia/what-is-alzheimers/risk-factors</a>                                           |
| [41] | <b>World Health Organization – <i>Risk reduction of cognitive decline and dementia</i></b>    | <a href="https://www.who.int/publications/i/item/9789241550543">https://www.who.int/publications/i/item/9789241550543</a>                                                                               |
| [42] | <b>Alzheimer's Association – <i>10 Early Signs and</i></b>                                    | <a href="https://www.alz.org/alzheimers-dementia/10_signs">https://www.alz.org/alzheimers-dementia/10_signs</a>                                                                                         |

|      |                                                                              |                                                                                                                                                                                                         |
|------|------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
|      | <i>Symptoms of Alzheimer's</i>                                               |                                                                                                                                                                                                         |
| [43] | Alzheimer's Society – <i>Symptoms and progression of Alzheimer's disease</i> | <a href="https://www.alzheimers.org.uk/about-dementia/types-dementia/alzheimers-disease">https://www.alzheimers.org.uk/about-dementia/types-dementia/alzheimers-disease</a>                             |
| [44] | RadiologyInfo – <i>X-ray (Radiography)</i>                                   | <a href="https://www.radiologyinfo.org/en/info/xray">https://www.radiologyinfo.org/en/info/xray</a>                                                                                                     |
| [45] | RadiologyInfo – <i>Magnetic Resonance Imaging (MRI)</i>                      | <a href="https://www.radiologyinfo.org/en/info/mri">https://www.radiologyinfo.org/en/info/mri</a>                                                                                                       |
| [46] | RadiologyInfo – <i>Computed Tomography (CT Scan)</i>                         | <a href="https://www.radiologyinfo.org/en/info/ctscan">https://www.radiologyinfo.org/en/info/ctscan</a>                                                                                                 |
| [47] | RadiologyInfo – <i>Medical Imaging</i>                                       | <a href="https://www.radiologyinfo.org">https://www.radiologyinfo.org</a>                                                                                                                               |
| [48] | RadiologyInfo – <i>Functional MRI (fMRI)</i>                                 | <a href="https://www.radiologyinfo.org/en/info/fmribrain">https://www.radiologyinfo.org/en/info/fmribrain</a>                                                                                           |
| [49] | RadiologyInfo – <i>Diffusion Tensor Imaging (DTI)</i>                        | <a href="https://www.radiologyinfo.org/en/info/dti">https://www.radiologyinfo.org/en/info/dti</a>                                                                                                       |
| [50] | National Institute on Aging – <i>Brain Changes in Alzheimer's Disease</i>    | <a href="https://www.nia.nih.gov/health/alzheimers-and-dementia/what-happens-brain-alzheimers-disease">https://www.nia.nih.gov/health/alzheimers-and-dementia/what-happens-brain-alzheimers-disease</a> |
| [52] | World Health Organization – <i>Ethics and governance of AI for health</i>    | <a href="https://www.who.int/publications/i/item/9789240029200">https://www.who.int/publications/i/item/9789240029200</a>                                                                               |

|      |                                                         |                                                                                                                                                                                         |
|------|---------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| [53] | IBM – <i>Artificial Intelligence (AI)</i>               | <a href="https://www.ibm.com/topics/artificial-intelligence">https://www.ibm.com/topics/artificial-intelligence</a>                                                                     |
| [54] | IBM – <i>Machine Learning</i>                           | <a href="https://www.ibm.com/topics/machine-learning">https://www.ibm.com/topics/machine-learning</a>                                                                                   |
| [55] | Microsoft Learn – <i>What is supervised learning?</i>   | <a href="https://learn.microsoft.com/en-us/training/modules/introduction-to-machine-learning/">https://learn.microsoft.com/en-us/training/modules/introduction-to-machine-learning/</a> |
| [56] | IBM – <i>Unsupervised Learning</i>                      | <a href="https://www.ibm.com/topics/unsupervised-learning">https://www.ibm.com/topics/unsupervised-learning</a>                                                                         |
| [58] | IBM – <i>Reinforcement Learning</i>                     | <a href="https://www.ibm.com/topics/reinforcement-learning">https://www.ibm.com/topics/reinforcement-learning</a>                                                                       |
| [59] | TensorFlow – <i>Convolutional Neural Networks (CNN)</i> | <a href="https://www.tensorflow.org/tutorials/images/cnn">https://www.tensorflow.org/tutorials/images/cnn</a>                                                                           |
| [60] | TensorFlow – <i>Classification with Keras</i>           | <a href="https://www.tensorflow.org/tutorials/images/classification">https://www.tensorflow.org/tutorials/images/classification</a>                                                     |
| [61] | TensorFlow API – <i>Batch Normalization</i>             | <a href="https://www.tensorflow.org/api_docs/python/tf/keras/layers/BatchNormalization">https://www.tensorflow.org/api_docs/python/tf/keras/layers/BatchNormalization</a>               |
| [62] | TensorFlow – <i>Pooling Layers</i>                      | <a href="https://www.tensorflow.org/api_docs/python/tf/keras/layers/MaxPooling2D">https://www.tensorflow.org/api_docs/python/tf/keras/layers/MaxPooling2D</a>                           |
| [63] | Google AI – <i>MobileNetV2</i>                          | <a href="https://ai.googleblog.com/2018/04/mobilenetv2-next-generation-of-on.html">https://ai.googleblog.com/2018/04/mobilenetv2-next-generation-of-on.html</a>                         |
| [64] | TensorFlow Keras – <i>MobileNetV2</i>                   | <a href="https://keras.io/api/applications/mobilenet/">https://keras.io/api/applications/mobilenet/</a>                                                                                 |

## **Résumé**

*Ce projet de fin d'études porte sur le développement d'un système intelligent destiné à la détection de la maladie d'Alzheimer à partir d'images d'Imagerie par Résonance Magnétique (IRM) en utilisant des techniques de Deep Learning. L'objectif principal est de classifier automatiquement les images IRM en trois catégories : Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI) et Cognitively Normal (CN).*

*Les images utilisées proviennent de la base de données ADNI et ont subi plusieurs étapes de prétraitement, notamment la lecture des fichiers DICOM, le redimensionnement, la normalisation, la conversion en RGB ainsi que l'augmentation des données (Data Augmentation). Deux modèles de Deep Learning ont été développés et comparés : un réseau de neurones convolutif (CNN) conçu spécifiquement pour cette étude et un modèle de Transfer Learning basé sur MobileNetV2.*

*Les performances des modèles ont été évaluées à l'aide de plusieurs métriques, notamment l'accuracy, la précision, le rappel (recall), le F1-score, la matrice de confusion ainsi que la courbe ROC. Les résultats expérimentaux montrent que le modèle MobileNetV2 a obtenu les meilleures performances avec une accuracy de 91 %, tandis que le modèle CNN a atteint 87 %. Une comparaison avec plusieurs travaux de la littérature a permis de situer les performances obtenues. Enfin, la méthode Grad-CAM a été utilisée afin d'améliorer l'interprétabilité des prédictions en mettant en évidence les régions cérébrales ayant le plus influencé les décisions des modèles.*

### *Mots clés :*

*Maladie d'Alzheimer, IRM, Deep Learning, CNN, MobileNetV2, Transfer Learning, Grad-CAM, ADNI.*

## **Abstract**

*This final-year project focuses on the development of an intelligent system for the detection of Alzheimer's disease from Magnetic Resonance Imaging (MRI) using Deep Learning techniques. The main objective is to automatically classify brain MRI images into three categories: Alzheimer's Disease (AD), Mild Cognitive Impairment (MCI), and Cognitively Normal (CN).*

*The MRI images were obtained from the ADNI database and underwent several preprocessing steps, including DICOM image reading, resizing, normalization, RGB conversion, and data augmentation. Two Deep Learning approaches were implemented and compared: a custom Convolutional Neural Network (CNN) and a Transfer Learning model based on MobileNetV2.*

*The proposed models were evaluated using several performance metrics, including accuracy, precision, recall, F1-score, confusion matrix, and ROC curve. Experimental results showed that MobileNetV2 achieved the best performance with an accuracy of 91%, while the CNN model reached 87%. The obtained results were compared with several recent studies reported in the literature. Furthermore, the Grad-CAM explainability technique was employed to highlight the brain regions that contributed most to the model predictions, thereby improving the interpretability of the proposed system.*

### *Keywords:*

*Alzheimer's disease, MRI, Deep Learning, CNN, MobileNetV2, Transfer Learning, Grad-CAM, ADNI*